

安全调度技能（Safety Orchestrator Skill）技术路线

一、研究目标

本项目目标构建安全调度技能（Safety Orchestrator Skill）作为统一的安全调度层，其核心是一个轻量级安全路由（Safety Router），根据当前任务阶段和潜在风险类型，动态决定调用哪一个原子级安全技能（Atomic Safety Skill）。其中，向人类确认的安全哨兵 Skill 被视为最高权限的原子级安全技能，当风险无法判定时，Safety Router 主动路由到安全哨兵 Skill，终止自主执行，请求人类介入与确认。

二、总体技术思路

本系统由三个核心模块构成：Atomic Safety Skill 库构建、安全哨兵 skill 构建、轻量级 Safety Router 构建。三者的关系如下：Atomic Safety Skill 库提供可复用的安全能力单元（包括规则、工具、以及最高优先级的向人类确认的安全哨兵 skill）；安全路由根据任务阶段和风险类型，通过阅读 skill 的描述文件决策调用哪个原子技能；当风险无法判定调用安全哨兵 skill 时，安全哨兵输出当前风险是否需要人类介入予以确认。具体实现如下：

1. Atomic Safety Skill 库构建：对现有的各类安全能力进行拆解与标准化，形成可复用的 Atomic Safety Skill 库。具体技术路线如下：先采用人工和脚本结合的方式，筛选和整理收集公开 skills，拟收集来源如下：

来源类别	作用	代表对象
1. 官方 skill 仓库	高质量种子集，适合建立初始 schema 与去重标准	OpenAI skills（公开安全项较少）；Anthropic skills（安全思路更多散落在文档、PR、issue、discussion）；OpenClaw/ClawHub（安全相关 skill 密度最高，建议重点抓取）
2. 综合 skill 聚合站	扩大覆盖面，补足跨生态的显式 skill	Official Agent Skills Directory；VoltAgent/awesome-agent-skills 等
3. MCP 扫描/审计工具与注册表	补齐不以 skill 形式发布的安全能力	modelcontextprotocol/registry；Smithery；Glama；MCP.so / chat.mcp.so；PulseMCP 等。检索关键词建议扩展到 scanner、guardrail、audit、policy、trust、vetter
4. GitHub 安全专项项目	抓取更完整的安全流程、审计模板和	如 prompt-security/clawsec、UseAI-pro/openclaw-skills-security、slowmist/openclaw-

	规则集	security-practice-guide 等
5. 标准、博客与论文	为 Safety Orchestrator Skill 提供统一规范与风险 taxonomy	如 OWASP Agentic Skills Top 10; Snyk ToxicSkills 研究; 相关 MCP 安全研究与行业博客

收集完成后，对每个候选技能形成基础记录，包括来源、版本、用途说明和当前状态。其次，将结构化后的安全 skill 进一步拆解为更小的安全 skill 单元，例如检测意图歧义、检查参数安全、约束工作区边界、检查敏感信息外泄等。随后再对这些能力做语义对齐、去重和合并，形成一个内部一致的 Atomic Safety Skill 库。

2. **安全哨兵 Skill 构建**：构建安全哨兵 Skill 作为 Atomic Safety Skill 库中的一个特殊技能，当风险无法判定时，安全路由主动调用安全哨兵 Skill，用于判断是否需要人类介入。具体技术路线如下：构建面向任务执行过程的状态表示，包括任务进度、工具调用轨迹、环境反馈、历史决策序列等多模态/结构化信息。基于历史交互数据标注人类是否介入的关键节点，形成训练数据，训练二分类预测模型（3b Llama），输出当前时刻是否需要人类介入的风险概率。在风险感知基础上，引入可调节阈值机制，实现不同任务场景下自主性与安全性的动态平衡。安全哨兵作为原子级 skill 库被定义为一个特殊的原子技能，拥有最高优先级。

3. **Safety Router 构建**：为满足轻量化、延迟低、算力低的 Router 需求，Router 内部维护一张阶段-技能映射表。根据当前任务阶段（如输入理解、规划决策、工具调用、输出生成）和风险类型，通过阅读 Atomic Safety Skill 描述文件完成 Router 决策，确保轻量化。在智能体执行任务的全生命周期中，Router 先判断当前任务处于哪个阶段，再根据映射表加载对应的原子技能进行检查和约束。当路由到安全哨兵 skill 时，系统暂停自动化执行，向人类发送确认请求，等待人类反馈后继续。

三、预期产出

本项目最终希望形成三类清晰的产出。第一，形成一个独立的安全哨兵模块工具，即插即用，可以适配各种 Agent 框架。第二，形成一套面向 Agent 全执行链路的细粒度攻击面 taxonomy 和 atomic skill 库，用于统一描述安全问题和防护动作。第三，形成一个可运行的 Safety Orchestrator Skill 工具，包括候选技能的审计与结构化流程、原子能力库，以及运行时的阶段化路由与仲裁模块。