




人工智能平台 V5.0

普通用户手册

软件版本：V5.0

文档版本：V1.0

发布日期：2024 年 6 月 25 日



浪潮电子信息产业股份有限公司
Inspur Electronic Information Industry Co., Ltd

版权所有 © 浪潮电子信息产业股份有限公司。保留一切权力

未经本公司书面许可，任何单位和个人不得以任何形式复制、传播本手册的部分或全部内容。

安全声明

公司产品不会主动获取或使用用户的个人数据，仅在您同意使用特定功能或服务时，在业务运营或故障定位的过程中可能会获取或使用用户的某些个人数据（如告警邮件接收地址、IP 地址），公司产品在涉及个人数据的收集、存储、使用、传输、删除等全生命周期的处理活动中，已在产品功能上部署了必要的安全保护措施，同时，您也有义务根据所适用国家或地区的法律法规制定必要的用户隐私政策并采取足够的措施以确保用户的个人数据受到充分的保护。

浪潮信息高度重视产品数据安全，公司产品在涉及系统运行和安全数据的全生命周期处理活动中，已严格按照相关法律法规及监管要求，在产品功能上部署了必要的安全保护措施。作为系统运行和安全数据处理者，您有义务根据所适用国家或地区的法律法规制定必要的数据安全政策并采取足够的措施以确保系统运行和安全数据受到充分的保护。

浪潮信息将一如既往的严密关注产品与解决方案的安全性，为客户提供更满意的服务。浪潮信息已全面建立产品安全漏洞应急和处理机制，确保第一时间处理产品安全问题。若您在本产品使用过程中发现任何安全问题，或者寻求有关产品安全漏洞的必要支持，请直接联系浪潮信息客户服务人员。

内容声明

您购买的产品、服务或特性应受浪潮信息商业合同和条款的约束，本文档中描述的全部或部分产品、服务或特性可能不在您的购买或使用范围之内。除非合同另有约定，浪潮信息对本文档内容不做任何明示或默示的声明或保证。文档中的示意图与产品实物可能有差别，请以实物为准。

本文档仅作为使用指导，不对使用我们产品之前、期间或之后发生的任何损害负责。文档所含内容如有升级或更新，恕不另行通知。

目录

普通用户 1

整体介绍 2

 名词、术语介绍 4

 系统要求 6

首页 7

 快速入门 8

 使用详情 8

 资源配额 9

 个人资源详情 9

 用户组资源详情 11

 场景资源详情 12

 资源使用状态 (已用/总量) 13

 资源组使用情况 13

 节点使用情况 14

AI 开发 15

 模型开发 15

 开发环境 15

 模型训练 20

 工作流管理 31

 算法管理 35

 模型管理 48

 模型列表 48

 导入模型 48

 新增版本 51

 共享模型 53

 取消共享 53

 删除模型 54

 编辑模型基本信息 54

 导出模型版本 54

 发起模型测试 55

发布模型版本	56
生成应用	57
编辑模型版本	57
删除模型版本	58
模型传输列表	59
推理服务	59
服务部署	59
原生部署	89
服务编排	96
推理任务	101
存储卷管理	106
大模型开发	109
模型微调	109
创建微调任务	109
创建导出模型任务	115
停止微调任务	119
启动微调任务	119
重新提交微调任务	119
删除微调任务	119
筛选未终结任务	119
筛选终结任务	120
查看微调日志	120
查看容器实例	120
查看任务基本信息	121
任务可视化	121
提交紧急任务	122
模型仓库	122
模型列表	122
导入模型	123
新增版本	126
共享模型	128


取消共享	128
删除模型	128
编辑模型基本信息	129
导出模型版本	129
发布模型版本	130
生成应用	130
编辑模型版本	131
删除模型版本	132
模型传输列表	133
服务部署	133
Chat	156
模型选择	156
对话参数	157
对话	159
历史记录	160
新建对话	162
清空对话	162
Prompt 模板	162
Prompt 管理	164
列表	164
创建	164
详情	166
编辑	166
删除	167
共享	167
资产	168
数据管理	168
文件管理	168
数据集管理	187
数据下载	194
创建数据下载任务	194

数据下载任务列表	196
数据下载任务详情	197
数据下载任务暂停	197
数据下载任务启动	198
数据下载任务删除	198
镜像管理	198
镜像查询	198
镜像分享	200
取消分享	200
镜像删除	200
导出镜像	201
生成懒加载镜像	202
创建镜像	203
内部导入镜像	204
外部镜像导入	205
修改镜像	206
修改镜像 Logo	207
镜像发布	207
应用商店	208
应用列表	208
应用导入	209
应用详情	215
应用编辑	225
设置应用权限	225
转移所有权	225
应用删除	226
监控统计	226
监控告警	226
告警列表	226
系统管理	227
资源管理	227

资源组	227
节点管理	228
设置	231
公告管理	231
消息中心	232
日志管理	233
审批管理	234
服务调用数据	236
API 授权	240
AK/SK 签名认证	242
工具指南	243
Jupyter Lab 简介及常用操作	243
打开 Jupyter Lab	243
默认文件目录	243
预置 Jupyter-Example 使用	243
Kernel 重启	244
镜像组件安装手册	244
基于 CentOS 安装组件	245
基于 Ubuntu 安装组件	248
镜像制作手册	251
基础镜像	251
安装组件	266
配置适配平台的组件	272
可视化功能使用说明	272
任务管理可视化	272
开发环境可视化	275
PyCharm 对接平台	276
PyCharm 配置	276
通过 SSH 连接到开发环境	280
配置 Remote Debug	283
开发环境配置相关 debug 包	287

- 配置 Remote debug 288
- VSCode 对接平台 293
 - Remote-ssh 插件 294
 - Rmate 插件 297
- 预置算例-开发环境使用说明 298
 - 注意: 298
 - 创建开发环境 299
 - 开发环境模型调试 301
- 预置算例-训练任务使用说明 304
 - 训练任务创建 304
 - 单机任务创建 306
 - 分布式任务创建 308
 - MPI 任务创建 309
- 数据处理工具-通过开发环境启动镜像使用说明 310
 - 通过开发环境启动数据处理工具镜像 311

普通用户



注意：1、当平台激活为“旗舰版”时，当前用户的业务范围是训练时，显示图中公共模块和训练模块；2、当平台激活为“旗舰版”时，当前用户的业务范围是推理时，显示图中公共模块和推理模块；3、当平台激活为“旗舰版”时，当前用户的业务范围是训练 + 推理时，显示图中所有模块；4、当平台激活为“企业版”时，当前用户的业务范围是训练时，显示图中除大模型之外的公共模块和训练模块；5、当平台激活为“企业版”时，当前用户的业务范围是推理时，显示图中除大模型之外的公共模块和推理模块；

6、当平台激活为“企业版”时，当前用户的业务范围是训练 + 推理时，显示图中除大模型之外的所有模块；7、当平台激活为“标准版”时，显示图中除大模型之外的公共模块和训练模块；8、AK/SK 签名认证在当前用户具有开发权限时显示

整体介绍

人工智能平台以客户需求为导向，依托自主研发及技术持续创新，聚焦安防、金融、能源、汽车、教育等产业用户，致力于成为业内领先、高性能、可扩展、稳定安全的企业级人工智能平台。人工智能平台提供异构计算集群的资源统一管理和多策略调度、可视化 AI 建模、AI 训练作业、AI 服务部署的全生命周期管理。

人工智能平台可以帮助普通用户实现如下功能：

1. 提供多种数据使用方式

人工智能平台提供四种数据使用方式：用户自有数据、用户组共享数据、平台全局共享数据、全局样本数据，这四类数据分别存放在不同存储空间中，用户可以按需选择不同存储空间的数据。

2. 在线模型开发功能

人工智能平台的默认镜像均提供了 JupyterLab 功能，每个用户创建的开发环境自带 JupyterLab，便于进行交互式模型开发，使用 JupyterLab 可以快速构建一个独立的 IDE 开发环境。

3. 开发环境多种连接方式

用户可以通过 web 版 shell、本地 shell、VSCode 远程连接、PyCharm 远程连接等四种方式连接所创建的开发环境，可根据使用习惯灵活选择需要的连接方式。

4. 多种深度学习训练任务模式

用户可以通过人工智能平台便捷地提交单机训练任务和分布式训练任务，支持 TensorFlow、PyTorch、MXNet、Caffe、PaddlePaddle 等业界主流的深度学习框架。

5. 多种资源自动匹配

人工智能平台可以自动识别集群中的不同加速卡类型（GPU、MLU、BI 等），调度器会根据业务需求自动将任务调度到所需类型的加速卡上。

6. 自动任务容错

人工智能平台提供多种训练任务容错方式，可自动识别网络中断、服务器宕机、加速卡丢失等异常所导致的任务错误，自动从 checkpoint 重新拉起训练任务，确保用户训练任务的可靠运行。

人工智能平台可以帮助组管理员用户实现如下功能：

1. 模型开发

组管理员可以对同一个用户组内所有用户的开发作业、训练作业进行有效管理，及时了解组内业务的详细情况。

2. 用户管理

组管理员可以即时调整组内用户的资源配额、以及包括紧急任务队列和模型发布在内的特殊权限，避免因资源分配不合理影响组内业务进展，提升整体开发工作效率。

3. 账单管理

组管理员可以获取组内多维度的计费账单，包括总体账单、组内用户账单、组账单、任务账单等，及时了解组内资源和预算的使用情况。

人工智能平台可以帮助管理员用户实现如下功能：

1. 多维度运营分析

系统管理员可以通过人工智能平台方便快捷地获得集群、节点、加速卡等不同资源粒度的即时使用信息，并通过多维度、自定义报表功能，获得集群、资源组、节点、用户/用户组、任务的历史统计信息，全面掌握集群的运行情况。通过人工智能平台的计费功能，管理员可以获得自定义日期的总体账单、用户账单、用户组账单、任务账单等多种账单报表，满足不同业务的计费需求。

2. 资源精细化管理

系统管理员可以通过人工智能平台对 AI 训练集群以节点为粒度灵活划分为开发资源组、训练资源组、通用资源组等三种资源组，以承载不同的 AI 开发业务需求。通过 GPU 共享模式设置，可以快速实现 MIG、无显存控制的多任务复用、显存严格控制的多任务复用等三种作业共享模式，以适用不同的开发场景。

系统管理员还可以对用户的容器环境设置超时策略，触发超时限制条件的用户资源可以被系统提示给管理员回收，避免资源被长期无效占用，提升系统资源使用效率。

3. 多租户管理

系统管理员可以通过人工智能平台实现多级组织管理，管理普通用户、组管理员、审计员、系统管理员等四种用户角色，并实现多级组织资源的配额管理。系统管理员也可以设置每个用户的特殊业务权限，包括样本数据可见空间、数据下载、紧急任务队列、模型发布等，满足精细化控制场景的需求。

4. 智能运维

系统管理员可以通过人工智能平台的智能运维功能，实时监测平台关键组件的运行状态，快速处理异常，保障业务正常运行。通过自定义设置集群告警事件，系统管理员可以及时获取集群的异常事件，并快速

响应，提升集群运维效率。

名词、术语介绍

名称	说明
InfluxDB	InfluxDB 是一种流行的开源时序数据库，专门设计用于处理时间序列数据；用于存储平台内产生的监控数据（包括：CPU 性能数据、加速卡性能数据、内存性能数据、网卡性能数据等）和报表数据（包括：任务机时报表、概况统计报表、存储报表等）
Telegraf	Telegraf 是一款基于插件化的开源指标收集工具，支持按照时间间隔周期性的输出数据到时序数据库中；平台内主要用于节点（CPU、内存、磁盘等）、加速卡（显存利用率、利用率、显存大小、温度等）、高速网卡（IB 或 RoCE 等）等性能数据的采集
IB	Infiniband 协议，一整套完整的链路层到传输层规范，是一个用于高性能计算的计算机网络通信标准，具有极高的吞吐量和极低的延迟，用于计算机与计算机之间的数据高速互连
MIG	nvidia 提供的物理切分 GPU 功能，可以将单个 GPU 切分为多个不同规格的实例，每个实例均完全独立于各自的高带宽显存、缓存和计算核心
GPU 显存隔离	每个 GPU 实例可隔离使用的 GPU 显存，各个实例之间的显存互相隔离互不影响
GPU 复用率	每个 GPU 卡可被几个容器共享使用
RoCE	RoCE(RDMA over Converged Ethernet), 基于以太网协议支持 RDMA，可以复用已有的以太网设施，包括 RoCEv1 和 RoCEv2 两个版本
配额	Quota 是一种资源使用限制，可以对用户用户组进行配额管理，管理的内容为 CPU、加速卡、存储等对象

名称	说明
Docker	Docker 是一个被广泛使用的开源容器引擎，是一种操作系统级别的虚拟化技术
Harbor	Harbor 是容器镜像仓库开源项目，包括了权限管理 (RBAC)、LDAP、审计、安全漏洞扫描、镜像验真、管理界面、自我注册等功能
OpenLDAP	OpenLDAP 是一个轻量级目录访问协议 (LDAP) 的开源实现，在平台中主要用于用户认证系统使用，实现用户账号存储和认证功能
K8S	Kubernetes，开源的容器集群管理平台，提供了灵活的容器编排策略、资源调度策略、集群运维、网络管理等能力，有非常完善的生态，是目前主流的容器编排平台
DCGM	DCGM(Data Center GPU Manager) 即数据中心 GPU 管理器，是一种 NVIDIA 提供的用于在集群环境中管理和监控 GPU 的组件工具
PyTorch	PyTorch 是一个开源的 Python 学习库，基于 Torch，用于图像处理、自然语言处理等人工智能应用程序
Caffe	Caffe (全称 Convolutional Architecture for Fast Feature Embedding) 是一个兼具表达性、速度和思维模块化的深度学习框架
tensorflow	tensorflow 是由谷歌人工智能团队谷歌大脑开发和维护的深度学习平台, 目前人工智能领域主流的开发平台, 在全球有着广泛的用户群体
PaddlePaddle	飞桨 (PaddlePaddle) 以百度多年的深度学习技术研究和业务应用为基础，集核心框架、基础模型库、端到端开发套件、丰富的工具于一体的开源开放的产业级深度学习平台
mxnet	mxnet 是一个灵活且可扩展的深度学习框架, 支持多种深度学习模型、编程语言

名称	说明
NFS	NFS (Network File System) 是网络文件系统，它允许网络中的计算机之间通过 TCP/IP 网络共享资源。在 NFS 的应用中，本地 NFS 的客户端应用可以透明地读写位于远端 NFS 服务器上的文件，就像访问本地文件一样
hdfs	HDFS 是以 master-slave 形式存在，一个集群存在一个 master (NameNode) 节点和若干个 slave (DataNode) 节点，主节点负责存储元数据信息以及任务分配，从节点则负责存储实际的数据
Ceph	Ceph 是一款分布式存储系统，Ceph 可以将多台服务器组成一个超大集群，把这些机器中的磁盘资源整合到一块儿，形成一个大的资源池，然后按需分配给客户端应用使用
GPFS	GPFS (General Parallel File System) 是一款并行的文件系统，它保证在资源组内的所有节点可以并行访问整个文件系统，而且针对此文件系统的服务操作，可以同时安全地在此文件系统的多个节点上实现。它允许客户共享文件，而这些文件可能分布在不同节点的不同硬盘上，保证了数据的一致性和完整性
kServe	KServe 提供一个 Kubernetes 自定义资源定义，用于在任意框架上提供模型服务。它旨在通过为常见的 ML 框架 (如：Tensorflow、XGBoost、Scikit-Learn、PyTorch 和 ONNX) 提供高性能、高度抽象的接口来解决生产模型服务场景

系统要求

人工智能平台需要以下软件环境支撑：


客户浏览端：

操作系统：windows 10 及以上版本。

浏览器：chrome86 及以上版本。

首页

普通用户登录系统之后可以在首页中直观的看到快速入门、个人相关的使用详情、资源配额，如下图所示：





上图中包含的具体信息详细说明如下：

快速入门

平台业务使用的快速入门，可通过相关快捷方式使用相关业务功能。

使用详情

使用详情主要包括以下内容：

名称	说明	业务范围
开发环境	开发环境中个人的总数、运行中个数	训练 + 推理、训练
训练任务	任务管理中个人所有未删除任务的总数 (任务管理 + 终结任务)、运行中个数	训练 + 推理、训练
工作流	工作流管理中个人工作流的总数、执行中个数	训练 + 推理、训练
算法	算法管理中个人算法的总数、已发布个数	训练 + 推理、训练

名称	说明	业务范围
镜像	镜像中个人镜像的总数	训练 + 推理、训练
场景	场景管理中个人绑定的场景总数	训练 + 推理、推理
数据集	数据集管理中个人数据集总数	训练 + 推理、训练
模型	统计 AI 开发的模型，模型管理中个人模型总数、版本数	训练 + 推理、训练
大模型	大模型统计，模型仓库中个人模型总数、版本数	训练 + 推理
告警	最近半年内集群所有未解决的告警总数	训练 + 推理、训练、推理
服务	展示模型服务中通用模型、应用部署、原生部署、HELM 部署的服务总数、和已上线数量（通用模型、应用部署、原生部署的就绪状态，HELM 部署的运行中状态）	训练 + 推理、推理
大模型服务	展示大模型服务总数、和就绪数量	训练 + 推理
应用	用户个人应用总数	训练 + 推理、推理

资源配额

显示用户的个人资源配额、用户所属用户组的组资源配额、用户的场景资源配额等数据。

个人资源详情

“首页 > 资源配额 > 个人”，在业务范围是训练 + 推理、训练下可用

显示当前用户个人资源的使用情况，包括磁盘配额、资源配额 (按照资源组-资源系列-资源类型三个维度

管理), 其中资源配额, 比如 CPU、GPU 等, 可以按照设置的资源组维度配额进行筛选, 配额包括:

名称	说明
GPU-ALL 使用情况	总量 (创建用户时分配的资源大小, 可以设置为无限制)、已用 (非停止状态的开发环境 + 排队中 (非 Queuing)、数据拉取中、镜像拉取中、运行中状态的训练任务使用 GPU 卡的和)、可用 (总量-已用); MIG 下实例按整卡算
MLU-ALL 使用情况	总量 (创建用户时分配的资源大小, 可以设置为无限制)、已用 (非停止状态的开发环境 + 排队中 (非 Queuing)、数据拉取中、镜像拉取中、运行中状态的训练任务使用 MLU 卡的和)、可用 (总量-已用)
其他某类型加速卡使用情况	总量 (创建用户时分配的资源大小, 可以设置为无限制)、已用 (非停止状态的开发环境 + 排队中 (非 Queuing)、数据拉取中、镜像拉取中、运行中状态的训练任务使用其他某类型加速卡的和)、可用 (总量-已用)
CPU 使用情况	总量 (创建用户时分配的资源大小, 可以设置为无限制)、已用 (非停止状态的开发环境 + 排队中 (非 Queuing)、数据拉取中、镜像拉取中、运行中状态的训练任务使用 CPU 的和)、可用 (总量-已用)
磁盘使用情况	总量 (创建用户时分配的资源大小, 可以设置为无限制)、已用 (统计当前用户的用户目录在节点中的实际使用空间)、可用 (总量-已用)

磁盘使用量包含各个存储使用详情。磁盘使用量支持手动刷新, 展示磁盘更新时间, 手动刷新统计范围只统计用户家目录使用量, 不统计组共享和全局共享用户存储使用量。

注意:

1. 类似 GPU-ALL 第二位 ALL 是加速卡类型维度, 可能为 GPU-Tesla-P100-PCIE-16GB; 当总量为无限制时, 可用也为无限制; 当已用超过总量时, 可用显示为 0, 同时在页面初始化加载后进行弹框提示配额超出; 当集群中没有 MLU 节点的时候, MLU 使用情况将不会展示; 当集群中没有其他类型加速卡

节点的时候，其他某类型加速卡卡数将不会展示。

2. 说明中的训练任务包括“任务管理”中全部类型的任务。

用户组资源详情

显示当前用户所在用户组资源的使用情况，分为训练、推理两种，包括：

用户组训练配额

“首页 > 资源配额 > 用户组 > 训练资源”，在业务范围是训练 + 推理、训练下可用

名称	说明
磁盘	已用（当前用户所在用户组，用户组所有家目录、组共享和全局共享使用之和）、总量（管理员创建用户组时分配的资源大小，可以设置为无限制）
CPU 核数	已用（当前用户所在用户组，非停止状态的开发环境 + 排队中 (非 Queuing)、数据拉取中、镜像拉取中、运行中状态的训练任务使用 CPU 的和）、总量（管理员创建用户组时分配的 CPU 核数大小，可以配置为无限制）
GPU 卡数	已用（当前用户所在用户组，非停止状态的开发环境 + 排队中 (非 Queuing)、数据拉取中、镜像拉取中、运行中状态的训练任务使用 GPU 的和）、总量（管理员创建用户组时分配的 GPU 卡大小，可以配置为无限制）； MIG 下实例按整卡算
MLU 卡数	已用（当前用户所在用户组，非停止状态的开发环境 + 排队中 (非 Queuing)、数据拉取中、镜像拉取中、运行中状态的训练任务使用 MLU 的和）、总量（管理员创建用户组时分配的 MLU 卡大小，可以配置为无限制）

名称	说明
其他某类型加速卡卡数	已用（当前用户所在用户组，非停止状态的开发环境 + 排队中 (非 Queuing)、数据拉取中、镜像拉取中、运行中状态的训练任务使用其他某类型加速卡的和）、总量（管理员创建用户组时分配的其他类型加速卡大小，可以配置为无限制）

磁盘使用量包含各个存储使用详情。

注意：

- 1. 当集群中没有 MLU 节点的时候，MLU 卡数将不会展示；当集群中没有其他类型加速卡节点的时候，其他某类型加速卡卡数将不会展示。
- 2. 说明中的训练任务包括“任务管理”中全部类型的任务。

用户组推理配额

“首页 > 资源配额 > 用户组 > 推理资源”，在业务范围是训练 + 推理、推理下可用

名称	说明
内存	已用、总量（管理员创建用户组时分配的内存大小，不能配置为无限制）
存储类 XXX	已用、总量（管理员创建用户组时分配的存储类大小，不能配置为无限制）
CPU 核数	已用、总量（管理员创建用户组时分配的 CPU 核数大小，不能配置为无限制）
NVIDIA-AXX-PCIE-40GB 卡数	已用、总量（管理员创建用户组时分配的加速卡大小，不能配置为无限制）

场景资源详情

“首页 > 资源配额 > 场景”，在业务范围是训练 + 推理、推理下可用

显示当前用户绑定的场景资源的使用情况，包括：

名称	说明
内存	已用、总量（管理员创建场景时分配的内存大小，不能配置为无限制）
存储类 XXX	已用、总量（管理员创建场景时分配的存储类大小，不能配置为无限制）
CPU 核数	已用、总量（管理员创建场景时分配的 CPU 核数大小，不能配置为无限制）
NVIDIA-AXX-PCIE-40GB 卡数	已用、总量（管理员创建场景时分配的加速卡卡大小，不能配置为无限制）

资源使用状态 (已用/总量)

“首页 > 资源配额 > 个人”，在业务范围是训练 + 推理、训练、推理下可用

显示当前用户所在资源组以及资源组内节点的资源使用情况，包括：

资源组使用情况

名称	说明
CPU 核数	已用（统计当前资源组下实际使用的 CPU 核数，包括组件使用）、总量（统计当前资源组下所有节点的实际 CPU 核数）
加速卡数	已用（统计当前资源组下实际使用的加速卡数，如果同一个卡被多个任务使用则只统计一次，已用不会超过总量）、总量（统计当前资源组下所有节点的实际加速卡数）；MIG 下实例按整卡算
GPU 共享-复用率	已用（统计当前资源组下所有任务使用的 GPU 共享数量）、总量（该资源组下 GPU 复用的个数），如果不是共享则显示“-”
GPU 共享-显存隔离	已用（统计当前资源组下所有任务使用的 GPU 显存大小）、总量（该资源组下 GPU 显存复用大小）

名称	说明
GPU MIG	(按照 MIG 规格统计当前资源组下所有任务使用的 GPU 数量)、总量 (按照 MIG 规格统计该资源组下 GPU 个数)

注意：共享模式下包括 GPU 复用率、GPU 显存隔离、GPU MIG。

节点使用情况

名称	说明
节点名称	当前用户所在资源组内包含的节点的名称
CPU 核数	已用 (统计当前节点下 CPU 实际使用的数量, 包括节点组件中使用的资源, 向上取整, 不能超过总量)、总量 (该节点下 CPU 总核数)
加速卡数	已用 (统计当前节点下实际使用的加速卡数, 如果同一个卡被多个任务使用则只统计一次, 已用不会超过总量)、总量 (统计当前节点下的实际加速卡数); MIG 下实例按整卡算
GPU 共享-复用率	已用 (统计当前节点下所有任务使用的 GPU 共享数量)、总量 (该节点下 GPU 复用的个数), 如果不是共享则显示 “-”
GPU 共享-显存隔离	已用 (统计当前节点下所有任务使用的 GPU 显存大小)、总量 (该节点下 GPU 显存复用大小)
GPU MIG	已用 (按照 MIG 规格统计当前节点下所有任务使用的 GPU 数量)、总量 (按照 MIG 规格统计该节点下 GPU 个数)

注意：共享模式下包括 GPU 复用率、GPU 显存隔离、GPU MIG。

AI 开发

模型开发

开发环境

“模型开发 > 开发环境”，在业务范围是训练 + 推理、训练下可用

开发环境列表

单击左侧导航栏中的开发环境，打开开发环境列表页面，页面顶部展示开发环境汇总信息，列表中展示开发环境的基本信息，列表右侧展示相关操作按钮。可以选中多个开发环境单击右上角删除按钮进行批量删除，或者单击任一开发环境右侧操作区域的下拉栏中的删除选项，如下：

当前开发环境 2CPU 已用 2加速卡独占 0GPU 复用 0

密码设置

创建

删除

☐	环境名称	状态	运行时长	剩余时长	资源信息	运行节点	镜像	操作
☐	20240514190137	排队中	0	-	Cards:0 CPU:1	node1(0, -.-) :	100.. adm	克隆 资源调整 删除
☐	20240514190129	运行中	4秒	56秒	Cards:0 CPU:1	node1(0, -.-) :	100.. adm	克隆 资源调整 删除

选择列

当前选中 0 条

共 2 条

50条/页

1

前往

1

页

单击顶部密码设置按钮设置开发环境 shell 密码，支持随机密码 (默认)、固定密码。

创建开发环境

用户单击页面中的创建按钮创建开发环境，支持从头创建开发环境 (目前支持 LLM、Caffe、TensorFlow、Mxnet、Pytorch、PaddlePaddle 和 Other 框架)，也支持基于历史的开发环境创建，并可以将历史开发环境进行归档与取消归档，归档之后展示优先级提前，用户可以选择资源组、资源配置、数据、模型、环境变量等信息，同时也可以指定节点，如下图：

最近创建开发环境

10.14.28.5000/pytorch/pytorch-admin:21.10-py3

加速卡*0

CPU*1

POD*1

2024-05-14 19:04:17

☆ 归档

100.2. , pytorch/pytorch-admin:21.10-py3

加速卡*0

CPU*1

POD*1

2024-05-14 19:04:11

☆ 归档

环境名称 *

20240514190218

镜像 *

外部镜像

请选择

请选择

资源配置

资源组 *

请选择

集群网络类型 *

请选择

加速卡系列 *

请选择

加速卡类型

请选择

数据配置

数据

文件管理

数据集管理

+ 选择数据

选择模型

+ 选择模型

环境变量

+ 添加环境变量

批量添加

更多选项

端口

+ 添加

批量添加


版权所有 © 浪潮电子信息产业股份有限公司

16


开发环境详情

用户在开发环境列表中，单击运行中的开发环境的名称，可以进入该开发环境的详情中，在详情页中，可以使用 Jupyter 对脚本进行编辑调试，可以使用 web shell 终端连接环境 (支持多窗口)，可以在容器实例中查看容器实例列表、性能监控，可以查看基本信息，同时也支持可视化 (目前支持 TensorBoard、Visdom、Netscope)、将当前开发环境保存为镜像，一键提交训练任务，查看训练任务等功能，如下图：


Jupyter:



Shell 终端:



容器实例:



容器实例列表包括：名称、状态、加速卡、节点、IP、端口、操作列。

功能	描述
容器列表-复制当前页容器信息	通过该功能可以复制当前容器列表中 (如果分页，需要切换分页才能复制其他页的数据) 所有容器的 Pod Name、节点 IP、容器 IP 信息
操作列-SSH	通过该功能可以复制连接相关容器的 ssh 命令、密码，注意，该功能需要相关镜像安装 ssh 组件
操作列-重启	通过该功能可以重启当前容器，如果出现个别容器启动失败，后续修复问题，可以通过该功能重启容器，不需要重启整个开发环境

性能曲线可以通过单击容器实例列表选择展示对应容器实例的数据，可以通过单击“15 分钟”、“4 小时”、“24 小时”、自定义时间限制查询时间范围，如果容器所在节点使用了 IB 或 RoCE 网络可以通过“Infiniband”弹框筛选性能曲线中展示的对应该网卡。

性能曲线指标包括：

场景	性能曲线指标
基本场景	CPU 利用率、内存利用率、网络输入/输出、内存总量/已用、磁盘输入/输出
使用 GPU 场景	基本场景下新增：加速卡利用率、加速卡显存利用率、加速卡显存已用、加速卡显存未用、draw_active、fp64_active、fp32_active、fp16_active、gr_engine_active、sm_active、sm_occupancy、tensor_active、pcie_rx_bytes、pcie_tx_bytes、nvlink_rx_bytes、nvlink_tx_bytes
使用 MIG 场景	基本场景下新增：MIG 显存利用率、MIG 显存已用、MIG 显存未用、draw_active、fp64_active、fp32_active、fp16_active、gr_engine_active、sm_active、sm_occupancy、tensor_active
使用 IB 或 RoCE 网络场景	基本场景下新增：ib_xmitdata、ib_rcvdata、ib_xmitpktsize、ib_rcvpktsize

注意：仅支持 NVIDIA DCGM Profiling Metrics 的 GPU 型号才会展示如下性能指标：gr_engine_active、sm_active、sm_occupancy、tensor_active、dram_active、fp16_active、fp32_active、fp64_active、pcie_rx_bytes、pcie_tx_bytes、nvlink_rx_bytes、nvlink_tx_bytes

基本信息：

Jupyter	Shell终端	容器实例	<u>基本信息</u>			
环境名称	20230530142930		创建时间	2023-05-30 14:30:04	状态	运行中
镜像	pytorch  rch/pytorch:21.10-py3					
资源组	defaultGroup		加速卡	GPU:1	CPU	4
副本数	1		shm_size	4GB	启动命令	touch /home/test
数据	-					
挂载的模型	-					

其他功能，包括可视化、保存镜像、一键提交、训练任务。

功能	描述
可视化	打开一个可视化环境，目前支持 TensorBoard、Visdom、Netscope
保存镜像	将当前开发环境中所有信息保存为一个新的镜像，类似 docker commit 方式
一键提交	按照当前开发环境的配置，一键提交一个训练任务
训练任务	当前用户未完结训练任务的简易列表

开发环境操作功能

用户在列表中的操作栏中，可以对开发环境进行操作，目前支持以下操作：

功能	描述
克隆	克隆一个相同配置的开发环境
启动	将停止的开发环境启动
停止、恢复	用户可以将一个运行中的开发环境停止 (停止后底层数据会删除)，单击恢复后可以重新运行该开发环境
删除	可以删除开发环境
挂载数据集	可以挂载数据集
资源调整	可以对运行中的开发环境进行动态资源调整，修改资源配置
导出	可以导出当前开发环境的配置信息，按照一个副本一行的格式，每行的数据包括 pod name、node ip、pod ip，保存到用户家目录中

模型训练

“模型开发 > 模型训练”，在业务范围是训练 + 推理、训练下可用

创建训练任务

本手册以 tensorflow 单机任务为例子进行说明。功能说明：用户通过平台提供的训练任务功能，能够自动创建一个新的训练任务，创建成功后自动在任务管理列表展示该任务。

操作步骤：

A：进入“模型开发 > 模型训练”，单击页面“创建”按钮，弹出填写任务信息页面，如下图：

创建训练任务

< 任务管理

☆ 归档

☆ 归档

任务名称 *

20231108154251

镜像 *

外部镜像

请选择

请选择

部署类型 *

单机

Worker个数 *

-

1

+

运行 *

脚本模式

命令模式

脚本 *

执行目录 *

资源组 *

请选择

B：填写任务详细信息：

- 名称：任务名字（只接受英文字母、数字和下划线，不能以下划线开头）。
- 镜像：在第一个窗口选择 tensorflow 框架名称，在第二个窗口选择框架版本。
- 外部镜像：勾选该选项后，用户可以自定义输入镜像名称。
- 部署类型：训练任务部署类型，选择“单机”。
- 资源组：选择资源组。
- 网络类型：选择相应网络类型。
- 加速卡系列：根据下拉列表配置可选择相应的加速卡系列；只能使用一种类型提交任务；右侧的可用节点信息会根据所选加速卡系列，进行动态筛选变化。
- 加速卡类型：选择资源组内相应的加速卡类型。
- CPU/加速卡：选择 Worker 节点的 CPU/加速卡资源配置方案，当配额方案是“自定义”时，会弹出加速卡和 CPU 窗口，可以自定义设置资源配置方案。
- 脚本：单击窗口后的按钮，弹出“选择启动文件”窗口，选择 tensorflow 单机训练脚本。
- 脚本示例路径：/xlz/models/tensorflow/mnist/tf_mnist_single.py
- 说明：xlz 这个表示用户的家目录，最终以实际的用户名为准；选定后单击确定。

“选择启动文件”中有两个子选项，分别为“历史访问”、“个人数据”。“历史访问”表示以前使用过的启动脚本，展示在此处以使用户选择。“个人数据”表示自己文件中的数据文件。

选择启动文件


[历史访问](#)

个人数据

- ☐ `/z/sleep.py` [🔗](#)
☐ `/x/sleep2.py` [🔗](#)
☐ `/s/sleep1.py` [🔗](#)
- ☐ `/z/models/caffe/cifar10/cifar10_full_sigmoid_solver.prototxt` [🔗](#)
☐ `/models/caffe/cifar10/test.prototxt` [🔗](#)
- ☐ `/x/models/tensorflow/mnist/tf_mnist_single.py` [🔗](#)
☐ `/models/test.prototxt` [🔗](#)
- ☐ `/x/models/tensorflow/tf_resnet50_imagenet_tfrecord_single_multi.py` [🔗](#)
- ☐ `/algorithmIXuCFJ 83/models/caffe/mnist/solver lenet.prototxt` [🔗](#)
☐ `/models/paddle/paddle mnist multi.py` [🔗](#)

取消

确定



命令：用户单击“命令模式”会切换到命令模式，可以自定义自己的启动命令。

执行目录：选择执行训练脚本的目录，执行目录可以选择自己目录下的任何文件夹。

脚本参数：在“脚本参数”输入框可以输入 python 脚本所跟随的参数，例如 “ data_dir /MNIST_data data_dir2 /MNIST_data2”

弹性任务配置:

部署类型 *

单机

MPI

Master/Worker

?

最大Worker个数 *

- 2 +

弹性任务 *



最小Worker个数 *

- 2 +

1. MPI弹性任务,增加命令参数: --host-discovery-script /etc/mpi/discover_hosts.sh

2. Pytorch弹性任务,命令参数示例: torchrun --nnodes=2:4 --nproc_per_node=1 --max_restarts=100 --rdzv_id=1 --rdzv_backend=c10d --rdzv_endpoint=\$MASTER_ADDR:\$MASTER_PORT python train.py

目前训练框架支持 Horovod+Tensorflow, Horovod+Pytorch, Pytorch DDP 方式的弹性任务。

用户单击“弹性任务”开启,设置“最大 Worker 个数”大于“最小 Worker 个数”,完成弹性任务配置。

1. MPI 弹性任务、DeepSpeed 弹性任务, 增加命令参数: host-discovery-script /etc/mpi/discover_hosts.sh, 命令参数示例

```
horovodrun --verbose -np 2 --min-np 2 --max-np 4 --blacklist-cooldown-range
120 300 --host-discovery-script /etc/mpi/discover_hosts.sh python train.py
```

2. Pytorch 弹性任务、Megatron 弹性任务, 命令参数示例

```
torchrun --nnodes=2:4 --nproc_per_node=1 --max_restarts=100 --rdzv_id=1 --
rdzv_backend=c10d --rdzv_endpoint=$MASTER_ADDR:$MASTER_PORT python train.
py
```

数据配置

数据

文件管理

数据集管理

+ 选择数据

选择模型

+ 选择模型

环境变量

+ 添加环境变量 批量添加 ?

大模型分布式任务:

在镜像框架选择为 llm 时, 平台提供 DeepSpeed、Megatron 两个大模型框架。

在 DeepSpeed 框架下，平台自动生成 hostfile 文件，训练脚本可指定参数 hostfile=/opt/kube/hostfile 启动训练。

在 Megatron 框架下，平台会启动一个 master 和页面参数指定个数的 worker，在容器内自动设置 MASTER_ADDR、MASTER_PORT、RANK 等环境变量。训练程序可以直接使用环境变量启动训练。

任务名称 *

20240514190623

镜像 *

外部镜像

llm

700/llm/pytorch-admin:21.10-py3

部署类型 *

单机

DeepSpeed

Megatron ?

Worker个数 *

-

1

+

运行 *

脚本模式

命令模式

脚本 *

执行目录 *

资源组 *

defaultGroup

集群网络类型 *

请选择

数据配置：单击“数据配置 > 数据”，提供 2 种数据配置方式：

数据配置

数据

文件管理

数据集管理

+ 选择数据

选择模型

+ 选择模型

环境变量

+ 添加环境变量

批量添加 ?

数据-文件管理

在弹出的路径选择窗口中选择要使用的数据集，支持选择多个数据集。

版权所有 © 浪潮电子信息产业股份有限公司

24

数据-数据集管理

在数据集列表中选择可用数据集，只能选择一个数据集。

更新数据集说明：勾选后，平台自动会对缓存的数据集进行识别，如果部分数据集文件发生变化，平台会实现增量更新，如果缓存中没有数据集，会全量下载数据集。如果缓存中的数据集正在使用，则不能进行更新操作。

数据集使用方式说明：有“节点缓存”和“直接使用”两种方式。“节点缓存”表示将数据集缓存到节点，“直接使用”表示使用共享存储中的数据集。

注意：数据集也可以来自于用户目录、公共目录（全局共享和组共享），数据集可以选择多个。数据集示例路径：/MNIST_data

解压数据集说明：只有节点缓存方式支持解压操作，解压支持递归解压，解压类型支持：tar、tar.gz、zip、gz、tar.bz2，解压目录和压缩包目录同级且同名，解压支持单个数据集操作。

选择模型：用户可选择需要挂载的模型。

环境变量：用户可添加自定义环境变量。

更多配置：

功能	描述
调度策略	配置调度策略，目前支持 spread(默认)、bestfit。
端口	提供服务端口访问能力，容器内服务端口会自动映射到宿主机的端口上，且支持多个端口设置，多端口之间用英文状态下的分号隔开，第一个端口具有容错能力，其他端口只提供服务功能。设置完成后，可以在实例列表中查看到对应的端口信息。
内存	配置训练任务 Worker 节点所需要的内存，当设置为 0 时表示无限制（需要小于 Worker 所在主机目前剩余内存量）。
日志路径	训练日志输出路径，单击窗口后的按钮，选择相应路径后单击“确定”。
目录挂载	可供挂载的公共目录。
Shm	容器 shm_size 参数，默认为 4GB。
模型输出	开启开关后，配置输出模型的名称、路径，任务成功运行后，会自动按照配置输出一个模型，可以在模型管理中维护该模型。

在右侧区域显示资源组下的节点信息，这里可以自定义运行的节点，比如需要在 ainode53 上运行该任务，可以直接勾选，这样平台会默认调度到该节点上。节点列表中还可以看到每个节点上资源的情况。如果不选择节点，则平台会自动选择剩余资源满足的节点运行该任务。

C：信息填写完之后，单击“确定”按钮创建任务，任务展示在任务管理列表中。

停止训练任务

功能说明：用户通过平台提供的停止训练任务功能，能够停止一个正在运行的训练任务。工作流相关类型的任务不支持该操作。

操作步骤：

A：进入“**模型开发 > 模型训练**”，选中一个正在运行的训练任务，单击“停止”按钮。

B：页面显示停止成功表示该操作成功。

启动训练任务

功能说明：用户通过平台提供的启动训练任务功能，能够启动一个停止的训练任务。工作流相关类型的任务不支持该操作。

操作步骤：

A：进入“**模型开发 > 模型训练**”，选中一个停止的训练任务，单击“启动”按钮。

B：任务重新启动说明操作成功。

重新提交训练任务

功能说明：用户通过平台提供的重新提交训练任务功能，能够重新提交一个训练任务。工作流相关类型的任务不支持该操作。

操作步骤：

A：进入“**模型开发 > 模型训练**”，选中一个训练任务，单击“重新提交”按钮。

通过历史记录提交训练任务

功能说明：用户通过平台提供的通过历史记录提交训练任务功能。

操作步骤：

A：进入“**模型开发 > 模型训练**”，单击“创建”按钮，进入任务信息填写窗口，如下图：

历史任务

任务名称

20230525091925

框架

other

资源配置

worker*1:
vMLU370-X8:1, CPU:1, MEM:0GB

镜像

 (other/heartexlabs/abel-studio:latest

启动内容

sleep 1d

提交时间

2023-05-25 09:20:09

☆ 归档

任务名称 *

20230525093531

镜像 *

外部镜像

请选择

请选择

部署类型 *

单机

?

Worker个数 *

-

1

+

运行 *

脚本模式

命令模式

脚本 *

执行目录 *

B：可以将历史任务进行归档与取消归档，归档之后展示优先级提前。

C：选中相应的历史任务后，单击后将自动填充历史任务信息：框架类型、镜像、加速卡、CPU、内存、启动文件、数据集等信息。

删除训练任务

功能说明：用户通过平台提供的删除训练任务功能，能够删除一个训练任务。工作流相关类型的任务不支持该操作。

版权所有 © 浪潮电子信息产业股份有限公司

27

操作步骤：

A：进入“**模型开发 > 模型训练**”，选中一个训练任务，单击“删除”按钮。

B：页面显示删除成功表示该操作成功。

筛选未终结任务

功能说明：用户通过筛选功能筛选未终结的任务。

操作步骤：

A：进入“**模型开发 > 模型训练**”，单击“任务管理”列表，通过筛选功能进行筛选。

筛选终结任务

功能说明：用户通过筛选功能筛选终结的任务。

操作步骤：

A：进入“**模型开发 > 模型训练**”，单击“终结任务”列表，通过筛选功能进行筛选。

查看训练日志

功能说明：用户通过平台提供的查看任务日志功能，能够查看具体的训练日志。

操作步骤：


A：进入“**模型开发 > 模型训练**”，单击任务名字跳转到任务详情页面，单击“任务日志”按钮可以查看训练日志。

查看容器实例

功能说明：用户通过平台提供的查看任务容器实例功能，能够查看任务的容器实例信息和监控信息。

操作步骤：

A：进入“**模型开发 > 模型训练**”，单击任务名字跳转到任务详情页面，单击“容器实例”按钮可以查看容器实例信息，如下图：



容器实例列表包括：名称、状态、加速卡、节点、IP、端口、操作列。

性能曲线可以通过单击容器实例列表选择展示对应容器实例的数据，可以通过单击“15 分钟”、“4 小时”、“24 小时”、自定义时间限制查询时间范围，如果容器所在节点使用了 IB 或 RoCE 网络可以通过“Infiniband”弹框筛选性能曲线中展示的对应该网卡。

性能曲线指标包括：

场景	性能曲线指标
基本场景	CPU 利用率、内存利用率、网络输入/输出、内存总量/已用、磁盘输入/输出
使用 GPU 场景	基本场景下新增：加速卡利用率、加速卡显存利用率、加速卡显存已用、加速卡显存未用、draw_active、fp64_active、fp32_active、fp16_active、gr_engine_active、sm_active、sm_occupancy、tensor_active、pcie_rx_bytes、pcie_tx_bytes、nvlkink_rx_bytes、nvlkink_tx_bytes
使用 MIG 场景	基本场景下新增：MIG 显存利用率、MIG 显存已用、MIG 显存未用、draw_active、fp64_active、fp32_active、fp16_active、gr_engine_active、sm_active、sm_occupancy、tensor_active
使用 IB 或 RoCE 网络场景	基本场景下新增：ib_xmitdata、ib_rcvdata、ib_xmitpktsize、ib_rcvpktsize

注意：仅支持 NVIDIA DCGM Profiling Metrics 的 GPU 型号才会展示如下性能指标：gr_engine_active、sm_active、sm_occupancy、tensor_active、dram_active、fp16_active、fp32_active、fp64_active、pcie_rx_bytes、pcie_tx_bytes、nvlink_rx_bytes、nvlink_tx_bytes

查看任务基本信息

功能说明：用户通过平台提供的查看任务基本功能，能够查看任务的基本信息。

操作步骤：

A：进入“**模型开发 > 模型训练**”，单击任务名字跳转到任务详情页面，单击“基本信息”按钮可以查看任务基本信息。

任务可视化

功能说明：用户通过平台提供的可视化功能，能够查看任务的训练日志。

操作步骤：

A：进入“**模型开发 > 模型训练**”，在任务列表的操作栏，单击“可视化”按钮。

B：如果在创建任务的时候没有选择日志路径，在此处将会再次提示用户选择。

C：单击“确定”后，弹出可视化窗口。

提交紧急任务

如果用户有提交紧急任务的权限，当单击“创建”按钮，创建任务时，可以看到紧急任务的开关。

数据配置



开启紧急任务开关，单击“确定”按钮，提交一个紧急任务。

工作流管理

“模型开发 > 工作流管理”，在业务范围是训练 + 推理、训练下可用

创建工作流

用户单击“创建”，进入创建工作流页面。用户可以根据需要，自己填写工作流信息。工作流创建，主要有以下步骤：

1. 基本信息

字段	描述
名称	工作流名称，全局唯一
定时执行	是否开启定时执行，开启后，可以按照年、月、周、日或者自定义 cron 配置执行周期
立即运行	工作流创建成功是否开启立即运行，如果开启，创建成功后会立即触发工作流运行
描述	工作流的描述信息

基本信息

添加子任务

名称*

定时执行*

?

立即运行

描述

2. 子任务（支持多个子任务）

字段	描述
任务信息	包括“任务名称”字段，工作流子任务的名称。

字段	描述
资源信息	工作流子任务的资源配置，包括“资源组”、“集群网络类型”、“加速卡系列”、“加速卡类型”。
任务数据	工作流子任务的数据配置，包括“数据”信息，用户可以选择子任务需要的数据集信息。
算法信息	工作流子任务使用的算法配置，选择对应的算法后，可以修改算法带入的配置信息，包括脚本参数、环境变量、部署类型、CPU/加速卡等配置。

基本信息

task1

添加子任务

任务信息

任务名称 *

task1

资源信息

资源组 *

test

集群网络类型 *

ib

加速卡系列 *

MLU

加速卡类型

MLU370-X8

任务数据

数据

文件管理

数据集管理

路径	挂载路径	使用方式	操作
/test1108/test	/test1108/test	节点缓存 ☐ 解压	🗑

+ 选择数据

更新数据

数据集支持节点缓存和直接使用两种方式，节点缓存是把数据集下载到计算节点的本地盘目录中后再进行使用，直接使用是直接存储中读取数据使用。
只有节点缓存方式支持解压和更新操作，解压支持递归解压，解压类型支持：tar、tar.gz、zip、gz、tar.bz2，解压目录和压缩包目录同级且同名，解压支持单个数据集操作。
更新是把已缓存的数据集更新为最新的源数据集，保持和源数据一致。如果打开更新选项是针对多个数据集统一更新。

当前资源(已用/总量)

用户组可用资源

CPU

MLU

个人可用资源

CPU

MLU

节点

node1

算法信息

算法

名称

alg4

版本

1

状态

已创建

镜像

(tensorflow)w/t

tensorflow-admin:21.10-tf1-py3

执行命令

sleep 1d

描述

脚本参数

+

环境变量

+ 添加环境变量

批量添加

选择模型

+ 选择模型

部署类型

单机

MPI

PS/Worker

Worker个数

-

1

+

CPU/加速卡

64/1

128/2

自定义

CPU

-

1

+

核

加速卡

-

0

+

卡

shm_size

-

4

+

GB

内存

-

0

+

GB

日志路径

运行 workflow

	名称	状态	资源配置	拥有者	定时执行	发起时间	运行时长	运行次数	描述	操作
☐	wf1	未启动	t1 CPU:1;加速卡:0	xlz	-		0	0		编辑 运行 删除

选择列

当前选中 0 条

共 1 条

50条/页

1

前往

1

页

workflow 启动方式：

1. 立即运行：创建和编辑 workflow 时设置为立即启动运行，则完成 workflow 配置后，该 workflow 会自动立即运行。

2. 非立即运行：待创建完成 workflow 后，在 workflow 列表操作栏，手动单击“运行”按钮。

3. 定时执行：创建和编辑 workflow 时设置，或在 workflow 列表上方选择开启定时执行。

停止/启动工作流

☐	名称	状态	资源配置	拥有者	定时执行	发起时间	运行时长	运行次数	描述	操作
☐	wf1	● 执行中	t1 CPU:1;加速卡:0	xlz	-	2024-05-30 15:12:15	0	1		编辑 停止 删除

选择列

当前选中 0 条

共 1 条

50条/页

< 1 >

前往 1 页

用户可以将运行未完结的工作流停止，停止后，工作流任务以及子任务都会停止，同时也不会再执行周期调度。

用户可以启动停止的工作流。

编辑工作流

编辑工作流

< 工作流管理

➕ 基本信息

✔ t1

添加子任务

名称 *

wf1

定时执行

②

立即运行

描述

对符合状态条件的工作流进行编辑，有些信息无法修改，如工作流名称等。

删除工作流

☐	名称	状态	资源配置	拥有者	定时执行	发起时间	运行时长	运行次数	描述	操作
☐	wf1	● 未启动	t1 CPU:1;加速卡:0	xlz	-		0	0		编辑 运行 删除

选择列

当前选中 0 条

共 1 条

50条/页

< 1 >

前往 1 页

对符合状态条件的工作流进行删除。

工作流信息查看

用户可以选择列表中的工作流，单击工作流名称，进入工作流详情页面，查看工作流基本信息、子任务，以及工作流任务。

工作流信息

基本信息

名称wf1

定时执行否

立即运行否

描述-

子任务1

任务信息

任务名称t1

任务数据

数据-

更新数据

算法信息

算法名称testalg1

版本1

镜像tensorflow | tensorflow/tensorflow-admin:21.10-tf1-py3

大小0 Byte

描述-

创建时间2023-12-15 20:07:09

脚本参数-

环境变量-

工作流任务

执行总次数: 1失败: -成功: -执行中: 1停止: -

wf1_1

执行中

执行时间: 2023-12-15 20:10:15

t1

查看日志

名称wf1_t1_1

创建时间2023-12-15 20:10:15

状态 镜像拉取中

算法管理

“模型开发 > 算法管理”，在业务范围是训练 + 推理、训练下可用

创建算法

用户单击“**创建**”或“**创建版本**”，进入创建算法或创建版本页面。用户可以根据需要，填写相关算法信息。

创建算法页面，可以自定义算法名称和版本。创建版本页面，算法名称不能自定义。镜像可以使用平台镜像或者外部镜像。脚本模式需要在个人目录选择算法执行脚本和执行目录，且执行脚本在执行目录下，命令模式需要输入执行命令。运行参数是执行脚本或命令需要的运行参数，环境变量是算法任务运行需要的环境变量，可以选择性填写运行算法需要的 CPU 和加速卡资源数量。部署类型，根据镜像框架类型，自主选择。选择模型，可以根据需求选择模型。

支持的部署类型：

部署类型	框架
单机 (Worker: 1)	所有框架
PS/Worker (PS: 1-1000, Worker: 1-1500)	tensorflow
MPI (Worker: 2-1500)	非 paddlepaddle 框架
Master/Worker (Master: 1, Worker: 1-1500)	pytorch
Server/Worker (Server: 1-1000, Worker: 1-1500)	mxnet
collective: (Worker: 2-1500)	paddlepaddle
DeepSpeed (Worker: 2-1500)	llm
Megatron (Master: 1, Worker: 1-1500)	llm

名称*

classification

版本*

1

镜像*

mxnet

5000/mxnet/mxnet:20.09-py3-cuda11

部署类型*

单机

MPI

Server/Worker

Server个数*

-

1

+

Worker个数*

-

1

+

运行*

脚本模式

命令模式

脚本*

/wjy/classification/class.py

脚本参数

sfds

:

sfdsfds

+ 添加脚本参数

批量添加

执行目录*

/wjy/classification

环境变量

env

:

sfdsf

+ 添加环境变量

批量添加

选择模型

名称

class

版本

1

挂载路径

+ 选择模型

CPU

-

1

+

加速卡

-

1

+

描述

创建算法页面，用户可以使用已发布的算法进行快速创建，单击对应的已发布算法，创建信息会自动填充，用户可以根据需要，进行修改。脚本模式，如果用户未自己选择脚本和目录，平台会将已发布的算法目录，拷贝到用户个人目录，以创建的算法名称_版本命名。用户自己选择，则不再进行拷贝，以用户选择为准。

弹性任务配置：

部署类型 *

单机

MPI

Master/Worker

?

最大Worker个数 *

-

2

+

弹性任务 *

最小Worker个数 *

-

2

+

具体操作配置参考“[任务管理](#) > [创建训练任务](#) > [弹性任务配置](#)”内容

编辑算法

用户单击“[编辑](#)”按钮，进入编辑算法界面，除算法名称和版本外，可以根据需要修改相关信息。

名称 *

alg4

版本 *

1

镜像 *

外部镜像

tensorflow

744805002/tensorflow/tensorflow-admin:21.10-tf1-py3

部署类型 *

单机

MPI

PS/Worker

Worker个数 *

-

1

+

运行 *

脚本模式

命令模式

sleep 1d

环境变量

+

添加环境变量

批量添加

选择模型

+

选择模型

CPU

-

1

+

加速卡

-

0

+

算法列表

用户单击“**算法管理**”，显示算法信息主列表，同名算法通过主子列表展示，主列表优先显示最新的算法信息，子列表展示最新的 10 条数据，用户可查看全局、组内及个人的算法信息。主列表操作栏有修改、删除、训练、发布管理、发布、创建版本、收藏等功能。

算法管理

我的收藏

输入名称,描述搜索

拥有者

更多

搜索

创建

删除

进度管理

☐	名称	版本	状态	框架	镜像	拥有者	共享方式	大小	发布数量	创建时间	更新时间	操作
☐	test111	5	已创建	llm	llm/pytorch-admin:2.1.10-py3	xlz	个人	0 Byte	-			编辑 删除 发布
☐	test111	31	已创建	pytorch	pytorch/pytorch-admin:2.1.10-py3	xlz	个人	0 Byte	-			编辑 删除 发布
☐	test111	122	已创建	llm	llm/pytorch-admin:2.1.10-py3	xlz	个人	0 Byte	-			编辑 删除 发布
☐	test111	12	已创建	llm	llm/pytorch-admin:2.1.10-py3	xlz	个人	0 Byte	-			编辑 删除 发布

用户可以根据条件查询算法信息，查询条件包括：算法的名称或算法的描述信息、算法的拥有者，以及算法的更新时间范围。根据条件查询的算法信息，不再以主子列表进行展示，而是分页展示符合条件的查询结果。

算法管理我的收藏

test111

拥有者

更多

搜索

创建

删除

进度管理

☐	名称	版本	状态	框架	镜像	拥有者	共享方式	大小	发布数量	创建时间	更新时间	操作
☐	test111	5	已创建	llm	100.2.44.200/llm/pytorch-admin:2.1.10-py3	xlz	个人	0 Byte	-			编辑 删除 发布
☐	test111	31	已创建	pytorch	100.2.44.200/pytorch-admin:2.1.10-py3	xlz	个人	0 Byte	-			编辑 删除 发布
☐	test111	122	已创建	llm	100.2.44.200/llm/pytorch-admin:2.1.10-py3	xlz	个人	0 Byte	-			编辑 删除 发布
☐	test111	12	已创建	llm	100.2.44.200/llm/pytorch-admin:2.1.10-py3	xlz	个人	0 Byte	-			编辑 删除 发布
☐	test111	2	已发布	pytorch	100.2.44.200/pytorch-admin:2.1.10	xlz	个人	0 Byte	-			编辑 删除 发布

算法训练

用户单击“训练”按钮，跳转到创建训练任务界面，并自动填充算法相关信息。

创建训练任务

镜像*

☐ 外部镜像

mxnet

部署类型*

单机	MPI	Server/Worker
----	-----	--

Server个数*

Worker个数*

运行*

脚本模式

脚本* `/classification1_1/class.py`

脚本参数	--sfsd sfsdfds
------	----------------

执行目录* `/classification1_1`

资源组*

请选择

网络类型*

请选择

加速卡系列*

请选择

加速卡类型

请选择  

数据配置

数据

文件管理 数据集管理

+选择数据

选择模型

名称 版本 1 ☐ 挂载路

+ 选择模型

环境变量

env : sf sdf 

发布算法

用户单击发布按钮，可以发布算法，可以将算法发布到个人、组或者全局，发布到组，只有同组成员可以查看，发布到全局，所有用户都可以查看。发布成功后算法状态变为已发布。

发布

共享方式*

个人

组

全局

取消

确定

算法发布管理

用户单击发布管理按钮或算法名称，进入“发布界面 > 基本信息”界面，可以查看算法的详细信息，单击版本的下拉列表，可以查看同名不同版本的算法详细信息。

基本信息

版本

2

名称

classification1

镜像

[mxnet, ...]/mxnet/mxnet:20.09-py3-cuda11

运行参数

--sfsd sfsdfs

CPU

1

执行脚本

/classification1_1/class.py

算法目录

/classification1_1

环境变量

env: sfsdf

加速卡

-

部署类型

Server/Worker

Server个数

1

Worker个数


1

描述

-

挂载的模型

名称	版本	挂载路径
class	1	



用户在发布界面，单击发布列表，可以查看同名算法的已发布列表，列表操作包含：编辑、删除、训练、发布等。

基本信息

发布列表

删除

☐	名称	版本	状态	框架	镜像	拥有者	共享方式	大小	创建时间	更新时间	发布时间	操作
☐	classificatio...	1	已发布	mxnet	100.2.81...	wjy	全局	45 Byte	2022-11-...	2022-11-...	2022-11-...	编辑 删除 发布

选择列

当前选中 0 条

共 1 条

50条/页

<

1

>

前往

1

页

删除算法

用户可以删除符合条件的算法，未发布算法支持批量删除，已发布算法不支持批量删除。



进度管理

进度列表，维护算法相关功能操作的进度信息，其中，一些操作场景是没有进度管理的概念的，比如创建命令模式的算法，没有进度列表。进度列表，主要针对操作算法目录场景。

操作类型	场景
操作类型“创建”	已发布 > 创建算法。
操作类型“编辑”	已发布 > 创建 > 创建失败；已创建 > 发布 > 发布失败。
操作类型“发布”	已创建 > 发布；已创建 > 发布 > 发布失败 > 发布。
操作类型“删除”	已发布 > 删除。

进度管理

×

删除

☐	名称	版本	操作类型	状态	进度	失败原因	操作
☐	alg3	1	发布	成功	100%	-	删除 重试

⌂

当前选中 0 条

共 1 条

50条/页

▼

<

1

>

前往

1

页

失败重试

进度管理列表，操作类型：创建、编辑和发布失败的进度，如果状态为失败，可以进行失败重试，再次进行操作。

进度管理

×

删除

☐	名称	版本	操作类型	状态	进度	失败原因	操作
☐	alg3	1	发布	成功	100%	-	删除 重试

当前选中 0 条

共 1 条

50条/页

<1>

前往1页

算法收藏和取消收藏

用户可以收藏算法，并在“我的收藏”中，查看收藏的算法，也可以取消收藏的算法。

算法管理我的收藏

输入名称,描述搜索

拥有者

更多

搜索

创建

删除

☐	名称	版本	状态	框架	镜像	拥有者	共享方式	大小	创建时间	更新时间	描述	操作
☐	test2	1	已发布	pytorch	pytorch/pytorch-admin:2.1.10	xlz	个人	0 Byte	2024-01-30 11:26:13	2024-02-27 16:37:59		编辑 删除 训练
☐	test111	2	已发布	pytorch	pytorch/pytorch-admin:2.1.10	xlz	个人	0 Byte	2024-01-30 11:08:00	2024-01-30 11:12:04		编辑 删除 训练

选择列

当前选中 0 条

共 2 条

50条/页

<1>

前往1页

模型管理

“AI 开发 > 模型管理”，在业务范围是训练 + 推理、训练下可用

平台提供了统一的模型管理能力，集中管理在训练任务中得到的模型、用户本地开发的模型、外部平台输出的模型。模型管理提供统一的导入功能入口，可以方便把本地和外部模型导入到模型管理系统中。在模型管理中提供发起测试功能进行模型的测试，测试过程提供详细的日志信息查看，测试完成后提供统一的模型发布功能，为部署模型做准备。

模型列表

可以根据名称、共享、创建时间查询模型列表。

查询条件		说明
名称	全模糊查询	
共享	下拉框中选择共享属性的精确查询	
创建时间	选择起止时间查询	

模型列表列包括：名称、最新版本、创建人、版本数量、共享、描述、类型、来源、创建时间、操作。可以根据创建时间进行升序或降序排列。

名称

共享

请选择

创建时间

请选择开始时间 - 请选择结束时间

搜索

导入

传输列表

☐	名称	最新版本	创建人	版本数量	共享	描述	类型	来源	创建时间	操作
☐	base0510	V1	xyy0430	1	私有			手动上传	2024-05-10 09:45:47	删除 新增版本 共享
☐	basellm2	V1	xyy0430	1	私有			手动上传	2024-05-06 10:56:46	删除 新增版本 共享
☐	basecifar1	V1	xyy0430	1	私有			手动上传	2024-05-06 10:31:41	删除 新增版本 共享
☐	basellm1	V1	xyy0430	1	组			手动上传	2024-05-06 10:18:38	删除 新增版本 取消共享
☐	basemx1	V1	xyy0430	1	组			手动上传	2024-05-06 10:16:43	删除 新增版本 取消共享

选择列

当前选中 0 条

共 12 条

5条/页

<

1

2

3

>

前往

1

页

导入模型

在训练任务完成后，平台会自动把模型文件保存到用户家目录中，能够方便地导入模型管理中。

单击“模型管理 > 导入”，进入导入界面。导入模型需要填写以下信息：

名称	说明
名称	模型的名称，必填参数，只接受汉字、英文字母、数字、下划线, 不能以下划线开头
版本	模型的版本，自动生成，不必填写
类型	模型的类型，非必填参数，自定义输入
数据	记录模型使用的数据，非必填
拷贝导入	是否要将用户目录的模型拷贝至共享存储的公共模型目录，非必填，开启拷贝导入权限时显示
镜像	记录模型使用的镜像，非必填，下拉选择
脚本	记录模型使用的脚本，非必填，只可以选择以.py和.prototxt 结尾的脚本文件
模型路径	导入的模型目录，必填参数，选择用户家目录下的模型文件，只能选择单个目录且不为空目录
模型描述	模型的描述，非必填
模型指标	模型的指标，非必填，自定义输入

示例中用户选择的文件为本次训练任务中得到的模型文件。

不开启拷贝导入时，不能从用户家目录选择和其他模型重复的模型目录。

导入模型 < 模型管理

名称*

testmodel

版本*

V1

类型

图像识别

数据

/xyy2/models_mnist3

×

拷贝导入

注：关闭拷贝导入，默认引用模型路径，请勿轻易移动模型文件，否则模型或所对应的服务无法使用

镜像

外部镜像

pytorch

▼

/pytorch/mlu-pytorch:v1.2.1-torch1.9-ubuntu18.04

▼

脚本

模型路径*

/xyy2/models_mnist2

模型描述

模型指标

模型导入到模型管理后，该模型文件在文件管理中显示一个共享图标，区别其他普通的文件。

☐

models_mnist2.zip

☐

models_mnist

如果该模型文件在文件管理被删除，等待一个定时 5 分钟的周期后，该模型版本状态会变为失效。

版本列表

版本号	版本描述	状态	模型路径	模型指标	创建时间	操作
V1		已失效 模型路径下无法找到模型文件	/xyy2/models_mnist4		2024-04-30 11:24:31	删除

用户默认没有拷贝导入的权限，需要管理员通过用户管理界面，单击“用户管理 > 用户 > 配额权限信息 > 调整权限”开启模型拷贝，赋予该用户模型拷贝的权限。

☒ 模型拷贝

版权所有 © 浪潮电子信息产业股份有限公司

50

开启拷贝导入时，从用户家目录选择的模型目录将拷贝至共享存储的公共模型目录下。

导入模型

< 模型管理

名称*

testmodel

版本*

V1

类型

图像识别

数据

/MNIST_pytorch/MNIST

/MNIST_pytorch/raw

/MNIST_pytorch/processed

拷贝导入

注：开启拷贝导入后，会将模型文件拷贝至公共目录下，避免模型文件丢失或误操作，但会占用一部分公共存储空间，请合理选择

镜像

外部镜像

pytorch

/pytorch/pytorch:21.10-py3

脚本

模型路径*

/xyy2/models_mnist3

模型描述

模型指标

新增版本

可以对同一类型的模型，复用模型名称，进行新增版本。单击“模型管理 > 新增版本”，进入新增版本界面。新增版本需要填写以下信息：

名称	说明
名称	模型的名称，自动带入
版本	模型的版本，自动生成，最新版本加 1
类型	模型的类型，自动带入
数据	记录模型使用的数据，非必填

名称	说明
拷贝导入	是否要将用户目录的模型拷贝至共享存储的公共模型目录，非必填，开启拷贝导入权限时显示
镜像	记录模型使用的镜像，非必填，下拉选择
脚本	记录模型使用的脚本，非必填，只可以选择以.py和.prototxt 结尾的脚本文件
模型路径	导入的模型目录，必填参数，选择用户家目录下的模型文件，只能选择单个目录且不为空目录
模型描述	模型的描述，非必填
模型指标	模型的指标，非必填，自定义输入

新增版本

< 模型详情

名称*

mx0001

版本*

V2

类型

1111111

数据

/MNIST_caffe/mnist_test_lmdb

/MNIST_caffe/mnist_train_lmdb

拷贝导入

注：开启拷贝导入后，会将模型文件拷贝至公共目录下，避免模型文件丢失或误操作，但会占用一部分公共存储空间，请合理选择

镜像

外部镜像

tensorflow

tensorflow/tensorflow:21.10-tf1-py3

脚本

模型路径*

/xyy2/models_mnist

版本描述

模型指标

同样的，不开启拷贝导入时，不能从用户家目录选择和其他模型重复的模型目录。模型导入到模型管理后，该模型文件在文件管理中显示一个共享图标，区别其他普通的文件。如果该模型文件在文件管理被删除，等待一个定时 5 分钟的周期后，该模型版本状态会变为失效。开启拷贝导入时，从用户家目录选择的模型目录将拷贝至共享存储的公共模型目录下。

共享模型

模型的共享属性有三种：私有、组、全局。

单击“模型管理”，用户可以共享私有和自己组内模型。

选择要共享的模型，单击模型列表操作列“共享”按钮，只支持单个操作。

☐	名称	最新版本	创建人	版本数量	共享	描述	类型	来源	创建时间	操作
☐	mx0001	V1	xyy2	1	私有		11111111	手动上传	2024-04-30 14:57:32	删除 新增版本 共享
☐	basecopy12	-	xyy2	0	私有			-	2024-04-30 11:31:08	删除 新增版本 共享
☐	basecopy9	-	xyy2	0	私有			-	2024-04-30 11:28:31	删除 新增版本 共享
☐	basenocopy1	V1	xyy2	1	私有			手动上传	2024-04-30 11:24:31	删除 新增版本 共享
☐	basecopy3	V1	xyy2	1	私有			手动上传	2024-04-30 11:16:49	删除 新增版本 共享

共享

☒ 组 ☐ 全局

取消 确定

取消共享

取消共享操作和模型共享操作互逆。

用户单击“模型管理”，可以将自己共享到组或全局的模型取消共享。只支持单个操作。

☒	名称	最新版本	创建人	版本数量	共享	描述	类型	来源	创建时间	操作
☐	mx0001	V1	xyy2	1	组		1111111	手动上传	2024-04-30 14:57:32	删除 新增版本 取消共享
☐	basecopy12	-	xyy2	0	私有			-	2024-04-30 11:31:08	删除 新增版本 共享
☐	basecopy9	-	xyy2	0	私有			-	2024-04-30 11:28:31	删除 新增版本 共享
☒	basenocopy1	V1	xyy2	1	全局			手动上传	2024-04-30 11:24:31	删除 新增版本 取消共享
☐	basecopy3	V1	xyy2	1	组			手动上传	2024-04-30 11:16:49	删除 新增版本 取消共享

删除模型

用户单击“模型管理”，用户可以删除拥有者是自己的模型。只支持单个操作。

☒	名称	最新版本	创建人	版本数量	共享	描述	类型	来源	创建时间	操作
☐	mx0001	V1	xyy2	1	组		1111111	手动上传	2024-04-30 14:57:32	删除 新增版本 取消共享
☒	basecopy12	-	xyy2	0	私有			-	2024-04-30 11:31:08	删除 新增版本 共享
☐	basecopy9	-	xyy2	0	私有			-	2024-04-30 11:28:31	删除 新增版本 共享

只能删除没有模型版本的模型，如果模型下存在模型版本，删除时，提示：先删除模型版本才可删除模型。

 先删除模型版本才可删除模型

编辑模型基本信息

单击模型名称进入详情页，可以对类型和描述进行单一编辑。单击编辑按钮，输入要更改的模型信息，单击确定。

基本信息

最新版本

V1

创建人

xyy0430

来源

手动上传

类型

- 已

创建时间

2024-05-10 09:45:47

描述

aaaaaaaaaaaa

取消 确定

共享

私有

更新时间

2024-05-10 09:45:47

版本列表

导出模型版本

用户在“模型管理”中，单击模型名称，进入版本列表，在要导出的模型版本列表的操作列，单击导出按钮，并在弹出框中自定义 tar 包名称，导出模型 tar 包至用户家目录下。

版本列表

版本号	版本描述	状态	模型路径	模型指标	创建时间	操作
V1		未发布	/xyy2/models_mnist2/model_s_mnist2/models_mnist2/1		2024-04-30 14:57:32	删除 编辑 发起测试

共 1 条

50条/页

导出

发布

导出

名称*

取消 确定

传输列表

名称	版本	节点名称	操作类型	状态	操作
wer	2	node1	导出	完成	删除

发起模型测试

用户选择模型发起测试，创建模型测试任务。

版本号	版本描述	状态	模型路径	模型指标	创建时间	操作
V1		已导入为应用	/xyy2/models_mnist2/model_s_mnist2		2024-04-30 10:10:13	删除 编辑 生成应用
V2		未发布	/xyy2/models_mnist 已导入		2024-05-10 09:51:57	删除 编辑 发起测试

创建模型测试任务 < 模型管理

任务名称 *

20231108154838

镜像 *

外部镜像

请选择

请选择

运行 *

脚本模式

命令模式

脚本 *

执行目录 *

资源组 *

请选择

集群网络类型 *

请选择

加速卡系列 *

请选择

加速卡类型

请选择

?

发布模型版本

用户默认没有发布权限，需要管理员通过用户管理界面，单击“用户管理 > 用户 > 配额权限信息 > 调整权限”开启模型发布，赋予该用户模型发布的权限。

模型发布

赋权后，该用户需要重新登录。单击“模型管理”，选中要发布的模型，单击发布按钮。

版本号	版本描述	状态	模型路径	模型指标	创建时间	操作
V1		未发布	/xyy2/models_mnist2/model s_mnist2/models_mnist2/1		2024-04-30 14:57:32	删除 编辑 发起测试

共 1 条

50条/页

导出

发布

若页面上方提示“该操作需要等待管理员审批，审批结果可在审批管理中查看”，则需要管理员进行审批操作。若管理员审批通过，该模型正常发布；若管理员审批拒绝，则该模型不进行后续发布操作。

版权所有 © 浪潮电子信息产业股份有限公司

56

✔

该操作需要等待管理员审批，审批结果可在审批管理中查看

生成应用

发布后的模型，可以进行生成应用操作，已导入为应用和已部署的模型版本支持再次生成应用。

版本号	版本描述	状态	模型路径	模型指标	创建时间	操作
V1		已导入为应用	/xyy2/models_mnist2/model s_mnist2		2024-04-30 10:10:13	删除 编辑 生成应用
V2		已发布	/xyy2/models_mnist 已导入		2024-05-10 09:51:57	删除 编辑 生成应用

对于训推融合场景，且用户业务范围包括训练和推理，自动跳转到应用商店导入应用页面，将模型 token 自动带入到输入框中。

导入应用

❗ 请先校验token

Token *

64b5bf31ce354f509db383a41e6ffc36

校验

应用名称 *

部署方式 *

模型方式

共享存储模型

镜像方式

helm方式

对于其他场景，单击导入应用后，弹框提示 token 值。

提示

❗ 请将该token值粘贴到推理平台应用商店导入应用

941ab50439734b1b8d8d8dad3d300209 [复制](#)

取消

编辑模型版本

除已失效状态的模型版本以外，其他状态的模型版本都可以进行编辑操作。

版本编辑

< 模型详情

名称*

base0510

版本*

V1

数据

拷贝导入

注：关闭拷贝导入，默认引用模型路径，请勿轻易移动模型文件，否则模型或所对应的服务无法使用

镜像

外部镜像

请选择

请选择

脚本

模型路径*

/xyy0430/models_mnist2

版本描述

模型指标

删除模型版本

模型版本的状态包括：未发布、已发布、已失效、已导入为应用、已部署。未发布、已发布、已失效的模型版本，在二次确认后可以直接删除。

确认

×

!

确认删除V1?

取消

确定

对于状态是“已导入为应用”的模型版本，删除时，提示：模型已导入至应用商店，请先删除对应应用，才能删除模型版本。

!

模型已导入至应用商店，请先删除对应应用，才能删除模型版本

对于状态是“已部署”的模型版本，删除时，提示：模型已部署成服务，请先删除对应服务，才能删除

模型版本。

!

模型已部署成服务，请先删除对应服务，才能删除模型版本

模型传输列表

进入传输列表的操作为：开启拷贝导入的导入模型/新增版本、导出模型。同一用户同一操作操作进行排队。

对于模型较大的文件，可以展示操作进度。对于完成、失败、排队的进度，可以单击“删除”按钮逐条删除。进行中的进度无法删除。

推理服务

在业务范围是训练 + 推理、推理下可用

服务部署

通用模型/应用部署

单击“推理服务 > 通用模型/应用部署”，显示用户有权查看的所有场景下的业务的列表。在业务列表操作栏，可以对业务进行更新、复制、下线、上线、删除。

通用模型

应用部署

Helms部署

推理服务

请求成功率

场景服务分布

2 / 3

在线/总数

0%

www

www-4

每分钟请求数

请注意，服务列表仅展示推理计算任务的部署数量，更多详情请点击业务名进入查看

业务

服务状态

请选择

模型

输入关键字搜索或点击模型选择

:

用户名称

请输入用户名称

创建时间

开始时间

-

结束时间

搜索

重置

立即部署

序号	业务	状态	创建人	场景	部署配置	模型地址	框架	实例	周期	定时发布	创建时间	资源	服务地址	操作
821	sdadddd	已下线	wm4	wm4	CPU(核): 2/2(2) 内存(GB): 4/4(4) 加速卡: -/-(-)	/5a3ebfca-ea89-11ee-a2c1-c6900ed3f355/r1_ofarrmr_1	pytorch	1/1	-	详情	2024-05-06 16:11:25	0	查看	上线 删除
853	bethhh	就绪	wm	www	CPU(核): 1/2(2) 内存(GB): 1/2(2) 加速卡: -/-(-)	/5a3ebfca-ea89-11ee-a2c1-c6900ed3f355/r1_ofarrmr_1	pytorch	1/1	-	详情	2024-05-09 11:10:53	100	查看	下线 删除
857	w3rer	就绪	wm	wm4	CPU(核): 2/2(2) 内存(GB): 1/1(1) 加速卡: -/-(-)	/5a3ebfca-ea89-11ee-a2c1-c6900ed3f355/r1_ofarrmr_1	pytorch	1/1	-	详情	2024-05-09 15:24:39	100	查看	下线 删除

id

选择列

共 3 条

50条/页

1

前往

1

页


在线/总数

单击“推理服务 > 通用模型/应用部署”，查看到**在线/总数**，表示服务的就绪数和总数量的对比。



请求成功率

单击“推理服务 > 通用模型/应用部署”，查看到**请求成功率**，表示服务成功请求数在总请求数中的占比。



场景服务分布


单击“推理服务 > 通用模型/应用部署”，查看到**场景服务分布**，场景服务分布展示用户有权限查看场景下的服务数量分布。



服务列表

单击“推理服务 > 通用模型/应用部署”，查看到**每分钟请求数和服务列表**

其中，“每分钟请求数”展示相应服务近一小时内每分钟的服务请求数曲线



服务列表展示用户有权查看的所有场景下的业务，信息如下：

名称	说明
业务	服务的名称
状态	服务的状态，有就绪、未就绪、已下线、故障四种状态
创建人	服务的创建人
场景	服务所属场景
资源配置	服务的 CPU、内存、加速卡使用量
镜像	应用部署服务使用的镜像
模型	通用模型服务使用的模型
框架	通用模型服务使用的模型的框架
实例数	服务的实例数量
周期	新增、删除、查看、编辑周期任务
定时	新增、删除、查看定时上线或下线任务
创建时间	服务的创建时间
流量	服务的流量，当服务可用时流量为 100，否则为 0
服务地址	展示服务调用的 URL
操作	可对服务进行的操作，操作类型有更新、复制、下线、上线、删除

序号	业务	状态	创建人	场景	资源配置	模型地址	框架	实例数	周期	定时发布	创建时间	流量	服务地址	操作
821	jdiddddd	已下线	wm4	wm4	CPU(核): 2/20 内存(GB): 4/40 加速卡: √(-)	/5a3ebfca-ea89-11ee-a2c1-c6900ed3f355/r1_ofarrmr1_1	pytorch	1/1	-	详情	2024-05-06 16:11:25	0	查看	上线 删除
853	bethhh	就绪	wm	wmww	CPU(核): 1/20 内存(GB): 1/20 加速卡: √(-)	/5a3ebfca-ea89-11ee-a2c1-c6900ed3f355/r1_ofarrmr1_1	pytorch	1/1	-	详情	2024-05-09 11:10:53	100	查看	下线 删除
857	w3rer	就绪	wm	wm4	CPU(核): 2/20 内存(GB): 1/10 加速卡: √(-)	/5a3ebfca-ea89-11ee-a2c1-c6900ed3f355/r1_ofarrmr1_1	pytorch	1/1	-	详情	2024-05-09 15:24:39	100	查看	下线 删除
共 3 条 50条/页														1 前往 1 页

定时服务

单击“推理服务 > 通用模型/应用部署 > 服务列表 > 定时”，可以在这里新增、删除、查看定时上线或下线任务。

定时发布详情

创建

序号	业务	场景	创建时间	定时发布时间	定时动作	操作
76	txethhh	www	2024-05-11 11:32:02	2024-05-16 00:00:00	上线	删除
77	txethhh	www	2024-05-11 11:32:02	2024-05-29 00:00:00	下线	删除

选择列

周期服务

单击“推理服务 > 通用模型/应用部署 > 服务列表 > 周期”，可以在这里新增、删除、查看、编辑周期任务。

修改周期

业务: h 场景: wm4

周期	开始时间	结束时间	实例下限	实例上限	操作
周期1	周一 15:44	周四 15:44	1	1	

+ 添加周期

实例运行状态

单击“推理服务 > 通用模型/应用部署”，单击业务列表状态栏中的状态，可查看业务的实例的运行状态。当业务未就绪时，单击状态中的“未就绪”，在未就绪原因中可查看到业务出错信息。

服务运行状态

运行状态 未就绪原因

实例名称	生存时长	就绪状态	重启次数	状态
fasdfas-786c999d8d-9pwfc	4天11时39分43秒	0/2	0	等待中

选择列

共 1 条 50条/页 < 1 > 前往 1 页

服务列表检索

在业务查询栏，可用业务、服务状态、模型、用户名称、创建时间对业务进行筛选。此外可用实例数、创建时间对列表进行升序、降序的排列。

业务 业务状态 请选择 模型 输入关键字搜索或点击模型选择 用户名称 请输入用户名称 创建时间 开始时间 结束时间 搜索 立即部署

序号	业务	状态	创建人	场景	实例数	模型地址	框架	实例数	周期	定时发布	创建时间	流量	服务地址	操作
----	----	----	-----	----	-----	------	----	-----	----	------	------	----	------	----

通用模型创建

单击“推理服务 > 通用模型 > 立即部署”，进入服务创建页面，在该页面进行服务参数配置。配置完成后单击部署，即可创建服务。

场景 *

www

模型 *

/5a3ebfca-ea89-11ee-a2c1-c6900ed3f355/1_cifar100_v1_1

选择

业务 *

test

框架

pytorch

路径

/v1/models/test/predict

无服务模式

☒

CPU *

2

核

-

2

核

内存 *

4

GB

-

4

GB

☐ GPU

请选择

实例数 *

1

-

1

QPS *

2

端口

http

8080

http1

开启日志

☐

批处理

☐

数据预处理

☐

数据后处理

☐

周期部署

☐

资源占用(资源申请总数/资源可用数) ①			
CPU	2/294核	内存	4/3084GB
加速卡			

资源复用率(场景已分配/场景资源总量) ②			
CPU	74.5%	内存	76.45%
加速卡			

资源预留			
CPU ③	-核/-核		
内存 ④	-GB/-GB		
是否满足	是		
配置	基准资源	CPU比例	内存比例
			

参数配置说明如下：

参数	说明
场景	服务所属场景
业务	服务的名称
模型	服务使用的模型
框架	模型的框架
路径	底层使用的镜像的接口，默认/v1/models/\$ 业务名:predict
无服务模式	无服务模式关闭时，服务不能收缩到 0，开启时可以收缩到 0
CPU 使用率	用于无服务模式关闭时的实例伸缩，当超过 cpu 利用率时进入实例扩容阶段

参数	说明
CPU	单实例使用 CPU 的最小、最大值
内存	单实例使用内存的最小、最大值
GPU	单实例使用 GPU 的数量
实例数	服务的最小、最大副本量
qps	单实例每分钟目标流量
PVC	可在这里选择 PVC 挂载到容器中
端口	服务所启动端口，当开启多端口时可配置多个端口
开启日志	当开启日志时，可收集、导出服务、响应信息
批量处理	批量处理时，可将多个请求收集后一起送到服务中处理。最大批处理数量、最大延迟时间、超时等待时间分别表示服务最大并行处理数量，批处理收集请求时等待的最长时间、等待服务返回的最长时间
数据处理	服务的数据前后处理作为子服务启动，可以在这里设置数据处理的参数配置
周期部署	设置服务实例数量的周期变化

资源占用

单击“推理服务 > 通用模型 > 立即部署”，进入服务创建页面，在右侧资源占用中，有资源的可用量显示，填写 CPU、内存、GPU、实例上下限时等资源相关参数，会自动计算服务分配资源是否超出可用资源，若超出某项资源，在右侧资源占用中会给出标红提示。

资源占用(资源申请总数/资源可用数) ②			
CPU	2/80核心	内存	4/80GB
加速卡	Tesla-T4	1/2卡	1/30GB

资源复用率

单击“推理服务 > 通用模型 > 立即部署”，进入服务创建页面，右侧资源复用率框初始展示各项资源复用率，复用率计算方式是“场景内已存在服务占用的资源/场景内实际物理资源总量”，在填写资源时，在

资源复用率框中，会自动计算当前服务加上场景内服务占用资源的复用率。资源复用率超出 200% 时，会给出提示。在计算时，采用实例上限乘以资源上限值，作为服务的分配资源。

资源复用率(场景已分配/场景资源总量) ?			
CPU	20%	内存	40%
加速卡	Tesla-T4 100%		

资源预留

单击“推理服务 > 通用模型 > 立即部署”，进入服务创建页面，右侧资源预留框展示该场景中的资源预留配置，以及需预留的资源/场景中的剩余资源信息，其中资源预留配置，展示的是对应的基准资源 (加速卡) 对应需预留的 CPU 和内存比例，即场景中每张加速卡需预留的 CPU 和内存数；需预留的资源统计方式，这里以 CPU 为例，“某类加速卡需预留 CPU 资源 = 未使用的加速卡数 * 对应的 CPU 预留比例，若存在多种加速卡，则对各类加速卡需预留 CPU 资源进行求和，得到最终结果”。场景中的剩余资源的统计方式为：“场景中资源可用数 服务的资源”；在填写资源时，在资源预留框中，会实时计算预留比例和场景内剩余资源。当“需预留的资源”小于“场景中的剩余资源”时，对应资源预留框会标红提示，同时，是否满足标记为红色的“否”，表示不满足资源预留比例条件，此时会拦截服务创建。

资源预留			
CPU ?	1核心/17.7核心		
内存 ?	1GB/14.9388GB		
是否满足	是		
配置	基准资源	CPU比例	内存比例
	Tesla-T4	1	1

应用部署创建

单击“推理服务 > 应用部署 > 立即部署”，进入服务创建页面，在该页面进行服务参数配置。当选择 GPU 类型加速卡时，可选择使用整卡、细粒度或者 MIG 方式，整卡资源分配时实例只能以 1 卡为精度使用卡，细粒度资源分配时，实例支持以百分之 1 的精度使用加速卡，当 GPU 卡被划分为 MIG 方式时，可选择 MIG 方式使用 GPU 卡。资源占用、资源复用率、资源预留的展示内容和通用模型相同。

场景

www

业务

add

镜像

addffff - add.d-216

路径

/add

无服务模式

CPU

1

核心

-

1

核心

内存

1

GB

-

1

GB

加速卡

不使用

实例数

1

-

1

qps

1

端口

http

8080

http1

开启日志

环境变量

命令

定时发布

批量处理

数据处理

周期部署

资源占用(资源申请总数/资源可用数) ①			
CPU	1/35.4核心	内存	1/30.35GB
加速卡	Tesla-T4 0/4卡		

资源利用率(场景已分配/场景资源总量) ①			
CPU	29.5%	内存	58.58%
加速卡	Tesla-T4 0%		

资源预留			
CPU ①	-核心+核心		
内存 ②	-GB+GB		
是否满足	是		
配置	基础资源	CPU比例	内存比例
	Tesla-T4	0	0

参数配置说明如下：

参数	说明
场景	服务所属场景
业务	服务的名称
镜像	服务使用的镜像
路径	使用的镜像的接口
无服务模式	无服务模式关闭时，服务不能收缩到 0，开启时可以收缩到 0
CPU 使用率	用于无服务模式关闭时的实例伸缩，当超过 cpu 利用率时进入实例扩容阶段
CPU	单实例使用 CPU 的最小、最大值
内存	单实例使用内存的最小、最大值
加速卡	单实例使用的加速卡数量，当选择 GPU 类型加速卡时，可选择使用整卡、细粒度或者 MIG 方式
实例数	服务的最小、最大副本量
qps	单实例每分钟目标流量
PVC	可在这里选择 PVC 挂载到容器中

参数	说明
端口	服务所启动端口，当开启多端口时服务可配置多个端口
开启日志	当开启日志时，可收集、导出服务请求、响应信息
批量处理	批量处理时，可将多个请求收集后一起送到服务中处理。最大批处理数量、最大延迟时间、超时等待时间分别表示服务最大并行处理数量，批处理收集请求时等待的最长时间、等待服务返回的最长时间
数据处理	服务的数据前后处理作为子服务启动，可以在这里设置数据处理的参数配置
周期部署	设置服务实例数量的周期变化

通用模型/应用部署详情

单击“推理服务 > 通用模型/应用部署 > 业务名”，进入服务详情页面，在该页面可以查看到服务详情。

fasdf

转到线上

URL: fasdf.fasdf.svc.cluster.local

场景: fasdf

描述 [编辑](#)

1%

请求成功率

1/1

副本数

0ms

请求延迟

概述

详情

metrics

日志

YAML

shell

测试

AB测试

外部URL

请求方式	端口	URL
http	8080	fasdf.fasdf.inais.cluster:30080

内部URL

请求方式	端口	URL
http	8080	fasdf.fasdf.svc.cluster.local/v1/models/fasdf/predict

AB测试URL <http://traffic-1699428363529917.fasdf.inais.cluster:30080>

组件 -

GPU共享 否

创建人 wnm

推理服务条件

状态	类型	最后过态时间	原因	消息
True	IngressReady	2023-11-08 15:26:15		
True	PredictorConfigurationReady	2023-11-08 15:26:14		
True	PredictorReady	2023-11-08 15:26:15		
True	PredictorRouteReady	2023-11-08 15:26:15		
True	Ready	2023-11-08 15:26:15		

左侧页面展示信息如下：

名称	说明
服务名	服务的名称

版权所有 © 浪潮电子信息产业股份有限公司

67

名称	说明
URL	服务内部 url
场景	服务所属场景
描述	服务的描述，可编辑
成功率	服务请求成功数在服务请求总数中的占比
副本数	服务的副本数
请求延迟	服务请求延迟的毫秒数

右侧页面展示信息如下：

概述

单击“推理服务 > 通用模型/应用部署 > 业务名”，进入服务详情页面，单击概述，展示信息如下，

名称	说明
外部 URL	可在集群外访问的服务的 URL
内部 URL	可在集群内访问的服务的 URL
AB 测试 URL	对服务进行 AB 测试的 URL，AB 测试 URL 是固定不变的，不会随着服务的新建、转正、删除而更改
组件	服务的组成部件，有 predictor 和 transformer 两种，服务默认有 predictor 组件，有数据处理时，服务多一个 trasnformer 组件
GPU 共享	服务是否为 GPU 细粒度类型的服务
创建人	服务的创建人
推理服务条件	展示服务各个组成部分的运行情况，当服务不就绪时，可用来排查哪个组成部分出了问题

概述

详情

metrics

日志

YAML

shell

测试

AB测试

外部URL

请求方式

端口

URL

http

8080

dfdfdf-fasdf.inais.cluster:30080

内部URL

请求方式

端口

URL

http

8080

dfdfdf-predictor-default.fasdf.svc.cluster.local:8080

AB测试URL

http://traffic-1699431400101160.fasdf.inais.cluster:30080

组件

predictor

GPU共享

否

创建人

wm

推理服务条件

状态

类型

最后过渡时间

原因

消息

False

IngressReady

2023-11-13 09:34:19

Predictor ingress not created

False

PredictorReady

2023-11-13 09:34:19

MinimumReplicasUnavailable

Deployment does not have minimum availability.

False

Ready

2023-11-13 09:34:19

Predictor ingress not created


详情

单击“推理服务 > 通用模型/应用部署 > 业务名”，进入服务详情页面，单击详情，展示服务在创建时的参数配置，

概述	详情	metrics	日志	YAML	shell	测试	AB测试
默认分支							
推理服务 - 流量: 0 业务 test57 场景 tt 状态 未就绪 实例上限 1 实例下限 1 镜像   /mine/addffffff/add:d-173 CPU上限(核) 1 CPU下限(核) 1 加速卡类型 Tesla-T4 加速卡上限(卡) 1 加速卡下限(卡) 1 显存(GB) - 内存上限 1GB 内存下限 1GB 端口 端口: 8080, 请求方式: http, 端口名称: http1 创建时间 2023-11-13 09:47:29 数据处理 - 流量: 0 状态 未就绪 实例上限 1 实例下限 1 CPU上限(核) 1 CPU下限(核) 1 加速卡类型 - 加速卡上限(卡) - 加速卡下限(卡) - 内存上限 1GB 内存下限 1GB 端口 端口: 8080, 请求方式: http, 端口名称: http1 镜像   /mine/addffffff/add:d-173							

metrics

单击“推理服务 > 通用模型/应用部署 > 业务名”，进入服务详情页面，单击 **metrics**，展示服务的各种指标信息，包括 cpu 利用率、内存使用率、内存已用、内存总量、部署网络传输速度、部署网络接收速率、请求数、请求成功率、请求延迟



日志

单击“推理服务 > 通用模型/应用部署 > 业务名”，进入服务详情页面，单击**日志**，展示服务下所有 pod，pod 下所有容器的日志，在 pod 框选择 pod，在 container 框选择 pod 下的 container，单击**查看日志**，即可查看到容器日志，

概述

详情

metrics

日志

YAML

shell

测试

AB测试

dfdfff-predictor-default-5c85c5b5f4-7dfhq

kserve-container

查看日志


```
[GIN-debug] [WARNING] Creating an Engine instance with the Logger and Recovery middleware already attached.

[GIN-debug] [WARNING] Running in "debug" mode. Switch to "release" mode in production.
- using env:   export GIN_MODE=release
- using code:  gin.SetMode(gin.ReleaseMode)

[GIN-debug] POST   /add                --> main.addOne (3 handlers)
[GIN-debug] POST   /add2               --> main.addTwo (3 handlers)
[GIN-debug] [WARNING] You trusted all proxies, this is NOT safe. We recommend you to set a value.
Please check https://pkg.go.dev/github.com/gin-gonic/gin#readme-don-t-trust-all-proxies for details.
[GIN-debug] Listening and serving HTTP on :8080
```


YAML

单击“推理服务 > 通用模型/应用部署 > 业务名”，进入服务详情页面，单击 **YAML**，展示服务的 yaml 信息，



shell

单击“推理服务 > 通用模型/应用部署 > 业务名”，进入服务详情页面，单击 **shell**，可以查看到服务下所有 pod，pod 下所有容器，但这里只有提供 sh 命令的容器，可进入到容器中执行命令。在 pod 框选择 pod，在 container 框选择 pod 下的 container，单击**调试**可以进入容器执行 shell 命令，并且执行完命令后可以单击**保存 shell 文本**将命令保存。单击**上传/下载**，可以上传文件到容器中或从容器中下载文件。



测试

单击“推理服务 > 通用模型/应用部署 > 业务名”，进入服务详情页面，单击测试，可以用服务内部 URL 进行简单的连通性测试。这里支持以“curl”开头的测试请求，以及支持插入后缀为.json 格式的文件，单击发送请求后，在请求结果中返回服务的响应，在请求结果中，state 为 0 时代表服务正常返回，否则为异常。

概述

详情

metrics

日志

YAML

shell

测试

AB测试

请求代码

请求URL:

dfdfdf-predictor-default.fasdf.svc.cluster.local:8080

curl -X POST dfdfdf-predictor-default.fasdf.svc.cluster.local:8080/add -d '{"data": 1}'

插入文件

发送请求

请求结果


{
 "data": "{\\"data\\":2}",
 "state": 0
}

格式化JSON

还原格式

AB 测试

AB 测试即绑定主线服务和测试服务，然后通过手动流量控制、流量镜像、条件流量的策略将入口流量进行划分，并使用服务评估功能评估主线、测试服务的服务质量。单击“推理服务 > 通用模型/应用部署 > 业务名 > AB 测试”，进入 AB 测试页面，单击定位还原，可使拓扑图位于居中位置，



单击**创建**按钮，可以创建测试服务，这里参数含义和**通用模型/应用部署创建**相同，

AB测试

场景 *

www

业务 *

test

镜像 *

addffff - add:d-216

无服务模式

CPU *

2

核心

-

2

核心

内存 *

4

GB

-

4

GB

加速卡

不使用

实例数

1

-

1

qps *

1

端口

http

8080

http1

环境变量

命令

批量处理

数据处理

取消

部署

资源占用(资源申请总数/资源可用数) ?

CPU	2/35.4核心	内存	4/30.35GB
加速卡	Tesla-T4 0/4卡		

资源复用率(场景已分配/场景资源总量) ?

CPU	34.5%	内存	73.58%
加速卡	Tesla-T4 0%		

资源预留

CPU ?	-核心/-核心		
内存 ?	-GB/-GB		
是否满足	是		
配置	基准资源	CPU比例	内存比例
	Tesla-T4	0	0

在拓扑图中单击**流量分配方式**框，弹出 AB 测试配置页，目前支持三种流量配置方式：* 手动流量控制：采用手动方式，划分主线和测试服务之间的流量；若选择平均分配，则测试流量会平均划分到参与测试的桶中；若选择自定义分配，则需要手动设定每个桶的流量；若选择滚动调节，则主线从 100% 流量开始，每隔一个时间间隔，划分设定步长的流量到测试桶中。* 流量镜像分配：进入主线服务的流量会复制到测试桶中，返回响应结果时，只返回主线服务的。* 条件流量分配：根据设定条件，决定流量进入哪个桶中，条件支持 gjson 格式。

编辑流量分配方式

×

1

2

流量分配方式

测试分桶设置

手动流量控制

采用手动方式，划分参与A/B/n测试的服务之间的流量

流量滚动调节

时间间隔 *

60

步长 *

5

流量分配方式

平均分配

自定义分配

主线流量 *

60

测试流量 *

40

流量镜像分配

主线服务的流量复制发送到测试服务，返回结果只包含主线服务结果

条件流量分配

根据设置的条件确定流量发送到哪个服务（其中条件是gjson格式，根据条件对输入进行判断）

取消

下一步

其中，手动流量控制可以选择是否**流量滚动调节**，若选择滚动调节，则主线从 100% 流量开始，每隔一个时间间隔（时间间隔需要大于等于 60s），划分设定步长（需要大于等于 1）的流量到测试桶中，直到主线桶和测试桶到达目标流量。并且，流量分配方式可以选择**平均分配**或**自定义分配**，当选择平均分配时，主线桶的目标流量采用**主线流量**，而**测试流量**则平均分配到每个测试桶里；当选择自定义分配时，则需要为每个桶设置目标流量，

版权所有 © 浪潮电子信息产业股份有限公司

76

编辑流量分配方式

×

✓

流量分配方式

2

测试分桶设置

当前流量分配方式: 手动流量控制

☒ 加入测试

流量: *

−

40

+

端口: *

8080

▼

路径: */div>

分桶编号: 0

业务: dfdfdf

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试

流量: *

−

50

+

端口: *

8080

▼

路径: */div>

分桶编号: 1

业务: test66

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试

流量: *

−

10

+

端口: *

8080

▼

路径: */div>

分桶编号: 2

业务: test778

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1


取消

上一步

提交

并且，需要为加入测试的每个桶设置访问路径、访问端口，设置完成后，单击提交，返回拓扑图，可看

到从流量分配框已经连线到服务框，



流量镜像分配，只能选择两个服务加入测试，每个服务的流量都是 100%，

编辑流量分配方式

×

①

流量分配方式

②

测试分桶设置

当前流量分配方式: 流量镜像分配

☒ 加入测试

流量 *

−

100

+

端口: *

8080

路径 *

/add

分桶编号: 0

业务: dfdfdf

CPU(核)

1/1

内存(GB)

1/1

加速卡数

-/-

实例数

1/1

☒ 加入测试

流量 *

−

100

+

端口: *

8080

路径 *

/add

分桶编号: 1

业务: test66

CPU(核)

1/1

内存(GB)

1/1

加速卡数

-/-

实例数

1/1

☐ 加入测试

流量

−

100

+

端口:

8080

路径

/add

分桶编号: 2

业务: test778

CPU(核)

1/1

内存(GB)

1/1

加速卡数

-/-

实例数

1/1

取消

上一步

提交

条件流量分配，需要设置到达服务的条件，

编辑流量分配方式



当前流量分配方式 条件流量分配

☒ 加入测试 端口: * 8080

路径: * /add

条件: * [@this].#(userid==1)

分桶编号: 0

业务: dfdfdf

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试 端口: * 8080

路径: * /add

条件: * [@this].#(userid==2)

分桶编号: 1

业务: test66

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试 端口: * 8080

路径: * /add

条件: * [@this].#(userid==3)

分桶编号: 2

业务: test778

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

取消

上一步

提交

在流量调整中，可重新调整配置，

流量调整×

当前流量分配方式 手动流量控制

☒ 加入测试

流量 *

-

40

+

端口: *

8080

路径 *

/add

分桶编号: 0

业务: dfdfdf

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试

流量 *

-

30

+

端口: *

8080

路径 *

/add

分桶编号: 1

业务: test66

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试

流量 *

-

30

+

端口: *

8080

路径 *

/add

分桶编号: 2

业务: test778

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

在拓扑图中，单击右侧分桶框，弹出分桶操作页，在分桶操作页，可以对测试桶进行**流量回滚**，即将测试桶流量完全回滚到主线桶，测试桶流量置 0；**服务转正**是指将测试服务提升为主线服务，并且同时删除主线和测试桶上的流量策略。注意**流量回滚**和**服务转正**只有在手动流量控制中才可使用。**删除**是指删除该测试服务，在测试服务正在参与流量策略时，不能删除测试服务，可以通过**流量调整**将该测试服务勾选掉，再删除该测试服务。主线服务无法进行服务转正。主线服务的删除需要进入通用模型/应用部署首页的列表进行删除，在首页删除时，会把主线服务、所有的测试服务以及流量策略都删除。

×

分桶编号 2

业务: test778

CPU(核) 1/1

内存(GB) 1/1

加速卡数 -/-

实例数 1/1

就绪

流量回滚

服务转正

删除

服务评估

在**服务评估**中，可创建实验对主线和测试服务进行服务质量评估，单击**实验**，展示实验列表，包含名称、场景、状态、操作等信息，只有加入场景的用户才能看到该场景下的所有实验。

服务评估

×

实验

指标

创建实验

名称	场景	状态	操作
yyy	mmm	成功	删除

⌂

选择列

共 1 条

50条/页

< 1 >

前往 1 页

单击**创建实验**，需填写如下参数：

名称	说明
服务名	创建的实验名称，长度应小于等于 32 且不为空
场景	实验运行的场景
主指标	必填，且需指明方向 高/低 ，高表示该指标取值越高越好，反之则表示取值越低越好
辅指标	可以有若干个（≥0 个），需选择指标名称，指标的上下限，并填写指标的阈值
服务	默认可以选择两个服务进行评估，可以继续添加新的服务。选择对应服务，会自动代入服务所属场景，路径必填，表示该服务对外提供的 URL

创建实验

服务名 *

yyy

场景 *

mmm

指标

主指标

http/request-count

高

辅指标1

http/error-count

上限

-

100

+

+ 添加辅指标

服务

服务1

trirt

mmm

trirt.mmm.svc.cluster.local

服务2

dsds

mmm

dsds.mmm.svc.cluster.local

+ 添加服务

取消

确定

单击**确定**按钮，创建实验，之后自动返回实验列表页面。实验评估创建成功后，初始状态为**未知**，等待一段时间，状态会发生如下转变：**未知 -> 运行中 -> 成功/失败**。单击实验名称，进入**评估结果**页面，若实验状态为失败，意味着评估失败，**推荐服务**栏为空，单击两个服务的下拉按钮，可以查看服务评估详情。若辅指标中有一项**是否满足条件**为否，则排除该服务；只有当所有辅指标均满足条件，则根据主指标的实际值和方向进行比较，最终选出推荐服务。

评估结果

实验名称 yyy

场景 mmm

推荐服务 dsds

应用	实验状态	实验时间
trirt	成功	2023-11-17 09:13:56
主指标 http/request-count 主指标方向 高 主指标实际值 100		
辅指标	辅指标目标值	辅指标上下限
http/error-count	100	上限
是否满足条件	是	实际值
		100
dsds	成功	2023-11-17 09:13:56
主指标 http/request-count 主指标方向 高 主指标实际值 100		
辅指标	辅指标目标值	辅指标上下限
http/error-count	100	上限
是否满足条件	是	实际值
		100

在**指标**菜单页，用户可以看到指标列表，包含名称、类型、描述等信息。其中，类型为内置表明为内置指标。

版权所有 © 浪潮电子信息产业股份有限公司

83

服务评估

×

实验指标

名称	类型	描述
http/request-count	内置	发送的请求总数
http/error-count	内置	错误响应数
http/error-rate	内置	错误响应率
http/latency-mean	内置	平均响应时间
http/latency-stddev	内置	响应时间标准差
http/latency-min	内置	最小响应时间
http/latency-max	内置	最大响应时间
http/latency-p50	内置	50%的请求延迟情况
http/latency-p75	内置	75%的请求延迟情况
http/latency-p90	内置	90%的请求延迟情况
http/latency-p95	内置	95%的请求延迟情况
http/latency-p99	内置	99%的请求延迟情况
http/latency-p99.9	内置	99.9%的请求延迟情况

选择列

共 13 条

50条/页

<1>

前往1页

在**实验**菜单页展示的实验列表中，可以单击操作栏的**删除**按钮删除对应的实验。

注：目前 AB 测试只支持有 http、https 类型端口的服务创建测试服务，细粒度主线服务只能创建细粒度的测试服务，非细粒度主线服务只能创建非细粒度的测试服务

更新

单击“**推理服务 > 通用模型/应用部署 > 操作栏 > 更新**”，可以对服务的参数进行更新，更改参数后，单击**更新**，既可更新服务参数配置。目前，细粒度服务不支持更新。

场景 *

wm4

业务 *

w3rer34

镜像 *

multirpo - multirpo:d-276

路径

无服务模式

☐

cpu使用率 *

1

%

CPU *

1

核

-

1

核

内存 *

2

GB

-

2

GB

加速卡

不使用

PVC

+

实例数 *

1

-

1

多端口

☒

端口

https

8080

http1

https

8081

http55

+

开启日志

☐

环境变量

+

命令

+

批量处理

☐

数据处理

☐

周期部署

☐

复制

单击“推理服务 > 通用模型/应用部署 > 操作栏 > 复制”，可以拷贝现有服务参数，在更改业务名以及其他参数后，单击部署，既可创建一个新服务。

场景 *

wm4

模型 *

/5a3ebfca-ea89-11ee-a2c1-c6900ed3f355/1_cifarrrrr_1

选择

业务 *

sdddddcopy

框架

pytorch

路径

无服务模式

CPU *

2

核

-

2

核

内存 *

4

GB

-

4

GB

☐ GPU

请选择

实例数 *

1

-

1

QPS *

2

端口

http

8080

http1

开启日志

批量处理

☐

数据处理

☐

周期部署

☐

下线、上线

单击“推理服务 > 通用模型/应用部署 > 操作栏 > 下线”，可以将现有服务下线并释放资源，单击上线，可以上线当前服务并为当前服务占用资源。

删除

单击“推理服务 > 通用模型/应用部署 > 操作栏 > 删除“，可以将现有服务删除，释放资源。##### HELM 部署 ##### HELM 部署列表单击“HELM 部署”，根据业务名称、所属应用、状态进行模糊查询，查询出满足要求的应用商店中部署方式是 HELM 类型的应用的部署情况，展示的信息包括：业务名称、所属

应用、状态（失败的话，展示失败原因）、资源配置（CPU、内存、加速卡）、创建时间、创建人、以及删除操作。单击“删除”按钮，弹出对话框，单击“确定”即可。


业务名称	所属应用	状态	资源配置	创建时间	操作
zjh3-cor-f73cdf9	zjh3-cor	失败	CPU(核): 4/5 内存(GB): 6.442/8.59 加速卡(卡): 1/1	2022-07-20 17:51:26	删除
zjh3-ocr-cpu-e770349d	zjh3-ocr-cpu	启动中	CPU(核): 2/3 内存(GB): 2.147/3.221 加速卡(卡): -/-	2022-07-15 17:15:59	删除
zjh3-cor-01959106	zjh3-cor	运行中	CPU(核): 2/3 内存(GB): 2.147/3.221 加速卡(卡): -/-	2022-07-15 17:01:39	删除

名称	说明
业务名称	helm 部署的实例名称
所属应用	helm 模板所属应用
状态	下拉列表，有失败、启动中、运行中三种取值

名称	说明
业务名称	helm 部署的服务名称
所属应用	helm 模板所属应用
状态	有失败、启动中、运行中三种取值
资源配置	cpu、内存、加速卡使用情况
创建时间	helm 实例创建时间
操作	删除

HELM 部署

单击“HELM 部署 > 立即部署”或者“应用商店 > helm 应用 > 部署”，进入部署页面。选择场景、应用名称、默认业务名称（可自定义）、默认展示 values.yaml 文件的内容（可手动选择文件进行修改）；右侧展示场景的资源信息、持久卷声明列表、应用的镜像列表。可自定义修改文件中的内容（资源大小，镜像等），其中，单击持久卷声明“复制”按钮进行快速拷贝，单击镜像”复制“按钮进行快速拷贝，修改完成单击保存后进行部署。




如果需要指定服务运行节点为推理节点，在 values.yaml 的 “nodeSelector” 字段增加 “resource-type: inference” 并在相关 yaml 文件中配置 “nodeSelector” 字段。

```
nodeSelector:
  resource-type: inference
```

HELM 实例详情

单击“HELM 部署 > HELM 部署的实例”，进入实例详情界面，展示的信息包括：场景、描述（可修改）、请求成功率、副本数、请求延迟、内部 URL、外部 URL、使用的资源信息、创建时间、创建人、镜像列表；metrics 页签中展示的监控的相关指标；日志页签中展示该业务的日志，通过 POD 以及容器进行过滤；shell 页签中展示进入容器的信息，通过 POD 以及容器进行过滤；测试页签可以在页面上进行接口测试。



原生部署

原生部署模块支持 k8s 原生资源以及 CRD 资源的创建、删除。单击“原生部署”，进入原生部署模块，原生部署分为工作负载、服务、配置与存储、CRD、周期服务几个 TAB 页。目前只有 Deployment 类型支持周期部署。



原生部署创建

单击“原生部署”，从任一个 TAB 页中的服务部署进入创建原生服务页面。界面上可直接编辑 yaml，或者可选择导入 yaml 文件，将已经写好的 yaml 文件导入，并更改 namespace 为当前用户可使用的场景，如果使用镜像时，需要更改 image 为当前用户可使用的镜像地址，

导入YAML文件

保存

场景 www

复制

搜索/替换

撤回

复制

粘贴

剪切

```
1 apiVersion: apps/v1
2 kind: Deployment
3 metadata:
4   name: test
5   namespace: ww
6   labels:
7     labe: one
8 spec:
9   replicas: 3
10  selector:
11    matchLabels:
12      app: webbb
13  template:
14    metadata:
15      labels:
16        app: webbb
17    spec:
18      containers:
19        - name: ww
20          image: 127.0.0.1:5000/9/ct-v14
21      resources:
22        limits:
23          cpu: 1
24          memory: 1000M
25        requests:
26          cpu: 1
27          memory: 1000M
28      ports:
29        - containerPort: 80
30      env:
31        - name: PORT
32          value: "80"
33
```

☐ 周期部署

场景可用资源(www)

资源复用率

CPU	40核	内存	40GB
加速卡	Tesla-T4(GPU)		4卡

持久卷声明

持久卷声明名称	存储类名称	容量	访问模式	操作
wwc	external-default -sc	1GB	RWX	复制

1

前往 1 页

镜像

应用名称	镜像名称	镜像地址	镜像大小	操作
addffff	add: d-216	00/mine/addffff/ add: d-216	10.67MB	复制
zzh	aa: v2-214	00/mine/zzh/aa: v2-214	10.67MB	复制

在创建 Pod、DaemonSet、Deployment、ReplicaSet、StatefulSet 时，需要在 yaml 中提供资源限制，即 requests、limits 信息，在使用 GPU、MIG、MLU 等加速卡时，需要提供 nodeSelector 等键值对方式来标注使用的加速卡类型，以供服务调度时调度到指定加速卡类型的节点上，键值对中 key 为：

加速卡硬件类型	kubernetes 资源名	key
GPU	nvidia.com/gpu	gpuType
GPU MIG	nvidia.com/mig*	gpuType
MLU	cambricon.com/mlu	cambricon-type
BI	iluvatar.ai/gpu	iluvatar-type
AIPU	iei.com/inpu	aipu-type
GCU	enflame.com/gcu	enflame-type

值为场景可用资源里加速卡栏展示的类型，例如这里是 Tesla-T4：

场景可用资源(www)

CPU	79核	内存	79.068GB
加速卡	Tesla-T4(GPU)		1卡

当加速卡为 MIG 时，值为下划线之前的类型，

场景可用资源(ww)			
CPU	36.7核	内存	34.355GB
加速卡	1g.5gb(GPU) MLU370-S4(MLU)		0卡 1卡

此外，集群底层区分训练和推理节点的方式是节点的 resource-type 标签值不同，训练节点的 resource-type=train，推理节点的 resource-type=inference，如果使用节点内计算资源时，可以用 nodeSelector 或者 nodeAffinity 等方式选择使用推理节点。在编辑完 yaml 后，可单击右上角**保存**，文件即可保存到本地。单击**提交**，即用该 yaml 创建业务申请，后台会根据用户 yaml 文件中的 kind 对创建的任务进行分类，划分到**工作负载、服务、配置与存储、CRD** 中。

在**场景可用资源**中可以查看到当前场景剩余资源（乘以复用率后的），单击**资源复用率**，会自动计算当前服务加上场景内服务占用资源的复用率。资源复用率超出 200% 时，会给出提示，


资源复用率(场景已分配/场景资源总量) ×

CPU	195.45%	内存	180.45%
加速卡			

在**持久卷声明**中，可以查看到当前用户有权限使用的持久卷声明；在**镜像**中，可以查看到当前用户有权限使用的镜像。

原生部署详情

单击“**原生部署 > 业务名**”，进入服务详情页面，在该页面可以查看到服务详情。




左侧页面展示信息如下：

名称	说明
服务名	服务的名称
场景	服务所属场景
描述	服务的描述，可编辑
成功率	服务请求成功数在服务请求总数中的占比
副本数	服务的副本数
请求延迟	服务请求延迟的毫秒数

右侧页面展示信息如下：


详情

单击“原生部署 > 业务名”，进入服务详情页面，单击详情，查看到服务在 kubernetes 中的信息，作用相当于 kubectl describe 命令，



metrics

单击“原生部署 > 业务名”，进入服务详情页面，单击 **metrics**，展示服务的各种指标信息，包括 cpu 利用率、内存使用率、内存已用、内存总量、部署网络传输速度、部署网络接收速率、请求数、请求成功率、请求延迟



日志

单击“原生部署 > 业务名”，进入服务详情页面，单击日志，展示业务下所有 pod，pod 下所有容器的日志，在 pod 框选择 pod，在 container 框选择 pod 下的 container，单击查看日志，即可查看到容器日志，

详情

metrics

日志

YAML

shell

测试

AB测试

test555-649dc4d789-bdxcq

www

查看日志


```
[GIN-debug] [WARNING] Creating an Engine instance with the Logger and Recovery middleware already attached.

[GIN-debug] [WARNING] Running in "debug" mode. Switch to "release" mode in production.
- using env: export GIN_MODE=release
- using code: gin.SetMode(gin.ReleaseMode)

[GIN-debug] POST   /add          --> main.addOne (3 handlers)
[GIN-debug] POST   /add2         --> main.addTwo (3 handlers)
[GIN-debug] [WARNING] You trusted all proxies, this is NOT safe. We recommend you to set a value.
Please check https://pkg.go.dev/github.com/gin-gonic/gin#readme-don-t-trust-all-proxies for details.
[GIN-debug] Listening and serving HTTP on :8080
```


YAML

单击“原生部署 > 业务名”，进入服务详情页面，单击日志，查看到该业务的 yaml 信息，这个 yaml 和创建业务时的 yaml 一致，



shell

单击“原生部署 > 业务名”，进入服务详情页面，单击 **shell**，可以查看到业务下所有 pod，pod 下所有容器，但这里只有提供 sh 命令的容器，可进入到容器中执行命令。在 pod 框选择 pod，在 container 框选择 pod 下的 container，单击**调试**可以进入容器执行 shell 命令，并且执行完命令后可以单击**保存 shell 文本**将命令保存。单击**上传/下载**，可以上传文件到容器中或从容器中下载文件。



原生部署删除

单击“原生部署 > 操作栏 > 删除”，可以将现有服务删除，释放资源。

服务编排

单击“服务编排”，显示用户有权查看的所有场景的服务编排列表，服务流状态有正常、异常、未知、故障三种状态、单元数量代表服务流中服务组成的节点数量。其中正常状态为服务流可用状态，异常状态为服务流出现问题状态，故障状态为服务流需要管理员恢复的状态，未知状态为服务状态不可知状态。目前，服务单元中的服务支持使用通用模型和应用部署中的服务。

创建服务流

服务流名称	场景	状态	单元数量	服务端地址	描述	创建人	操作
fgdfg	www	未知	1	http://fgdfg.www.inais.clusterr.30080		wrn4	删除


选择列

共 1 条50条/页11前往1 页

服务编排创建

单击“服务编排 > 创建服务流”，进入创建服务流界面。填写服务流名称，在场景中选择服务流场景，填写描述，然后在添加节点中添加服务流的节点，节点的类型可以为：* 串行：服务或者子节点在节点内部是顺序执行 * 融合：对节点内所有服务或子节点的输出结果进行一个拼接 * 流量：按照节点内服务或子节点配置的流量百分比，来分配流量 * 条件：按照节点内服务或子节点配置的条件，来决定流量流向

在节点的服务列表中，可以配置服务或子节点，表示请求或响应数据由服务来进行处理，当选择子节点时，表示请求或响应数据由下一个节点进行处理后返回给当前节点。在流量类型的节点中，需要在服务列表中，给出每个服务或子节点的流量，并且所有流量加起来等于 100%。在条件类型的节点中，需要在服务列表中，给出访问每个服务或子节点的条件，条件支持 gjson 格式。



并且，需要为加入编排的每个服务设置访问路径、访问端口。

服务编排详情

单击“服务编排 > 业务名”，进入服务详情页面，在该页面可以查看到服务流详情。

fgdfg

场景: www

描述 [编辑](#)

✓

-

请求成功率

🔍

1

单元数量

🔍

-

请求延迟

概述

详情

metrics

日志

YAML

shell

测试

AB测试

外部URL http://fgdfg.www.inais.cluster:30080

内部URL http://fgdfg.www.svc.cluster.local

状态 未知

创建人 wm4

推理服务条件

状态	类型	最后过账时间	原因	消息
True	ConfigurationsReady	2023-10-31 15:48:02		
Unknown	Ready	2023-10-31 15:47:53	Unknown	invalid domain name "fgdfg.www.CLUSTER_DOMAIN": url: Invalid value: "fgdfg.www.CLUSTER_DOMAIN": a lowercase RFC 1123 subdomain must consist of lower case alphanumeric characters, '-', or '.', and must start and end with an alphanumeric character (e.g. 'example.com', regex used for validation is '[a-z0-9]([-a-z0-9]*[a-z0-9])?(\.[a-z0-9]([-a-z0-9]*[a-z0-9])?)*')

左侧页面展示信息如下：

名称	说明
服务名	服务的名称
场景	服务所属场景
描述	服务的描述，可编辑
请求成功率	服务请求成功数在服务请求总数中的占比
单元数量	服务流中服务组成的节点数量
请求延迟	服务请求延迟的毫秒数

右侧页面展示信息如下：

概述

单击“**服务编排 > 业务名**”，进入服务详情页面，单击**概述**，展示信息如下，

名称	说明
外部 URL	可在集群外访问的服务流的 URL
内部 URL	可在集群内访问的服务流的 URL
创建人	服务的创建人
状态	展示服务流状态

概述详情metrics日志YAMLshell测试AB测试

外部URLhttp://graph55.fasdf.inais.cluster:30080

内部URLhttp://graph55.fasdf.svc.cluster.local

状态未知

创建人wm

治理服务条件

状态	类型	最后过账时间	原因	消息
Unknown	ConfigurationsReady	2023-11-13 13:48:31		
Unknown	Ready	2023-11-13 13:48:31	RevisionMissing	Configuration "graph55" is waiting for a Revision to become ready.
Unknown	RoutesReady	2023-11-13 13:48:31	RevisionMissing	Configuration "graph55" is waiting for a Revision to become ready.

详情

单击“服务编排 > 业务名”，进入服务详情页面，单击详情，展示创建时的服务流拓扑图，

概述详情metrics日志YAMLshell测试AB测试

业务graph55

场景fasdf

定位还原

服务流配置

节点名称root

服务/节点2

节点类型串行

节点名称n2

服务/节点2

节点类型融合

节点名称n3

服务/节点2

节点类型流量


节点名称n4

服务/节点2

节点类型条件

metrics

单击“服务编排 > 业务名”，进入服务详情页面，单击 **metrics**，展示服务的各种指标信息，包括 cpu 利用率、内存使用率、内存已用、内存总量、部署网络传输速度、部署网络接收速率、请求数、请求成功率、请求延迟



日志

单击“服务编排 > 业务名”，进入服务详情页面，单击**日志**，展示服务流 pod，以及 pod 下所有容器的日志，在 pod 框选择 pod，在 container 框选择 pod 下的 container，单击**查看日志**，即可查看到容器日志，可以在 user-container 日志中查看到服务流的转发日志，

概述详情metrics**日志**YAMLshell测试AB测试


graph55-00001-deployment-59b8dd45b8-xzpb6tuser-container查看日志

```
[{"level": "info", "ts": 1699854752.4887273, "logger": "InferenceGraphRouter", "msg": "elapsed time", "node": "n4", "time": 0.000000516}
{"level": "info", "ts": 1699854752.489477, "logger": "InferenceGraphRouter", "msg": "elapsed time", "node": "n3", "time": 0.000787184}
{"level": "info", "ts": 1699854752.489501, "logger": "InferenceGraphRouter", "msg": "elapsed time", "node": "n2", "time": 0.000822886}
{"level": "info", "ts": 1699854752.4895499, "logger": "InferenceGraphRouter", "msg": "elapsed time", "node": "root", "time": 0.059910102}
{"level": "error", "ts": 1699854752.4895587, "logger": "InferenceGraphRouter", "msg": "failed to process request", "error": "unexpected end of JSON input", "stacktrace": "main.graphHandler\\n\\tgithub.com/kxserve/kserve"}

```


YAML

单击“服务编排 > 业务名”，进入服务详情页面，单击 **YAML**，展示服务流的 yaml 信息，




服务编排删除

单击“服务编排 > 操作栏 > 删除”，可以将现有服务流删除，释放资源。

推理任务

创建推理任务

进入“推理任务”，单击“创建任务”，进入创建推理任务页面。




名称	说明
场景	必填项
任务	必填项，任务名不能超过 32 字符，小写字母和数字，且以小写字母开头
镜像	必填项
CPU	必填项，cpu 须大于 0，最多支持 3 位小数，下限须小于等于上限
内存	必填项，内存须大于 0，最多支持 3 位小数，下限须小于等于上限
加速卡	选填项，正整数
PVC	选填项，最多选择 64 个 PVC，挂载路径为字符串，支持/开头，后接字母、数字、.，挂载路径长度限制 64
实例数	必填项，为大于 0 且不超过 12 位的整数
最长运行时间	选填项
优先级	必填项，默认为低
环境变量	选填项，总数量限制 100，字长限制 256
命令	选填项，总数量限制 100，字长限制 256


填写完成后，单击提交，即可创建推理任务，单击取消，即取消创建。提交成功后，任务不会立即执行，而是进入队列中等待执行，任务列表中将会查看到相应的任务信息，状态显示为“等待中”。

删除推理任务

进入“推理任务”，单击“任务列表”或者“已完成”列表中每条数据后面的删除，可删除单个任务。



进入“推理任务”，单击“任务列表”或者“已完成”列表中的数据的数据的复选框，选择要删除的数据，单击列表上方的的删除，可批量删除任务。



查询推理任务

进入“推理任务”，即可看到“任务列表”和“已完成”列表。“任务列表”中展示的是未完成的推理任务，“已完成”中展示的是已完成的推理任务（已完成列表中的任务将不在占用 CPU，内存等物理资源）。两列表均可按场景，任务名，状态，优先级，创建时间进行筛选。列表中展示了推理任务的基本信息，包括：

名称	说明
场景	任务所在场景
任务	任务名
状态	任务列表中是运行中和等待中，其中运行中包括运行中和运行中（Pending）两种状态，已完成列表中是成功和失败
优先级	任务优先级，包括高、中、低
创建人	任务创建人
创建时间	任务提交的时间
排队时长	任务从提交到实际被调度的时长
启动时间	实际被调度的时间点
实际运行时长	任务启动之后实际运行了多长时间
操作栏	任务列表中是删除按钮，已完成列表中是删除和重新提交按钮



推理任务详情

进入“推理任务”，查看“任务列表”和“已完成”列表，单击“任务名”，跳转到任务详情页。详情页具体展示了任务的场景，任务名称，镜像，优先级，最长运行时间，PVC，命令，环境变量，任务配置（CPU，内存，加速卡，实例数）等配置信息以及运行状态信息。

任务详情

场景mmm1

任务名test

镜像mine/customsxm/customsxm:v1-1

优先级低

最长运行时间

实际运行状态等待中

任务配置

CPU1/1(1)核

内存1/1(1)GB

加速卡-/-(-)-

实例数1

PVC

命令

环境变量

推理任务统计

进入“推理任务”，在页面上面即可看到推理任务的统计信息，包括任务总数，成功任务数，失败任务数，运行中任务数，等待任务数。

任务总数	成功任务数	失败任务数	运行中任务数	等待任务数
4	1	0	1	2

查看任务执行顺序

进入“推理任务”，单击“查看执行顺序”，可按场景和优先级查看任务的执行顺序，其中场景为必选。具体展示的信息包括任务名，创建时间，创建人，排队时长，优先级。

执行顺序×

场景mmm1

优先级请选择

搜索

任务	创建时间	创建人	排队时长	优先级
w	2024-05-22 14:29:46	sxm	4天20时57分19秒	低
test	2024-05-27 11:18:02	sxm	9分3秒	低

选择列

共 2 条

50条/页

1

前往1页

调整任务执行顺序

进入“推理任务”，单击“调整执行顺序”，可对同场景同等级的任务顺序进行调整。具体操作为：通过拖拽方式调整任务顺序，单击“确定”，操作成功之后任务将会按照调整后的顺序执行。具体展示信息包括任务名，创建时间，创建人，排队时长。

执行顺序×

场景mmm1

优先级低

搜索

	任务	创建时间	创建人	排队时长
⇅	w	2024-05-22 14:29:46	sxm	4天20时56分57秒
⇅	test	2024-05-27 11:18:02	sxm	8分41秒

取消

确定

推理任务重新提交

进入“推理任务”，查看已完成列表，可对列表中的所有任务执行重新提交操作，单击“重新提交”，任务将重新进入任务列表。

任务列表 已完成

场景请选择

任务

状态请选择

优先级请选择

创建时间

开始时间

结束时间

搜索

重置

删除

☐	任务	场景	状态	优先级	创建人	创建时间	排队时长	启动时间	实际运行时长	操作
☐	l	mmm1	成功	低	sxm	2024-05-22 14:26:44	11秒	2024-05-22 14:26:55	14秒	重新提交 删除

选择列

当前选中 0 条

共 1 条

50条/页

1

前往1页

存储卷管理

持久卷声明查询

功能说明：普通用户登录系统，单击“推理服务 > 存储卷管理”，可分页查看所有当前创建持久卷声明的概览信息（默认按照持久卷声明名称字母顺序升序排列），包括以下内容：

名称	说明
持久卷声明名称	持久卷声明的名称，字长限制为 253。
存储类名称	持久卷声明使用的存储类的名称，即所绑定的持久卷由该存储类创建。
场景	持久卷所属场景的名称，仅该场景下的服务可使用当前持久卷声明。
状态	持久卷声明状态，当存储类为持久卷声明分配持久卷并绑定后显示绑定，否则显示等待中。
持久卷名称	若状态为已绑定时显示持久卷名称，若状态为等待中时显示为空。
访问模式	访问模式有 RWO、ROX、RWX 三种选择。
挂载状态	未挂载、已挂载，对于已挂载的持久卷声明可查看挂载的服务名称。
描述	持久卷声明的描述，字长限制 256。
容量	持久卷声明的容量，单位为 GB。
创建时间	当前持久卷创建的时间。

持久卷声明持久卷

场景请选择持久卷声明名称搜索创建

持久卷声明名称	存储类名称	场景	状态	持久卷	访问模式①	挂载状态	描述	容量(GB)	创建时间	操作
pvc1	nfssc	wm	等待中	-	RWO,ROX	未挂载	This is description.	1	2024-05-27 16:39:25	删除

选择列

共 1 条50条/页11前往1页

普通用户可以在持久卷声明页面对已加入管理的持久卷声明进行检索，检索信息包括以下内容：

名称	说明
持久卷声明名称	由用户输入，非必填
场景	由用户选择，非必选

查询功能支持上述属性的组合查询。

持久卷声明创建

功能说明：普通用户登录系统，单击“推理服务 > 存储卷管理 > 创建”，可创建新的持久卷声明。

创建持久卷声明

场景*

wm

存储类*

nfssc

持久卷声明名称*

pvc2

访问模式*

ReadWriteOnce

卷容量*

1

GB

描述

0 / 256

取消

确定

持久卷声明创建操作中，普通用户需填充以下内容：

名称	说明
场景	当前持久卷声明所属场景，必填项；
存储类	持久卷生命所需的持久卷由哪个存储类创建，必填项；
持久卷声明名称	名称字长限制 253，支持小写字母、数字和-，必须以小写字母或数字开头或结尾，必填项；
持久卷声明描述	字长限制 256，选填项；
卷容量	非 0 整数，单位 GB，数值不可超过当前用户组当前场景下可使用的剩余存储容量。

持久卷声明删除

功能说明：普通用户登录系统，单击“推理服务 > 存储卷管理 > 删除”，输出持久卷声明名称可删除持久卷声明。

持久卷声明持久卷

场景请选择

持久卷声明名称

搜索

创建

持久卷声明名称	存储类名称	场景	状态	持久卷	访问模式 ①	挂载状态	描述	容量(GB)	创建时间	操作
pvc1	nfssc	wm	已绑定	pvc-785ce9a0-0f5b-40c4-b2a8-4cb2d699146f	RWO,ROX	未挂载	This is description.	1	2024-05-27 16:39:25	删除

选择列

共 1 条50条/页

1

前往1 页

状态为未挂载的持久卷声明可删除，状态为已挂载的持久卷声明不可删除。删除时需输入持久卷声明的名称进行确认，确认匹配后方执行删除操作。

持久卷查询

功能说明：普通用户登录系统，单击“推理服务 > 存储卷管理 > 持久卷”，可分页查看所有当前已加入管理的持久卷概览信息（默认按照持久卷名称字母顺序升序排列），包括以下内容：

名称	说明
持久卷名称	持久卷的名称，字长限制为 253。
存储类名称	持久卷使用的存储类的名称，即持久卷由该存储类创建。
场景	持久卷所属场景的名称，仅该场景下的服务可使用当前持久卷。
状态	持久卷状态，当存储类为持久卷声明分配持久卷并绑定后显示绑定，否则无当前持久卷记录。
容量	持久卷的容量，单位为 GB。
访问模式	访问模式有 RWO、ROX、RWX 三种选择。
回收机制	目前提供 Delete 模式。
创建时间	当前持久卷创建的时间。

普通用户可以在持久卷页面对已加入管理的持久卷进行检索，检索信息包括：

名称	说明
场景	由用户选择，非必选

持久卷声明持久卷

场景请选择搜索

持久卷名称	存储类名称	场景	状态	容量(GB)	访问模式 ①	回收机制	创建时间
pvc-785ce9a0-0f5b-40c4-b2a8-4cb2d699146f	nfscc	wm	已绑定	1	RWO,ROX	Delete	2024-05-27 16:39:25

选择列

共 1 条50条/页1前往1页

大模型开发

模型微调

“大模型开发 > 模型微调”，在业务范围是训练 + 推理下可用

创建微调任务

功能说明：用户通过平台提供的模型微调功能，能够自动创建一个新的微调任务，创建成功后自动在任务管理列表展示该任务。

操作步骤：

A：进入“大模型开发 > 模型微调”，单击页面“创建”按钮，弹出填写任务信息页面，如下图：

创建微调任务模型微调

任务类型 *SFT训练

微调方法 *

Full ②Freeze ②LoRA

任务名称 *20240531170417

模型 *+ 选择模型

模型类型 *请选择

数据 *

内置数据文件管理数据集管理

+ 选择数据

适配器路径 + 选择适配器路径 ②

输出路径 *

任务参数设置

B：填写任务详细信息：

任务类型：支持 SFT 训练（指令监督微调）。

微调方法：支持 3 种微调方式：Full、Freeze、LoRA。

任务名称：任务名字（只接受英文字母、数字和下划线，不能以下划线开头）。

模型：在弹出的模型选择窗口中选择要使用的模型，支持选择一个模型。

选择模型 ×

选择模型

Yuan2

V1

取消

确定

模型类型：在下拉列表中选择要使用的模型对应的模型类型。数据：提供 3 种数据集配置方式：

数据 *

内置数据

文件管理

数据集管理

+

选择数据

数据-内置数据

在下拉列表中选择要使用的数据集，支持选择多个数据集。

数据-文件管理

在弹出的路径选择窗口中选择要使用的数据集，支持选择多个数据集。

数据-数据集管理

在数据集列表中选择可用数据集，支持选择多个数据集。

更新数据集说明：勾选后，平台自动会对缓存的数据集进行识别，如果部分数据集文件发生变化，平台会实现增量更新，如果缓存中没有数据集，会全量下载数据集。如果缓存中的数据集正在使用，则不能进行更新操作。

数据集使用方式说明：有“节点缓存”和“直接使用”两种方式。“节点缓存”表示将数据集缓存到节点，“直接使用”表示使用共享存储中的数据集。

注意：数据集也可以来自于用户目录、公共目录（全局共享和组共享），数据集可以选择多个。

解压数据集说明：只有节点缓存方式支持解压操作，解压支持递归解压，解压类型支持：tar、tar.gz、zip、gz、tar.bz2，解压目录和压缩包目录同级且同名，解压支持单个数据集操作。

适配器路径：在弹出的路径选择窗口中选择要使用的适配器，支持选择多个适配器。

输出路径：选择微调日志输出的目录，可以选择自己目录下的任何文件夹。

任务参数：

任务参数设置

⚙️ 基础参数设置 ?

训练轮数 *

-

3

+

?

Batch Size *

-

2

+

?

学习率 *

5e-5

?

量化等级 *

none

?

提示模板 *

default

?

加速方式 *

none

?

附加参数

?

⚙️ 高级参数设置 ?

>

⚙️ LoRA 参数设置 ?

>

名称	说明
训练轮数	执行训练的总轮次数。每一轮包含所有训练样本的完整遍历。默认值：3。
Batch Size	每个 GPU 在一个训练步长中处理的样本数量。增大批次大小可能提高训练速度，但需确保内存足够。默认值：2。
学习率	用于 AdamW 优化器的初始学习率。建议范围通常在 1e-5 到 1e-3 之间。默认值：5e-5。
量化等级	启用 QLoRA 4-bit 或 8-bit 模型参数量化。默认值：none，即不使用 QLoRA。
提示模板	构建提示词时使用的模板。对于所有“基座“(Base)模型，参数可以是 default、alpaca、vicuna 等任意值。但“对话”(Instruct/Chat)模型请务必使用对应的模板。
加速方式	选择使用的加速技术，例如 FlashAttention。FlashAttention-2 支持 Ampere、Ada、Hopper GPU (如 A100、RTX 3090、RTX 4090、H100)。支持的数据类型有 fp16 和 bf16 (bf16 需要 Ampere、Ada 或 Hopper GPU)。默认值：none，即不使用加速技术。
附加参数	使用额外的参数设置。
截断长度	输入序列在分词后的最大长度。超出此长度的部分将被截断。默认值：1024。

名称	说明
最大样本数	可以处理的每个数据集的最大样本数。默认值：1000000。
计算类型	选择使用的计算类型，例如 fp16、bp16、fp32 或 pure_bf16。使用混合精度训练，可以加速训练过程并减少内存使用。默认值：fp16。
梯度累积	梯度累积的步数。用于在更新模型前累积多个批次的梯度，以模拟更大的批次大小。默认值：8。
学习率调节器	选择学习率调度器的类型，用于动态调整学习率。例如：linear、cosine。默认值：cosine。
最大梯度范数	梯度裁剪的最大范数值。用于防止梯度爆炸问题。默认值：1.0。
验证集比例	验证集所占全部样本的比例（百分比）。用于评估模型在训练期间的性能。默认值：0%。
保存间隔	保存模型检查点的间隔步数。用于在训练过程中定期保存模型状态。默认值：100。
预热步数	学习率预热的步数。在预热期间，学习率从 0 逐渐增加到预设值。默认值：0。
优化器	选择用于训练的优化器类型，例如 adamw_torch、adamw_8bit、adafactor。默认值：adamw_torch。
序列打包	将输入序列打包为等长样本。适用于动态填充或裁剪输入序列长度。默认值：关闭。
缩放归一化层	将归一化层的数值缩放至 32 位精度。适用于混合精度训练，防止数值不稳定。默认值：关闭。
可训练层数	设置模型中允许训练的层数。其余层将被冻结，保持参数不变。默认值：3。微调方式为 Freeze 时可设置。
可训练模块	设置可训练的模型模块名称。多个名称使用英文逗号分隔。默认值：all。微调方式为 Freeze 时可设置。
LoRA 秩	LoRA 矩阵的秩。控制低秩近似的参数数量。默认值：8。微调方式为 LoRA 时可设置。
LoRA 缩放系数	LoRA 缩放系数。用于控制低秩矩阵对原始权重矩阵的影响，可以调整 LoRA 适应性强度。默认值：16。微调方式为 LoRA 时可设置。
LoRA 随机丢弃	LoRA 权重随机丢弃的概率。用于正则化，防止过拟合。默认值：0.1。微调方式为 LoRA 时可设置。
LoRA 作用模块	设置应用 LoRA 的模块名称。多个名称使用英文逗号分隔。默认值：q_proj,v_proj。微调方式为 LoRA 时可设置。

资源配置：

资源配置

部署类型 *

单机

DeepSpeed

Worker个数 *

-

1

+

资源组 *

请选择

集群网络类型 *

请选择

加速卡系列 *

请选择

加速卡类型

请选择

?

紧急任务

关闭

☐

开启

部署类型：微调任务部署类型。

资源组：选择资源组。

集群网络类型：选择相应网络类型。

加速卡系列：根据下拉列表配置可选择相应的加速卡系列；只能使用一种类型提交任务；右侧的可用节点信息会根据所选加速卡系列，进行动态筛选变化。

加速卡类型：选择资源组内相应的加速卡类型。

CPU/加速卡：选择 Worker 节点的 CPU/加速卡资源配置方案，当配额方案是“自定义”时，会弹出加速卡和 CPU 窗口，可以自定义设置资源配置方案。

紧急任务：如果用户有提交紧急任务的权限，开启紧急任务开关，可以提交一个紧急任务。

大模型分布式任务：

平台提供 DeepSpeed 大模型框架。

在 DeepSpeed 框架下，平台自动生成 hostfile 文件，微调脚本可指定参数 hostfile=/opt/kube/hostfile 启动微调。支持弹性任务配置，用户单击“弹性任务”开启，设置“最大 Worker 个数”大于“最小 Worker 个数”。

部署类型 *

单机

DeepSpeed

Worker个数 *

-

2

+

弹性任务 *

☐

DeepSpeed任务：

hostfile文件平台会自动生成，可通过 --hostfile=/opt/kube/hostfile 使用

更多配置：

功能	描述
调度策略	配置调度策略，目前支持 spread（默认）、bestfit。
端口	提供服务端口访问能力，容器内服务端口会自动映射到宿主机的端口上，且支持多个端口设置，多端口之间用英文状态下的分号隔开，第一个端口具有容错能力，其他端口只提供服务功能。设置完成后，可以在实例列表中查看到对应的端口信息。
内存	配置训练任务 Worker 节点所需要的内存，当设置为 0 时表示无限制（需要小于 Worker 所在主机目前剩余内存量）。
日志路径	任务日志输出路径，单击窗口后的按钮，选择相应路径后单击“确定”。
目录挂载	可供挂载的公共目录。
Shm	容器 shm_size 参数，默认为 4GB。

在右侧区域显示资源组下的节点信息，这里可以自定义运行的节点，比如需要在 node1 上运行该任务，可以直接勾选，这样平台会默认调度到该节点上。节点列表中还可以看到每个节点上资源的情况。如果不选择节点，则平台会自动选择剩余资源满足的节点运行该任务。

C：信息填写完之后，单击“命令预览”按钮预览微调任务执行命令，单击“确定”按钮创建微调任务，任务展示在任务管理列表中。

命令预览

✕

```
python /workspace/LLaMA-Factory/src/train_bash.py \  
--stage sft \  
--do_train True \  
--model_name_or_path /workspace/LLaMA-Factory/models \  
--finetuning_type lora \  
--output_dir /workspace/LLaMA-Factory/saves \  
--dataset_dir /workspace/LLaMA-Factory/data \  
--dataset alpaca_gpt4_zh \  
--max_grad_norm 1.0 \  
--template yuan \  
--fp16 True \  
--galore_target mlp,attn \  
--gradient_accumulation_steps 8 \  
--optim adamw_torch \  
--num_train_epochs 3.0 \  
--lora_alpha 16 \  
--lr_scheduler_type cosine \  
--warmup_steps 0 \  
--save_steps 100 \  
--logging_steps 5 \  
--cutoff_len 1024 \  
--max_samples 100000 \  
--lora_rank 8 \  
--learning_rate 1e-5 \  
--lora_target q_proj,v_proj \  
--per_device_train_batch_size 2 \  
--lora_dropout 0.1 \  
--plot_loss
```

创建导出模型任务

功能说明：用户通过平台提供的导出模型功能，能够自动创建一个新的导出模型任务，创建成功后自动在任务管理列表展示该任务。

操作步骤：

A：进入“**大模型开发 > 模型微调**”，单击页面“导出模型”按钮，弹出填写任务信息页面，如下图：

创建导出任务

< 模型微调

任务类型 *

导出模型

微调方法 *

LoRA

任务名称 *

20240531170549

模型 *

+ 选择模型

适配器路径 *

+ 选择适配器路径

输出路径 *

任务参数设置

基础参数设置 ?

提示模板 *

default

?

最大分块大小 (GB) *

-

2

+

?

导出旧格式 *

?

B：填写任务详细信息：微调方法：支持 LoRA 微调方式。

任务名称：任务名字（只接受英文字母、数字和下划线，不能以下划线开头）。

模型：在弹出的模型选择窗口中选择要使用的模型，支持选择一个模型。

选择模型

选择模型

Yuan2

V1

取消

确定

适配器路径：在弹出的路径选择窗口中选择要使用的适配器，支持选择多个适配器。

输出路径：选择微调日志输出的目录，可以选择自己目录下的任何文件夹。

任务参数：

任务参数设置

⚙️ 基础参数设置 ?

提示模板 *

default

?

最大分块大小 (GB) *

-

2

+

?

导出旧格式 *

☐

?

提示模板：构建提示词时使用的模板。

最大分块大小 (GB)：单个模型文件的最大大小。

导出旧格式：不使用 safetensors 格式保存模型。

资源配置：

部署类型 *

单机

资源组 *

请选择

集群网络类型 *

请选择

加速卡系列 *

请选择

加速卡类型

请选择

?

紧急任务

关闭 ☐ 开启

部署类型：微调任务部署类型，选择“单机”。

资源组：选择资源组。

集群网络类型：选择相应网络类型。

加速卡系列：根据下拉列表配置可选择相应的加速卡系列；只能使用一种类型提交任务；右侧的可用节点信息会根据所选加速卡系列，进行动态筛选变化。

加速卡类型：选择资源组内相应的加速卡类型。

CPU/加速卡：选择 Worker 节点的 CPU/加速卡资源配置方案，当配额方案是“自定义”时，会弹出加速卡和 CPU 窗口，可以自定义设置资源配置方案。

更多配置：

功能	描述
调度策略	配置调度策略，目前支持 spread（默认）、bestfit。
端口	提供服务端口访问能力，容器内服务端口会自动映射到宿主机的端口上，且支持多个端口设置，多端口之间用英文状态下的分号隔开，第一个端口具有容错能力，其他端口只提供服务功能。设置完成后，可以在实例列表中查看到对应的端口信息。
内存	配置训练任务 Worker 节点所需要的内存，当设置为 0 时表示无限制（需要小于 Worker 所在主机目前剩余内存量）。
日志路径	任务日志输出路径，单击窗口后的按钮，选择相应路径后单击“确定”。
目录挂载	可供挂载的公共目录。
Shm	容器 shm_size 参数，默认为 4GB。
模型输出	将导出的模型保存到模型仓库中。

在右侧区域显示资源组下的节点信息，这里可以自定义运行的节点，比如需要在 node1 上运行该任务，可以直接勾选，这样平台会默认调度到该节点上。节点列表中还可以看到每个节点上资源的情况。如果不选择节点，则平台会自动选择剩余资源满足的节点运行该任务。

C：信息填写完之后，单击“命令预览”按钮预览微调任务执行命令，单击“确定”按钮创建微调任务，任务展示在任务管理列表中。

命令预览×

```
python /workspace/LLaMA-Factory/src/export_model.py \
--model_name_or_path /workspace/LLaMA-Factory/models \
--adapter_name_or_path /workspace/LLaMA-Factory/adapters/xlz/testllm/20240425173108/checkpoint-10 \
--template yuan \
--finetuning_type lora \
--export_dir /workspace/LLaMA-Factory/saves \
--export_size 2 \
--export_legacy_format False
```

停止微调任务

功能说明：用户通过平台提供的停止微调任务功能，能够停止一个正在运行的微调任务。

操作步骤：

A：进入“**大模型开发 > 模型微调**”，选中一个正在运行的微调任务，单击“停止”按钮。

B：页面显示停止成功表示该操作成功。

启动微调任务

功能说明：用户通过平台提供的启动微调任务功能，能够启动一个停止的微调任务。

操作步骤：

A：进入“**大模型开发 > 模型微调**”，选中一个停止的微调任务，单击“启动”按钮。

B：任务重新启动说明操作成功。

重新提交微调任务

功能说明：用户通过平台提供的重新提交微调任务功能，能够重新提交一个微调任务。

操作步骤：

A：进入“**大模型开发 > 模型微调**”，选中一个微调任务，单击“重新提交”按钮。

删除微调任务

功能说明：用户通过平台提供的删除微调任务功能，能够删除一个微调任务。

操作步骤：

A：进入“**大模型开发 > 模型微调**”，选中一个微调任务，单击“删除”按钮。

B：页面显示删除成功表示该操作成功。

筛选未终结任务

功能说明：用户通过筛选功能筛选未终结的任务。

操作步骤：

A：进入“**大模型开发 > 模型微调**”，单击“模型微调”列表，通过筛选功能进行筛选。

筛选终结任务

功能说明：用户通过筛选功能筛选终结的任务。

操作步骤：

A：进入“大模型开发 > 模型微调”，单击“终结任务”列表，通过筛选功能进行筛选。

查看微调日志

功能说明：用户通过平台提供的查看任务日志功能，能够查看具体的微调日志。

操作步骤：


A：进入“大模型开发 > 模型微调”，单击任务名字跳转到任务详情页面，单击“任务日志”按钮可以查看微调日志。

查看容器实例

功能说明：用户通过平台提供的查看任务容器实例功能，能够查看任务的容器实例信息和监控信息。

操作步骤：

A：进入“大模型开发 > 模型微调”，单击任务名字跳转到任务详情页面，单击“容器实例”按钮可以查看容器实例信息，如下图：



容器实例列表包括：名称、状态、加速卡、节点、IP、端口、操作列。

性能曲线可以通过单击容器实例列表选择展示对应容器实例的数据，可以通过单击“15 分钟”、“4 小时”、“24 小时”、自定义时间限制查询时间范围，如果容器所在节点使用了 IB 或 RoCE 网络可以通过“Infiniband”弹框筛选性能曲线中展示的对网网卡。

性能曲线指标包括：

场景	性能曲线指标
基本场景	CPU 利用率、内存利用率、网络输入/输出、内存总量/已用、磁盘输入/输出
使用 GPU 场景	基本场景下新增：加速卡利用率、加速卡显存利用率、加速卡显存已用、加速卡显存未用、draw_active、fp64_active、fp32_active、fp16_active、gr_engine_active、sm_active、sm_occupancy、tensor_active、pcie_rx_bytes、pcie_tx_bytes、nvlink_rx_bytes、nvlink_tx_bytes
使用 IB 或 RoCE 网络场景	基本场景下新增：ib_xmitdata、ib_rcvdata、ib_xmitpktsize、ib_rcvpktsize

注意：仅支持 *NVIDIA DCGM Profiling Metrics* 的 GPU 型号才会展示如下性能指标：gr_engine_active、sm_active、sm_occupancy、tensor_active、dram_active、fp16_active、fp32_active、fp64_active、pcie_rx_bytes、pcie_tx_bytes、nvlink_rx_bytes、nvlink_tx_bytes

查看任务基本信息

功能说明：用户通过平台提供的查看任务基本功能，能够查看任务的基本信息。

操作步骤：

A：进入“**大模型开发 > 模型微调**”，单击任务名字跳转到任务详情页面，单击“基本信息”按钮可以查看任务基本信息。

任务可视化

功能说明：用户通过平台提供的可视化功能，能够查看任务的训练日志。

操作步骤：

A：进入“**大模型开发 > 模型微调**”，在任务列表的操作栏，单击“可视化”按钮。

B：选择日志路径。

C：单击“确定”后，弹出可视化窗口。

提交紧急任务

如果用户有提交紧急任务的权限，当单击“创建”按钮，创建任务时，可以看到紧急任务的开关。

数据配置

数据

文件管理

数据集管理

+ 选择数据

选择模型

+ 选择模型

环境变量

+ 添加环境变量

批量添加 ②

紧急任务

关闭

☐

开启

开启紧急任务开关，单击“确定”按钮，提交一个紧急任务。

模型仓库

“大模型开发 > 模型仓库”，在业务范围是训练 + 推理下可用

平台提供了统一的大模型管理能力，集中管理模型微调任务、用户本地开发、外部平台下载的大模型。模型仓库提供统一的导入功能入口，可以方便把本地和外部模型导入到模型仓库系统中。在模型仓库中提供生成应用功能将模型导入至应用商店，为部署模型做准备。

模型列表

可以根据名称、共享、创建时间查询模型列表。

查询条件	说明
名称	全模糊查询
共享	下拉框中选择共享属性的精确查询
创建时间	选择起止时间查询

模型列表列包括：名称、最新版本、创建人、版本数量、共享、描述、类型、来源、创建时间、操作。可以根据创建时间进行升序或降序排列。

名称

共享

请选择

创建时间

请选择开始时间 - 请选择结束时间

搜索

导入

传输列表

☐	名称	最新版本	创建人	版本数量	共享	描述	类型	来源	创建时间	操作
☐	base0510	V1	xyy0430	1	私有			手动上传	2024-05-10 09:45:47	删除 新增版本 共享
☐	basellm2	V1	xyy0430	1	私有			手动上传	2024-05-06 10:56:46	删除 新增版本 共享
☐	basecifar1	V1	xyy0430	1	私有			手动上传	2024-05-06 10:31:41	删除 新增版本 共享
☐	basellm1	V1	xyy0430	1	组			手动上传	2024-05-06 10:18:38	删除 新增版本 取消共享
☐	basemx1	V1	xyy0430	1	组			手动上传	2024-05-06 10:16:43	删除 新增版本 取消共享

选择列

当前选中 0 条

共 12 条

5条/页

<

1

2

3

>

前往

1

页

导入模型

在训练任务完成后，平台会自动把模型文件保存到用户家目录中，能够方便地导入模型仓库中。
单击“模型仓库 > 导入”，进入导入界面。导入模型需要填写以下信息：

名称	说明
模型名称	模型的名称，必填参数，只接受汉字、英文字母、数字、下划线, 不能以下划线开头
版本号	模型的版本，自动生成，不必填写
类型	模型的类型，非必填参数，自定义输入
文本长度	允许的最大 token 长度，int 型数值，必填
模型参数	模型参数，单位为 billion，int 型数值，必填
模型类别	模型类别，下拉选择，单选，必填
模型格式	模型格式，下拉选择，单选，必填
量化方法	量化方法，可多选，必填
模型语言	支持的语言，可多选，必填
拷贝导入	是否要将用户目录的模型拷贝至共享存储的公共模型目录，非必填，开启拷贝导入权限时显示
模型路径	导入的模型目录，必填参数，选择用户家目录下的模型文件，只能选择单个目录且不为空目录
模型描述	模型的描述，非必填
模型指标	模型的指标，非必填，自定义输入

不开启拷贝导入时，不能从用户家目录选择和其他模型重复的模型目录。

导入模型

< 模型仓库

模型名称 *

llm11

版本号 *

V1

类型

aaa

文本长度 *

111

模型参数 *

111

billion

模型类别 *

chatglm3

模型格式 *

ggmlv3

量化方法 *

☒ 4-bit

☒ 8-bit

☐ q4-0

☐ q8-0

☐ None

模型语言 *

☒ 中文

☒ 英文

拷贝导入 *

☐

注：关闭拷贝导入，默认引用模型路径，请勿轻易移动模型文件，否则模型或所对应的服务无法使用

模型路径 *

/xyy2/models_mnist5

模型描述

模型指标

模型导入到模型仓库后，该模型文件在文件管理中显示一个共享图标，区别其他普通的文件。



如果该模型文件在文件管理被删除，等待一个定时 5 分钟的周期后，该模型版本状态会变为失效。

版本列表

版本号	版本描述	状态	模型路径	模型指标	模型类别	模型格式	模型参数	文本长度	创建时间	操作
V1		已失效 模型路径下无法找到模型文件	/xyy2/models_mnist3/models_mnist2 已导入		aichuan-2-chat	ggmlv3	1	1	2024-04-30 10:59:01	删除

开启拷贝导入时，从用户家目录选择的模型目录将拷贝至共享存储的公共模型目录下。

导入模型

模型仓库

模型名称 *

llm1

版本号 *

V1

类型

test

文本长度 *

111

模型参数 *

111

billion

模型类别 *

aichuan-2-chat

模型格式 *

pytorch

量化方法 *

☒ 4-bit

☒ 8-bit

☐ q4-0

☐ q8-0

☐ None

模型语言 *

☒ 中文

☒ 英文

拷贝导入 *

☒

注：开启拷贝导入后，会将模型文件拷贝至公共目录下，避免模型文件丢失或误操作，但会占用一部分公共存储空间，请合理选择

模型路径 *

/xyy2/models_mnist

模型描述

模型指标

新增版本

可以对同一类型的模型，复用模型名称，进行新增版本。单击“**模型仓库 > 新增版本**”，进入新增版本界面。新增版本需要填写以下信息：

名称	说明
模型名称	模型的名称，自动带入
版本号	模型的版本，自动生成，最新版本加 1
类型	模型的类型，自动带入
文本长度	允许的最大 token 长度，int 型数值，必填
模型参数	模型参数，单位为 billion，int 型数值，必填
模型类别	模型类别，下拉选择，单选，必填
模型格式	模型格式，下拉选择，单选，必填
量化方法	量化方法，可多选，必填
模型语言	支持的语言，可多选，必填
拷贝导入	是否要将用户目录的模型拷贝至共享存储的公共模型目录，非必填，开启拷贝导入权限时显示
模型路径	导入的模型目录，必填参数，选择用户家目录下的模型文件，只能选择单个目录且不为空目录
模型描述	模型的描述，非必填
模型指标	模型的指标，非必填，自定义输入

新增版本 < 模型仓库

模型名称 *	xyy55				
版本号 *	V2				
类型	1				
文本长度 *	111				
模型参数 *	111	billion			
模型类别 *	aichuan-2-chat				
模型格式 *	pytorch				
量化方法 *	☒ 4-bit	☒ 8-bit	☐ q4-0	☐ q8-0	☐ None
模型语言 *	☒ 中文	☐ 英文			
拷贝导入 *	☒				
	注：开启拷贝导入后，会将模型文件拷贝至公共目录下，避免模型文件丢失或误操作，但会占用一部分公共存储空间，请合理选择				
模型路径 *	/xyy2/models_mnist3				📁
版本描述					
模型指标					

同样的，不开启拷贝导入时，不能从用户家目录选择和其他模型重复的模型目录。模型导入到模型仓库后，该模型文件在文件管理中显示一个共享图标，区别其他普通的文件。如果该模型文件在文件管理被删除，等待一个定时 5 分钟的周期后，该模型版本状态会变为失效。开启拷贝导入时，从用户家目录选择的模型目录将拷贝至共享存储的公共模型目录下。

共享模型

模型的共享属性有三种：私有、组、全局。

单击“模型仓库”，用户可以共享私有和自己组内模型。

选择要共享的模型，单击模型列表操作列“共享”按钮，只支持单个操作。

☐	名称	最新版本	创建人	版本数量	共享	描述	类型	来源	创建时间	操作
☐	mx0001	V1	xyy2	1	私有		1111111	手动上传	2024-04-30 14:57:32	删除 新增版本 共享
☐	basecopy12	-	xyy2	0	私有			-	2024-04-30 11:31:08	删除 新增版本 共享
☐	basecopy9	-	xyy2	0	私有			-	2024-04-30 11:28:31	删除 新增版本 共享
☐	basenocopy1	V1	xyy2	1	私有			手动上传	2024-04-30 11:24:31	删除 新增版本 共享
☐	basecopy3	V1	xyy2	1	私有			手动上传	2024-04-30 11:16:49	删除 新增版本 共享

共享

☒ 组 ☐ 全局

取消

确定

取消共享

取消共享操作和模型共享操作互逆。

用户单击“模型仓库”，可以将自己共享到组或全局的模型取消共享。只支持单个操作。

☒	名称	最新版本	创建人	版本数量	共享	描述	类型	来源	创建时间	操作
☐	mx0001	V1	xyy2	1	组		1111111	手动上传	2024-04-30 14:57:32	删除 新增版本 取消共享
☐	basecopy12	-	xyy2	0	私有			-	2024-04-30 11:31:08	删除 新增版本 共享
☐	basecopy9	-	xyy2	0	私有			-	2024-04-30 11:28:31	删除 新增版本 共享
☒	basenocopy1	V1	xyy2	1	全局			手动上传	2024-04-30 11:24:31	删除 新增版本 取消共享
☐	basecopy3	V1	xyy2	1	组			手动上传	2024-04-30 11:16:49	删除 新增版本 取消共享

删除模型

用户单击“模型仓库”，用户可以删除拥有者是自己的模型。只支持单个操作。

☐	名称	最新版本	创建人	版本数量	共享	描述	类型	来源	创建时间	操作
☐	mx0001	V1	xyy2	1	组		1111111	手动上传	2024-04-30 14:57:32	删除 新增版本 取消共享
☒	basecopy12	-	xyy2	0	私有			-	2024-04-30 11:31:08	删除 新增版本 共享
☐	basecopy9	-	xyy2	0	私有			-	2024-04-30 11:28:31	删除 新增版本 共享

只能删除没有模型版本的模型，如果模型下存在模型版本，删除时，提示：先删除模型版本才可删除模型。

!

先删除模型版本才可删除模型

编辑模型基本信息

单击模型名称进入详情页，可以对类型和描述进行单一编辑。单击编辑按钮，输入要更改的模型信息，单击确定。

基本信息

最新版本

V1

创建人

xyy0430

来源

手动上传

类型

- 编辑

描述

aaaaaaaaaaaa

取消 确定

共享

私有

创建时间

2024-05-10 09:45:47

更新时间

2024-05-10 09:45:47

版本列表

导出模型版本

用户在“模型仓库”中，单击模型名称，进入版本列表，在要导出的模型版本列表的操作列，单击导出按钮，并在弹出框中自定义 tar 包名称，导出模型 tar 包至用户家目录下。

版本号	版本描述	状态	模型路径	模型指标	模型类别	模型格式	模型参数	文本长度	创建时间	操作
V1		已发布	/xyy2/models_mnist2		aichuan-2-chat	ggufv2	1	1	2024-04-24 14:20:36	删除 生成应用 导出

导出

名称*

test

取消

确定

传输列表



名称	版本	节点名称	操作类型	状态	操作
wer	2	node1	导出	完成	删除

发布模型版本

用户默认没有发布权限，需要管理员通过用户管理界面，单击“用户管理 > 用户 > 配额权限信息 > 调整权限”开启模型发布，赋予该用户模型发布的权限。



赋权后，该用户需要重新登录。单击“模型仓库”，选中要发布的模型，单击发布按钮。

版本号	版本描述	状态	模型路径	模型指标	模型类别	模型格式	模型参数	文本长度	创建时间	操作
V1		未发布	/xyy2/models_mnist3		aichuan-2-chat	ggmlv3	1	1	2024-04-24 14:31:30	删除 编辑 导出

共 1 条 50条/页 1 页

若页面上方提示“该操作需要等待管理员审批，审批结果可在审批管理中查看”，则需要管理员进行审批操作。若管理员审批通过，该模型正常发布；若管理员审批拒绝，则该模型不进行后续发布操作。



生成应用

发布后的模型，可以进行生成应用操作，已导入为应用和已部署的模型版本支持再次生成应用。

版本号	版本描述	状态	模型路径	模型指标	模型类别	模型格式	模型参数	文本长度	创建时间	操作
V1		已发布	/xyy2/models_mnist2		aichuan-2-chat	ggufv2	1	1	2024-04-24 14:20:36	删除 生成应用 导出

对于训推融合场景，且用户业务范围包括训练和推理，自动跳转到应用商店导入应用页面，将模型 token 自动带入到输入框中。

导入应用×

ⓘ 请先校验token×

Token *

64b5bf31ce354f509db383a41e6ffc36

校验

应用名称 *

部署方式 *

模型方式

共享存储模型

镜像方式

helm方式

编辑模型版本

只有未发布状态的模型版本可以进行编辑操作。

模型名称 *	xyy55	
版本号 *	V1	
文本长度 *	1	
模型参数 *	1	billion
模型类别 *	aichuan-2-chat	
模型格式 *	ggmlv3	
量化方法 *	☐ 4-bit ☒ 8-bit ☐ q4-0 ☐ q8-0 ☐ None	
模型语言 *	☐ 中文 ☒ 英文	
拷贝导入 *	注：关闭拷贝导入，默认引用模型路径，请勿轻易移动模型文件，否则模型或所对应的服务无法使用	
模型路径 *	/xyy2/models_mnist3	
版本描述		
模型指标		

删除模型版本

模型版本的状态包括：未发布、已发布、已失效、已导入为应用、已部署。未发布、已发布、已失效的模型版本，在二次确认后可以直接删除。

确认

×

! 确认删除V1?

取消

确定

对于状态是“已导入为应用”的模型版本，删除时，提示：模型已导入至应用商店，请先删除对应应用，才能删除模型版本。

! 模型已导入至应用商店，请先删除对应应用，才能删除模型版本

对于状态是“已部署”的模型版本，删除时，提示：模型已部署成服务，请先删除对应服务，才能删除模型版本。

! 模型已部署成服务，请先删除对应服务，才能删除模型版本

模型传输列表

进入传输列表的操作为：开启拷贝导入的导入模型/新增版本、导出模型。同一用户同一操作操作进行排队。

对于模型较大的文件，可以展示操作进度。对于完成、失败、排队的进度，可以单击“删除”按钮逐条删除。进行中的进度无法删除。

服务部署

“大模型开发 > 服务部署”，在业务范围是训练 + 推理下可用

单击“服务部署”，显示用户有权查看的所有场景下的业务的列表。在业务列表操作栏，可以对业务进行更新、复制、下线、上线、删除。

业务 服务状态 模型 输入关键字搜索或点击模型选择 : 用户名称 创建时间 开始时间 结束时间 检索 重置 立即部署

序号	业务	状态	创建人	场景	资源规格	模型地址	框架	实例	周期	定时发布	创建时间	流量	服务地址	共享Chat	操作
810	w3	已下线	wm4	wm4	CPU(核): 1/8(8) 内存(GB): 1/10(10) 加速卡: -/(-)	wm4isqspucbur	llm	1/1	-	详情	2024-04-30 09:08:09	0	查看	☒	上线 删除
812	w3copy	就绪	wm4	wm4	CPU(核): 1/8(8) 内存(GB): 1/10(10) 加速卡: -/(-)	wm4isqspucbur	llm	1/1	修改	-	2024-04-30 15:14:12	100	查看	☐	下线 删除
852	testingress	未就绪	wm4	wm4	CPU(核): 2/32 内存(GB): 4/48 加速卡: -/(-)	wm4isqmatremmw	llm	1/1	-	详情	2024-05-09 10:47:55	0	查看	☐	下线 删除

☐ 选择列

共 3 条 50条/页 1 前往 1 页

服务列表

单击“服务部署”，查看到服务列表

业务

服务状态

模型

输入关键字搜索或点击模型选择

:

用户名称

请输入用户名称

创建时间

开始时间

结束时间

检索

重置

立即部署

序号	业务	状态	创建人	场景	资源配置	模型地址	框架	实例数	周期	定时部署	创建时间	流量	服务地址	共享Chat	操作
810	w3	已下线	wm4	wm4	CPU(核): 1/5(9) 内存(GB): 1/10(10) 加速卡: √(-)	wm4:isq:pubur	llm	1/1	-	详情	2024-04-30 09:09:09	0	查看	☒	上线 删除
812	w3copy	就绪	wm4	wm4	CPU(核): 1/5(9) 内存(GB): 1/10(10) 加速卡: √(-)	wm4:isq:pubur	llm	1/1	修改	-	2024-04-30 15:14:12	100	查看	☐	下线 删除
852	testingress	未就绪	wm4	wm4	CPU(核): 2/3(2) 内存(GB): 4/4(4) 加速卡: √(-)	wm4:xqms:remmw	llm	1/1	-	详情	2024-05-09 10:47:55	0	查看	☐	下线 删除

选择列

共 3 条

50条/页

1

前往

1

页

服务列表展示用户有权查看的所有场景下的业务，信息如下：

名称	说明
业务	服务的名称
状态	服务的状态，有就绪、未就绪、已下线、故障四种状态
创建人	服务的创建人
场景	服务所属场景
资源配置	服务的 CPU、内存、加速卡使用量
镜像	应用部署服务使用的镜像
模型	通用模型服务使用的模型
框架	通用模型服务使用的模型的框架
实例数	服务的实例数量
周期	新增、删除、查看、编辑周期任务
定时	新增、删除、查看定时上线或下线任务
创建时间	服务的创建时间
流量	服务的流量，当服务可用时流量为 100，否则为 0
服务地址	展示服务调用的 URL
共享 chat	开启后，集群内所有用户均可使用该服务进行 chat
操作	可对服务进行的操作，操作类型有更新、复制、下线、上线、删除

定时服务

单击“服务部署 > 服务列表 > 定时”，可以在这里新增、删除、查看定时上线或下线任务。

定时发布详情

创建

序号	业务	场景	创建时间	定时发布时间	定时动作	操作
76	txethhh	www	2024-05-11 11:32:02	2024-05-16 00:00:00	上线	删除
77	txethhh	www	2024-05-11 11:32:02	2024-05-29 00:00:00	下线	删除

选择列

周期服务

单击“**服务部署 > 服务列表 > 周期**”，可以在这里新增、删除、查看、编辑周期任务。

修改周期

业务: h 场景: wm4

周期	开始时间	结束时间	实例下限	实例上限	操作
周期1	周一 15:44	周四 15:44	1	1	×

+ 添加周期

实例运行状态

单击“**服务部署**”，单击业务列表状态栏中的状态，可查看业务的实例的运行状态。当业务未就绪时，单击状态中的“未就绪”，在未就绪原因中可查看到业务出错信息。

服务运行状态

运行状态 未就绪原因

实例名称	生存时长	就绪状态	重启次数	状态
fasdfas-786c999d8d-9pwfc	4天11时39分43秒	0/2	0	等待中

选择列

共 1 条 50条/页 < 1 > 前往 1 页

服务列表检索

在业务查询栏，可用业务、服务状态、模型、用户名称、创建时间对业务进行筛选。此外可用实例数、创建时间对列表进行升序、降序的排列。

业务 服务状态 语言选择 模型 输入关键字搜索或点击模型选择 : 用户名称 请输入用户名称 创建时间 开始时间 结束时间 搜索 重置 立即部署

序号	业务	状态	创建人	场景	实例配置	模型地址	框架	实例数	周期	定时发布	创建时间	流量	服务地址	操作
----	----	----	-----	----	------	------	----	-----	----	------	------	----	------	----

服务部署创建

单击“服务部署 > 立即部署”，进入服务创建页面，在该页面进行服务参数配置。配置完成后单击部署，即可创建服务。

基本信息

场景

www

模型

wm4-dabjvtzoe

选择

业务

test

框架

lin

资源配置

无服务模式

CPU

2

核

-

2

核

内存

4

GB

-

4

GB

☐ GPU

请选择

实例数

1

-

1

QPS

1

端口

http

8080

http1

高级配置

路径

开启日志

批处理

☐

数据处理

☐

周期部署

☐

资源占用(资源申请总数/资源可用数) ①			
CPU	2/294核	内存	4/3084GB
加速卡			

资源复用率(场景已分配/场景资源总量) ①			
CPU	74.5%	内存	76.45%
加速卡			

资源预留	
CPU ①	-核/-核
内存 ①	-GB/-GB
是否满足	是
配置	基础资源 CPU比例 内存比例
	智能数据

参数配置说明如下：

参数	说明
场景	服务所属场景
业务	服务的名称
模型	服务使用的模型
框架	模型的框架
路径	底层使用的镜像的接口，默认/v1/models/\$ 业务名:predict
无服务模式	无服务模式关闭时，服务不能收缩到 0，开启时可以收缩到 0
CPU 使用率	用于无服务模式关闭时的实例伸缩，当超过 cpu 利用率时进入实例扩容阶段

参数	说明
CPU	单实例使用 CPU 的最小、最大值
内存	单实例使用内存的最小、最大值
GPU	单实例使用 GPU 的数量
实例数	服务的最小、最大副本量
qps	单实例每分钟目标流量
PVC	可在这里选择 PVC 挂载到容器中
端口	服务所启动端口，当开启多端口时可配置多个端口
开启日志	当开启日志时，可收集、导出服务、响应信息
批量处理	批量处理时，可将多个请求收集后一起送到服务中处理。最大批处理数量、最大延迟时间、超时等待时间分别表示服务最大并行处理数量，批处理收集请求时等待的最长时间、等待服务返回的最长时间
数据处理	服务的数据前后处理作为子服务启动，可以在这里设置数据处理的参数配置
周期部署	设置服务实例数量的周期变化

资源占用

单击“**服务部署 > 立即部署**”，进入服务创建页面，在右侧**资源占用**中，有资源的可用量显示，填写CPU、内存、GPU、实例上下限时等资源相关参数，会自动计算服务分配资源是否超出可用资源，若超出某项资源，在右侧资源占用中会给出标红提示。

资源占用(资源申请总数/资源可用数) ②			
CPU	2/80核心	内存	4/80GB
加速卡	Tesla-T4	1/2卡	1/30GB

资源复用率

单击“**服务部署 > 立即部署**”，进入服务创建页面，右侧**资源复用率**框初始展示各项资源复用率，复用率计算方式是“场景内已存在服务占用的资源/场景内实际物理资源总量”，在填写资源时，在资源复用率

框中，会自动计算当前服务加上场景内服务占用资源的复用率。资源复用率超出 200% 时，会给出提示。在计算时，采用实例上限乘以资源上限值，作为服务的分配资源。

资源复用率(场景已分配/场景资源总量) ?			
CPU	20%	内存	40%
加速卡	Tesla-T4		100%


资源预留

单击“服务部署 > 立即部署”，进入服务创建页面，右侧**资源预留**框展示该场景中的**资源预留配置**，以及**需预留的资源/场景中的剩余资源**信息，其中资源预留配置，展示的是对应的基准资源 (加速卡) 对应需预留的 CPU 和内存比例，即场景中每张加速卡需预留的 CPU 和内存数；需预留的资源统计方式，这里以 CPU 为例，“某类加速卡需预留 CPU 资源 = 未使用的加速卡数 * 对应的 CPU 预留比例，若存在多种加速卡，则对各类加速卡需预留 CPU 资源进行求和，得到最终结果”。场景中的剩余资源的统计方式为：“场景中资源可用数 服务的资源”；在填写资源时，在资源预留框中，会实时计算预留比例和场景内剩余资源。当“需预留的资源”小于“场景中的剩余资源”时，对应资源预留框会标红提示，同时，**是否满足**标记为红色的“否”，表示不满足资源预留比例条件，此时会拦截服务创建。

资源预留			
CPU ?	1核心/17.7核心		
内存 ?	1GB/14.9388GB		
是否满足	是		
配置	基准资源	CPU比例	内存比例
	Tesla-T4	1	1

服务部署详情

单击“服务部署 > 业务名”，进入服务详情页面，在该页面可以查看到服务详情。



上侧展示信息如下：

名称	说明
状态	服务的状态
serverless	是否开启无服务模式
GPU 共享	是否为细粒度服务
服务调用	是否开启日志

右侧展示信息如下：

名称	说明
上下线	上线、下线服务
更新服务	更新服务
获取 YAML	获取服务 YAML
删除	删除服务

概述

单击“服务部署 > 业务名”，进入服务详情页面，单击概述，展示信息如下，

名称	说明
基础信息	服务的基础配置信息
资源信息	服务的资源配置信息
服务调用地址	服务的访问地址
推理服务条件	展示服务各个组成部分的运行情况，当服务不就绪时， 可用来排查哪个组成部分出了问题

概述服务监控日志Shell连接在线调试AB测试

基础信息

场景wm4

模型地址wm4xqmairemmw

创建人wm4

更新时间-

概述编辑

周期服务查

实例数上限1, 下限1

创建时间2024-05-09 10:47:55

请求成功率

0/1

请求延迟

资源信息

CPU(核)上限2, 下限2

内存(G)上限4, 下限4

加速卡类型-

加速卡上限0, 下限0

服务调用地址

AB测试URLhttps://traffic-1715222878252995.wm4.inais.cluster:30080/https://traffic-1715222878252995.wm4.inais.cluster:30443

外部URL

请求方式	端口	URL
http	8000	testingress-wm4.inais.cluster:30000

内部URL


请求方式	端口	URL
http	8000	testingress-transformer-defaultwm4.svc.cluster.local:8000

推理服务条件

状态	类型	最后过期时间	原因	消息
False	IngressReady	2024-05-11 11:41:46	Predictor ingress not created	-
False	PredictorReady	2024-05-11 11:41:46	MinimumReplicasUnavailabl	Deployment does not have minimum availability.
False	Ready	2024-05-11 11:41:46	Predictor ingress not created	-
False	TransformerReady	2024-05-09 10:48:01	MinimumReplicasUnavailabl	Deployment does not have minimum availability.

服务监控

单击“**服务部署 > 业务名**”，进入服务详情页面，单击**服务监控**，展示服务的各种指标信息，包括 cpu 利用率、内存使用率、内存已用、内存总量、部署网络传输速度、部署网络接收速率、请求数、请求成功率、请求延迟



日志

单击“**服务部署 > 业务名**”，进入服务详情页面，单击**日志**，展示服务下所有 pod，pod 下所有容器的日志，在 pod 框选择 pod，在 container 框选择 pod 下的 container，单击**查看日志**，即可查看到容器日志，

概述详情metrics**日志**YAMLshell测试AB测试

dfdfdf-predictor-default-5c85c5b5f4-7dfhqkserve-container查看日志

```
[GIN-debug] [WARNING] Creating an Engine instance with the Logger and Recovery middleware already attached.


[GIN-debug] [WARNING] Running in "debug" mode. Switch to "release" mode in production.
- using env:   export GIN_MODE=release
- using code:  gin.SetMode(gin.ReleaseMode)

[GIN-debug] POST   /add                --> main.addOne (3 handlers)
[GIN-debug] POST   /add2               --> main.addTwo (3 handlers)
[GIN-debug] [WARNING] You trusted all proxies, this is NOT safe. We recommend you to set a value.
Please check https://pkg.go.dev/github.com/gin-gonic/gin#readme-don-t-trust-all-proxies for details.
[GIN-debug] Listening and serving HTTP on :8080
```

Shell 连接

单击“**服务部署 > 业务名**”，进入服务详情页面，单击**Shell 连接**，可以查看到服务下所有 pod，pod 下所有容器，但这里只有提供 sh 命令的容器，可进入到容器中执行命令。在 pod 框选择 pod，在 container

框选择 pod 下的 container，单击**调试**可以进入容器执行 shell 命令，并且执行完命令后可以单击**保存 shell 文本**将命令保存。单击**上传/下载**，可以上传文件到容器中或从容器中下载文件。



在线调试

单击“**服务部署 > 业务名**”，进入服务详情页面，单击**在线调试**，可以用服务内部 URL 进行简单的连通性测试。这里支持以“curl”开头的测试请求，以及支持插入后缀为.json 格式的文件，单击**发送请求**后，在请求结果中返回服务的响应，在请求结果中，state 为 0 时代表服务正常返回，否则为异常。

概述	详情	metrics	日志	YAML	shell	测试	AB测试
----	----	---------	----	------	-------	----	------

请求代码

请求URL: dfdfdf-predictor-default.fasdf.svc.cluster.local:8080

```
curl -X POST dfdfdf-predictor-default.fasdf.svc.cluster.local:8080/add -d '{"data": 1}'
```

插入文件 发送请求


请求结果

```
{  "data": "{\\"data\\":2}",  "state": 0}
```

格式化JSON 还原格式

AB 测试

AB 测试即绑定主线服务和测试服务，然后通过手动流量控制、流量镜像、条件流量的策略将入口流量进行划分，并使用服务评估功能评估主线、测试服务的服务质量。单击“**服务部署 > 业务名 > AB 测试**”，进入 AB 测试页面，单击**定位还原**，可使拓扑图位于居中位置，



单击**创建**按钮，可以创建测试服务，这里参数含义和**服务部署创建**相同，

AB测试

■ 基本信息

场景 *
wm4

模型 *

选择

业务 *

框架

■ 资源配置

无服务模式

CPU *

下限

核-

上限

核

内存 *

下限

GB-

上限

GB

☐ GPU

请选择

实例下限 *
1

实例上限 *

QPS *

端口

http

8080

http1

■ 高级配置

批量处理
☐

数据处理
☐

取消

部署

资源占用(资源申请总数/资源可用数) ①

CPU	0/96.9核	内存	0/94.56GB
加速卡			

资源复用率(场景已分配/场景资源总量) ②

CPU	38.5%	内存	42.4%
加速卡			

资源预留

CPU ③	-核/-核
内存 ④	-GB/-GB
是否满足	-

配置

基准资源

CPU比例

暂无数据

在拓扑图中单击**流量分配方式**框，弹出 AB 测试配置页，目前支持三种流量配置方式：* 手动流量控制：采用手动方式，划分主线和测试服务之间的流量；若选择平均分配，则测试流量会平均划分到参与测试的桶中；若选择自定义分配，则需要手动设定每个桶的流量；若选择滚动调节，则主线从 100% 流量开始，每隔一个时间间隔，划分设定步长的流量到测试桶中。* 流量镜像分配：进入主线服务的流量会复制到测试桶中，返回响应结果时，只返回主线服务的。* 条件流量分配：根据设定条件，决定流量进入哪个桶中，条件支持 gjson 格式。

编辑流量分配方式

×

1

2

流量分配方式

测试分桶设置

手动流量控制

采用手动方式，划分参与A/B/n测试的服务之间的流量

流量滚动调节

节

时间间隔 *

60

步长 *

5

流量分配方式

平均分配

自定义分配

主线流量 *

60

测试流量 *

40

流量镜像分配

主线服务的流量复制发送到测试服务，返回结果只包含主线服务结果

条件流量分配

根据设置的条件确定流量发送到哪个服务（其中条件是gjson格式，根据条件对输入进行判断）

取消

下一步

其中，手动流量控制可以选择是否**流量滚动调节**，若选择滚动调节，则主线从 100% 流量开始，每隔一个时间间隔（时间间隔需要大于等于 60s），划分设定步长（需要大于等于 1）的流量到测试桶中，直到主线桶和测试桶到达目标流量。并且，流量分配方式可以选择**平均分配**或**自定义分配**，当选择平均分配时，主线桶的目标流量采用**主线流量**，而**测试流量**则平均分配到每个测试桶里；当选择自定义分配时，则需要为每个桶设置目标流量，

版权所有 © 浪潮电子信息产业股份有限公司

146

编辑流量分配方式

×

✓

流量分配方式

2

测试分桶设置

当前流量分配方式: 手动流量控制

☒ 加入测试

流量: *

−

40

+

端口: *

8080

▼

路径: */div>

分桶编号: 0

业务: dfdfdf

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试

流量: *

−

50

+

端口: *

8080

▼

路径: */div>

分桶编号: 1

业务: test66

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试

流量: *

−

10

+

端口: *

8080

▼

路径: */div>

分桶编号: 2

业务: test778

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1


取消

上一步

提交

并且，需要为加入测试的每个桶设置访问路径、访问端口，设置完成后，单击提交，返回拓扑图，可看

到从流量分配框已经连线到服务框，



流量镜像分配，只能选择两个服务加入测试，每个服务的流量都是 100%，

编辑流量分配方式

×

①

流量分配方式

②

测试分桶设置

当前流量分配方式: 流量镜像分配

☒ 加入测试

流量 *

−

100

+

端口: *

8080

▼

路径 *

/add

分桶编号: 0

业务: dfdfdf

CPU(核)

1/1

内存(GB)

1/1

加速卡数

-/-

实例数

1/1

☒ 加入测试

流量 *

−

100

+

端口: *

8080

▼

路径 *

/add

分桶编号: 1

业务: test66

CPU(核)

1/1

内存(GB)

1/1

加速卡数

-/-

实例数

1/1

☐ 加入测试

流量

−

100

+

端口:

8080

▼

路径

/add

分桶编号: 2

业务: test778

CPU(核)

1/1

内存(GB)

1/1

加速卡数

-/-

实例数

1/1

取消

上一步

提交

条件流量分配，需要设置到达服务的条件，

编辑流量分配方式



1

流量分配方式

2

测试分桶设置

当前流量分配方式: 条件流量分配

☒ 加入测试

端口: * 8080

路径: * /add

条件: * [@this].#(userid==1)

分桶编号: 0

业务: dfdfdf

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试

端口: * 8080

路径: * /add

条件: * [@this].#(userid==2)

分桶编号: 1

业务: test66

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

☒ 加入测试

端口: * 8080

路径: * /add

条件: * [@this].#(userid==3)

分桶编号: 2

业务: test778

CPU(核)	内存(GB)	加速卡数	实例数
1/1	1/1	-/-	1/1

取消

上一步

提交

在流量调整中，可重新调整配置，

流量调整

×

当前流量分配方式 手动流量控制

☐ 加入测试

流量 *

-

40

+

端口: *

8080

路径 *

/add

分桶编号: 0

业务: dfdfdf

CPU(核)

1/1

内存(GB)

1/1

加速卡数

-/-

实例数

1/1

☒ 加入测试

流量 *

-

30

+

端口: *

8080

路径 *

/add

分桶编号: 1

业务: test66

CPU(核)

1/1

内存(GB)

1/1

加速卡数

-/-

实例数

1/1

☒ 加入测试

流量 *

-

30

+

端口: *

8080

路径 *

/add

分桶编号: 2

业务: test778

CPU(核)

1/1

内存(GB)

1/1

加速卡数

-/-

实例数

1/1

在拓扑图中，单击右侧分桶框，弹出分桶操作页，在分桶操作页，可以对测试桶进行**流量回滚**，即将测试桶流量完全回滚到主线桶，测试桶流量置 0；**服务转正**是指将测试服务提升为主线服务，并且同时删除主线和测试桶上的流量策略。注意**流量回滚**和**服务转正**只有在手动流量控制中才可使用。**删除**是指删除该测试服务，在测试服务正在参与流量策略时，不能删除测试服务，可以通过**流量调整**将该测试服务勾选掉，再删除该测试服务。主线服务无法进行服务转正。主线服务的删除需要进入通用模型/应用部署首页的列表进行删除，在首页删除时，会把主线服务、所有的测试服务以及流量策略都删除。

×

分桶编号 2

业务: test778

CPU(核) 1/1

内存(GB) 1/1

加速卡数 -/-

实例数 1/1

就绪

流量回滚

服务转正

删除

服务评估

在**服务评估**中，可创建实验对主线和测试服务进行服务质量评估，单击**实验**，展示实验列表，包含名称、场景、状态、操作等信息，只有加入场景的用户才能看到该场景下的所有实验。

服务评估

×

实验

指标

创建实验

名称	场景	状态	操作
yyy	mmm	成功	删除

选择列

共 1 条

50条/页

< 1 >

前往 1 页

单击**创建实验**，需填写如下参数：

名称	说明
服务名	创建的实验名称，长度应小于等于 32 且不为空
场景	实验运行的场景
主指标	必填，且需指明方向 高/低 ，高表示该指标取值越高越好，反之则表示取值越低越好
辅指标	可以有若干个（≥0 个），需选择指标名称，指标的上下限，并填写指标的阈值
服务	默认可以选择两个服务进行评估，可以继续添加新的服务。选择对应服务，会自动代入服务所属场景，路径必填，表示该服务对外提供的 URL

创建实验

服务名 *

yyy

场景 *

mmm

指标

主指标

http/request-count

高

辅指标1

http/error-count

上限

-

100

+

+ 添加辅指标

服务

服务1

trirt

mmm

trirt.mmm.svc.cluster.local

服务2

dsds

mmm

dsds.mmm.svc.cluster.local

+ 添加服务

取消

确定

单击**确定**按钮，创建实验，之后自动返回实验列表页面。实验评估创建成功后，初始状态为**未知**，等待一段时间，状态会发生如下转变：**未知 -> 运行中 -> 成功/失败**。单击实验名称，进入**评估结果**页面，若实验状态为失败，意味着评估失败，**推荐服务**栏为空，单击两个服务的下拉按钮，可以查看服务评估详情。若辅指标中有一项**是否满足条件**为否，则排除该服务；只有当所有辅指标均满足条件，则根据主指标的实际值和方向进行比较，最终选出推荐服务。

评估结果

实验名称 yyy

场景 mmm

推荐服务 dsds

应用	实验状态	实验时间
trirt	成功	2023-11-17 09:13:56
主指标 http/request-count 主指标方向 高 主指标实际值 100		
辅指标	辅指标目标值	辅指标上下限
http/error-count	100	上限
是否满足条件	是	实际值
		100
dsds	成功	2023-11-17 09:13:56
主指标 http/request-count 主指标方向 高 主指标实际值 100		
辅指标	辅指标目标值	辅指标上下限
http/error-count	100	上限
是否满足条件	是	实际值
		100

在**指标**菜单页，用户可以看到指标列表，包含名称、类型、描述等信息。其中，类型为内置表明为内置指标。

版权所有 © 浪潮电子信息产业股份有限公司

153

服务评估

×

实验指标

名称	类型	描述
http/request-count	内置	发送的请求总数
http/error-count	内置	错误响应数
http/error-rate	内置	错误响应率
http/latency-mean	内置	平均响应时间
http/latency-stddev	内置	响应时间标准差
http/latency-min	内置	最小响应时间
http/latency-max	内置	最大响应时间
http/latency-p50	内置	50%的请求延迟情况
http/latency-p75	内置	75%的请求延迟情况
http/latency-p90	内置	90%的请求延迟情况
http/latency-p95	内置	95%的请求延迟情况
http/latency-p99	内置	99%的请求延迟情况
http/latency-p99.9	内置	99.9%的请求延迟情况

选择列

共 13 条50条/页

<1>

前往1页

在**实验**菜单页展示的实验列表中，可以单击操作栏的**删除**按钮删除对应的实验。

注：目前 AB 测试只支持有 http、https 类型端口的服务创建测试服务，细粒度主线服务只能创建细粒度的测试服务，非细粒度主线服务只能创建非细粒度的测试服务

更新

单击“**服务部署 > 操作栏 > 更新**”，可以对服务的参数进行更新，更改参数后，单击**更新**，既可更新服务参数配置。目前，细粒度服务不支持更新。

基本信息

环境 *
vm4

模型 *
win4.xqmainmme 选择

业务 *
testingress

框架
lim

资源配置

无限制模式 ☐

cpu使用率 *
1 %

CPU *
2 核 - 2 核

内存 *
4 GB - 4 GB

☐ GPU
资源池

PVC

实例数 *
1 - 1

多端口 ☐

端口
http 8080 http8080

高级配置

路径

开启日志 ☐

批量处理 ☐

数据缓存 ☐

应用部署 ☐

资源占用/资源申请/总数量/资源可用数

CPU	2/105 1核	内存	4/105 5GB
加速卡			

资源使用率/资源已分配/资源资源总量

CPU	31.83%	内存	33.94%
加速卡			

资源预览

CPU 核/核

内存 GB/GB

资源预览

资源池

CPU比例

内存比例

资源预览

资源池

复制

单击“服务部署 > 操作栏 > 复制”，可以拷贝现有服务参数，在更改业务名以及其他参数后，单击部署，既可创建一个新服务。

基本信息

环境 *
vm4

模型 *
win4.xqmainmme 选择

业务 *
testingresscopy

框架
lim

资源配置

无限制模式 ☐

cpu使用率 *
1 %

CPU *
2 核 - 2 核

内存 *
4 GB - 4 GB

☐ GPU
资源池

PVC

实例数 *
1 - 1

多端口 ☐

端口
http 8080 http8080

高级配置

路径

开启日志 ☐

批量处理 ☐

数据缓存 ☐

应用部署 ☐

资源占用/资源申请/总数量/资源可用数

CPU	2/96 9核	内存	4/96 56GB
加速卡			

资源使用率/资源已分配/资源资源总量

CPU	45.5%	内存	52.18%
加速卡			

资源预览

CPU 核/核

内存 GB/GB

资源预览

资源池

CPU比例

内存比例

资源预览

资源池

下线、上线

单击“**服务部署 > 操作栏 > 下线**”，可以将现有服务下线并释放资源，单击**上线**，可以上线当前服务并为当前服务占用资源。


删除

单击“**服务部署 > 操作栏 > 删除**“，可以将现有服务删除，释放资源。

Chat

“大模型开发 > Chat”，在业务范围是训练 + 推理下可用


平台提供了大模型对话功能，用户可以选择具有对话能力的大模型服务进行对话，并提供了新建对话、清空对话、历史记录重命名、对话保存和恢复的功能。



模型选择

在进行对话前需要单击“**选择服务**”下拉菜单，选择具有对话能力的大模型服务。普通用户可选择所有场景下具有对话能力的大模型服务进行对话。

Chat



The screenshot shows a web interface for a chat application. At the top, there is a header bar with the text "Chat". Below the header, there is a section titled "选择服务*" (Select Service*). Under this title, there is a dropdown menu with the text "请选择" (Please select) and an upward-pointing arrow. Below the dropdown menu, there is a list of available services, with "w3copy" being the only visible option.

对话参数

选择模型服务后，普通用户可设置温度、终止字符、重复惩罚、最大 token 数量、系统人设 5 个参数。

Chat

选择服务 *

w3copy

推理超参数

温度 ?

0.8

终止字符 ?

重复惩罚 ?

1

最大token数量 ?

512

系统人设

名称	说明
温度	控制文本生成的随机性，值越大生成内容越随机，多样性更好，取值范围 0.0-1.0，默认值为 0.8
终止字符	用于控制生成时遇到某些内容则停止，最多 32 个字符
重复惩罚	其中较高的值意味着更强的惩罚，生成的文本中将出现更少二点重复，取值范围 0.0-2.0，默认值为 1.0

名称	说明
最大 token 数量	限定了模型生成文本的最长长度。当模型达到指定的最大 token 数量时，它会停止继续生成新的文本内容，取值范围 1-模型上下文长度，默认值为 512。模型上下文长度在“模型仓库 > 导入 > 文本长度”中设置。
系统人设	给予模型的一段指令或上下文信息，指导模型按照特定方式进行文本生成。常用于控制输出风格、语气等。系统人设中的内容与聊天内容的 token 数量之和不得超过模型上下文长度

对话

单击下方的文本输入框，并输入对话内容后，单击“发送”按钮即可触发对话，对话内容将以对话框形式展示。

新建对话 清空对话 历史记录

 请介绍一下大语言模型



大语言模型是一种人工智能技术，它可以处理大规模文本数据，并根据文本中的模式生成相应的输出。它可以从大量的文本数据中自动提取信息，并使用机器学习算法对其进行建模，从而实现快速准确的文本生成。

Prompt模板

请介绍一下人工智能

发送

内容由AI生成，仅供参考，不代表平台立场，请仔细甄别

历史记录

在文本输入框输入对话内容并单击“**发送**”按钮对话内容将被自动保存。保存的对话单击“**历史记录**”进行查看。单击“**历史记录**”可查看被保存的历史记录列表，记录默认标题为最后一轮对话的问题。单击历史记录项，可将历史记录项中的聊天内容恢复到当前对话窗口。单击历史记录项的“**编辑**”按钮修改标题，自定义标题长度为 1-100 个字符。单击历史记录项的“**删除**”按钮可删除该历史记录项，如果被删除历史记录项为当前聊天记录，则在删除历史记录项的同时清空当前窗口中的聊天记录并新建对话。历史记录列表中，越近进行的对话的历史记录项越靠上。

历史记录

×

请介绍一下大语言模型

hi

222

gfgfg

请提供书籍钢铁是怎样炼成的的简介，300字。

请打印1到100这些数组

12345678901234567890123456789012345678901...

2222

测试测试

12

www

111

111

1111

aaaa

111

cccc

222


aaaa

新建对话

单击“新建对话”可开启新一轮对话，同时当前对话如果存在的话将被自动保存。

清空对话

当且仅当当前对话窗口中含有聊天内容时“清空对话”可被点击，单击“清空对话”可开启新一轮对话，同时当前对话历史将被删除。



Prompt 模板

列表

单击“Chat > Prompt 模板”，查看所有 Prompt。每个 Prompt 页签展示的信息包括：名称、标签、内容，操作按钮包括：使用按钮。Prompt 列表过滤条件支持名称、标签、内容进行过滤查询。

Prompt模板

名称

标签

内容

搜索

测试模板

人物信息

请描述{name}的生平，不少于{number}字

使用

我的第一个模板

书籍信息

请提供书籍{book}的简介，{number}字。

使用

共 2 条

50条/页

<

1

>

前往

1

页

名称	说明
名称	Prompt 名称
标签	Prompt 标签
内容	Prompt 内容

使用

单击“Chat > Prompt 模板 > Prompt > 使用”，进行模板变量录入，可以使用变量的默认值也可以修改变量值，点击确认后内容显示在 Chat 输入框中。

模板变量录入

请描述张三的生平，不少于100字

取消

确定

请描述张三的生平，不少于100字

发送


内容由AI生成，仅供参考，不代表平台立场，请仔细甄别

Prompt 管理

“大模型开发 > Prompt 管理”，在业务范围是训练 + 推理下可用

列表

单击“**Prompt 管理**”，查看所有 Prompt。每个 Prompt 页签展示的信息包括：名称、标签、权限（个人、组、公共）、内容，操作按钮包括：详情、编辑、设置共享权限、删除按钮。Prompt 列表过滤条件支持名称、标签、内容进行过滤查询。



名称	说明
名称	Prompt 名称
标签	Prompt 标签
权限	Prompt 权限
内容	Prompt 内容

创建

单击“**Prompt 管理 > 创建**”，进入创建的页面，填写信息如下：填写名称；标签可以选择已有的标签也可以自定义标签；填写内容；从内容中识别出“{}”中的变量名称并填写变量的默认值；单击“确定”即可。

创建Prompt

名称*

测试模板

标签*

人物信息

内容*

请描述下{name}的生平，不少于{number}字

26 / 11200

变量

name

张三

number

100

名称	说明
名称	必填，Prompt 的名称。格式要求：支持中英文、数字和中划线，且以中英文开头，不能以中划线结尾，长度不能超过 32 字符
标签	必填，下拉列表，可选择已有标签，也可自定义标签。格式要求：最多 12 个字符，支持中英文、数字和中划线，且以中英文开头，不能以中划线结尾
内容	必填，Prompt 内容，长度不超过 11200 字符
变量	非必填，Prompt 变量，分为变量名和变量值。其中，变量名从内容中根据“{}”中定义，变量名格式要求：支持英文、数字和下划线，且不能以数字开头，长度 2-30 字符，变量默认值自定义

详情

单击“**Prompt 管理 > Prompt > 详情**”，展示 Prompt 详情页面。展示的信息包括：名称、标签、权限、创建人、创建时间、更新时间、内容，变量包括变量名称和默认值。

Prompt详情

名称

测试模板

权限

个人

创建时间

2024-05-14 14:23:43

内容

请描述{name}的生平，不少于{number}字

变量

变量名称	默认值
name	张三
number	100

标签

人物信息

创建人

zxy1

更新时间

2024-05-14 14:23:43

编辑

单击“**Prompt 管理 > Prompt > 编辑**”，可以编辑 Prompt。可编辑信息包括：标签、内容、变量。

编辑Prompt

名称*

测试模板

标签*

人物信息

内容*

请描述{name}的生平，不少于{number1}字，不多于{number2}字

40 / 11200

变量

name	张三
number1	100
number2	200

名称	说明
标签	必填，下拉列表，可选择已有标签，也可自定义标签。 格式要求：最多 12 个字符，支持中英文、数字和中划线，且以中英文开头，不能以中划线结尾
内容	必填，Prompt 内容，长度不超过 11200 字符
变量	非必填，Prompt 变量，分为变量名和变量值。其中， 变量名从内容中根据“{}”中定义，变量名格式要求： 支持英文、数字和下划线，且不能以数字开头，长度 2-30 字符，变量默认值自定义

删除

单击“**Prompt 管理 > Prompt > 删除**”，可以删除 Prompt。

共享

单击“**Prompt 管理 > Prompt > 共享**”，可以共享 Prompt。目前 Prompt 权限支持三种：个人、组、公共，个人仅对自己可见，组是用户组下所有成员都可见，公共是集群中所有用户都可见。Prompt 权限只能升不能降，比如，可以从个人升级到组，但是不能从组降到个人。



资产

数据管理

文件管理

“数据管理 > 文件管理”，在业务范围是训练 + 推理、训练下可用

文件数据展示

文件数据支持列表模式和缩略图模式两种展示方式。

1. 单击“文件管理”，查看用户目录、公共目录和样本数据，默认为列表模式，显示用户目录文件列表。公共目录包括全局共享和组共享，用户目录和公共目录的文件列表显示项均为名称、拥有者、类型、大小、创建时间。列表模式下数据展示如下图：

上一级 | 用户目录 / zyh


用户目录	☐	名称	拥有者	类型	大小	创建时间
公共目录						
全局共享						
defaultShare						
组共享						
clh						
样本数据						
	☐	wildlife_painting.ta...	root	压缩包	2.50 MB	2023-05-24 16:42:42
	☐	测试图片json.zip	zyh	压缩包	404.75 KB	2023-05-24 16:48:27
	☐	logback-spring.xml	root	文件	2.00 KB	2023-05-19 10:04:14
	☐	测试图片json	zyh	文件夹	-	2023-05-24 16:48:39
	☐	test.py	zyh	文件	154 Byte	2023-05-24 18:06:01
	☐	mydata	root	文件夹	-	2023-05-24 17:53:17
	☐	visualization	zyh	文件夹	-	2023-05-19 09:56:49
	☐	logPersistence	root	文件夹	-	2023-05-24 18:07:06
	☐	多个标注结果.zip	zyh	压缩包	204.68 KB	2023-05-24 16:48:32

共 18 条 50条/页 1 前往 1 页

可以单击右上方模式切换的图标，切换为缩略图模式，如下图：



缩略图模式下数据展示如下图：



文件管理用户目录可以对接多存储，用户目录左侧的目录树将使用存储名分级展示如下图，其中主存储展示在第一个。



2. 路径导航栏上方有快捷文件操作按钮，包括上传、新建、复制到、重命名、删除，打开更多，可以查看其余文件操作按钮。

3. 单击“文件管理 > 公共目录”下的文件夹，显示全局共享和组共享文件，普通用户可以查看所属公共目录下文件。全局共享下有默认的 defaultShare 目录，管理员可以在全局共享下，将目录设为公共目录后，普通用户即可查看。普通用户的组共享目录只有一个，即为绑定的用户组，文件名称与用户组名相同。

4. 单击“文件管理 > 样本数据”下的文件夹，显示样本数据目录，样本数据目录可以查看文件列表，可以查看文件（包括普通文件、图片、音频、视频），可以支持文件和路径搜索，不可进行其他操作。文件管理样本数据可以对接多存储，左侧的目录树将使用存储名分级展示，与用户目录多存储显示一致，其中主存储展示在第一个。

系统管理员通过“设置 > 存储设置”页面添加样本数据备存储，然后，用户可以在平台其他模块使用新添加存储的公共样本数据文件。

当样本数据权限开关开启后，该目录只能展示已授权给该用户的样本数据目录。需要注意的是，样本数据权限开关开启状态下，样本数据的备存储数据同样需要系统管理员授权后才可以使用。

5. 列表模式下，可在文件列表表头对名称和创建时间进行升序或降序排序，支持用户目录、全局共享目

录、组共享目录排序，不支持样本数据排序。

☐	名称 ▾	拥有者	类型	大小	创建时间 ▾
☐	export	1001	文件夹	-	2023-05-24 17:53:25
☐	label_studio.sqlite3	1001	文件	1000.00 KB	2023-05-24 17:53:17
☐	media	1001	文件夹	-	2023-05-24 16:43:14

共 3 条


50条/页 ▾

< 1 >

前往 1 页

新建文件


1. 单击路径导航栏上方快捷键新建，可以在用户目录新建文件。



2. 弹出新建文件界面，在名称输入栏，输入合法文件名（与新建文件夹约束一致）。单击确定，则页面自动刷新，显示新建的文件。

新建文件夹

1. 单击路径导航栏上方快捷键新建，可以在用户目录新建文件夹。



2. 弹出新建文件夹界面，在名称输入栏，输入新建文件夹名，只能输入汉字、英文字母、数字、点、下划线和连接线，不能以连接线和点开头。

新建文件夹

名称*

`1

只接受汉字、英文字母、数字、点、下划线和连接线，不能以连接线和点开头

取消

确定

3. 输入合法文件夹名，单击确定，则页面自动刷新，显示新创建的文件夹。

查看

可以查看普通文件、图片 (支持 png、jpeg、jpg、bmp 格式)、音频文件 (支持 mp3、wav、flac 格式)、视频文件 (支持 mp4、avi、flv、mov)。支持查看 50M 以下的普通文件和图片，默认支持查看 50M 以下的音频，默认支持查看 100M 以下的视频。

普通文件查看

文件显示区域，选中文件，右键单击，弹出右键菜单，单击查看，或者双击，查看文件内容。

编辑文件

搜索/替换

撤回

复制

粘贴

剪切

```
1 # coding=utf-8
2 import hmac
3 import base64
4 from hashlib import sha256
5 from datetime import datetime
6
7 time=datetime.strftime(datetime.utcnow(), "%Y%m%d"+"T"+"%H%M%S"+"Z")
8 print (time)
9 appsecret = "411ec7b884b84a8e98f737dc4544d78a".encode('utf-8') # 密钥
10
11
12 datal = "GET\n" + "/v1/openapi/authenticate/\n" + "\n" + "HMAC-SHA256\n" +time
13 data = datal.encode('utf-8') # 加密数据
14 signature = base64.b64encode(hmac.new(appsecret, data, digestmod=sha256).digest())
15 # 获取十六进制加密数据
```

取消

确定

弹出的编辑文件界面，可以对文件进行编辑，编辑器支持搜索/替换、撤回、复制、粘贴、剪切，单击“确定”保存。

版权所有 © 浪潮电子信息产业股份有限公司


171

查看图片

支持双击和右键单击查看按钮进行图片查看，支持普通图片查看和带标注的图片查看，打开的图片支持缩放。支持当前页中上一张下一张图片查看，单击页面的左右箭头，或者使用键盘的左右键翻动，当查看到最后一张时，单击下一张，则循环到当前页的第一张图片，如下图：



缩略图模式下可以展示普通图片的缩略图，如下图：



用户查看带标注的图片，需要满足的条件是：图片和 json 文件在同一级目录下，一张图片对应一个 json 文件，且必须同名，且标注的 json 文件需要满足 label-studio 的 json 格式。如：a.jpg 和 a.json 如果


标注 json 文件和图片不在同一级目录下，可以在指定配置文件 dataset_json_setting.json 中配置标注 json 文件的路径，该配置模板位于全局共享目录/defaultShare 下，使用时，将该模板复制到用户家目录下，并按模板中的注释配置图片和 json 文件路径即可。

查看效果如下图：



播放音频

支持双击和单击查看按钮进行音频文件播放。



播放视频

支持双击和单击查看按钮进行视频文件播放。




HBase协处理器

主讲人： Louis




复制到

选择文件，右键单击，单击菜单的“复制到”或者单击路径导航栏上方快捷菜单“复制到”，弹出对话框，选择目标文件夹，文件的处理进度显示在右侧进度列表中。可通过进度列表的目录链接，进入文件列表。




重命名

选择文件，右键单击，单击菜单的“重命名”或者单击路径导航栏上方快捷菜单“重命名”，弹出重命名界面，在名称输入栏输入合法的文件名（与新建文件夹约束一致），单击“确定”，页面自动刷新，显示重命名文件。



压缩

压缩文件支持批量或单个文件进行压缩，支持压缩格式 tar、tar.gz 和 zip，首先选择文件，然后右键单击，单击“添加到压缩文件”或者单击路径导航栏上方快捷菜单“更多”选择添加到压缩文件，弹出压缩文件界面，在名称输入栏输入合法的压缩文件名，单击“确定”，页面自动刷新，显示压缩的文件，文件的处理进度显示在右侧进度列表中。可通过进度列表的目录链接，进入文件列表。压缩文件只可以在用户目录操作。




解压

选择压缩文件，右键单击“解压”，将压缩包解压到与压缩包同名的文件夹下，页面自动刷新，显示解压文件，文件的处理进度显示在右侧进度列表中。可通过进度列表的目录链接，进入文件列表。



上传文件


1. 单击路径导航栏上方快捷键上传，可以上传文件。



- 2. 单击“上传文件”，弹出提示框提示单次上传的最大文件数，单击确定，弹出加载文件界面，选择需要上传的文件。
- 3. 选中要上传的文件，支持选择多个文件，单击打开，文件处理列表中显示多条上传文件的进度。上传完成，页面自动刷新，列表中显示上传完成的文件。
- 4. 上传单个文件大小默认不超过 20G，如果超过指定大小无法上传，请使用 xftp 工具进行上传。

上传文件夹

1. 单击路径导航栏上方快捷键上传，可以上传文件夹。



提示

×

单次上传文件夹，文件夹中最多只能包含300个文件!


取消

确定

2. 单击“上传文件夹”，弹出提示框提示单次上传的文件夹，文件夹中包含的最大文件数，单击确定，弹出加载文件夹界面，选择需要上传的文件夹。
3. 选中要上传的文件夹，只能选择一个文件夹，单击打开，文件处理列表中显示一条上传文件夹的进度。上传完成，页面自动刷新，列表中显示上传完成的文件夹。
4. 上传单个文件夹总大小默认不超过 20G，如果超过指定大小无法上传，请使用 xftp 工具进行上传。

下载


1. 选择下载文件，右键菜单单击“下载”或者单击路径导航栏上方快捷菜单“更多”选择下载，只支持单个文件下载。只可以在用户目录下载文件。



2. 弹出下载文件提示。

删除


1. 删除支持单个文件和批量删除，首先选择删除的文件或文件夹，右键菜单，单击“删除”或者单击路径导航栏上方快捷菜单“删除”。



2. 弹出确定删除界面，单击“确定”，删除文件，文件处理列表中显示删除文件的进度。删除完成，页面自动刷新。


共享

1. 用户目录下文件的共享操作默认包含共享到组共享和共享到全局共享。选择文件，右键单击，单击菜单的“共享到组共享”/“共享到全局共享”或者单击路径导航栏上方快捷菜单“更多”选择操作。




2. 若只有一个全局共享目录或组共享目录，文件直接共享到该目录下，不必选择目标文件夹。当全局共享或组共享的目录多于一个时，弹出对话框，选择目标文件夹，文件的处理进度显示在右侧进度列表中。可通过进度列表的目录链接，进入文件列表。

3. 开启文件共享功能的用户，具有选择文件共享到用户的权限，在弹出框中输入共享的用户名即可将文件共享到用户。



取消共享

1. 支持单个和批量取消共享，在全局共享或组共享目录下，选择要取消共享的文件或文件夹，这里只能取消自己共享后的文件，不能取消其他人的共享文件。右键菜单，单击“取消共享”或者单击路径导航栏上方快捷菜单“更多”选择操作。



2. 弹出确定取消共享界面，单击“确定”，文件处理列表中显示取消共享文件的进度。取消共享完成后，页面自动刷新。

文件搜索


1. 在搜索框中输入要搜索的关键字，回车或单击搜索按钮，在当前目录下全局搜索。




2. 当搜索结果较多时，可以拖动右侧滚动条，进行展示。

路径搜索

1. 单击路径导航栏中的空白处，可以切换编辑模式，支持自定义输入路径，单击前往图标或者回车后跳转到该路径下，如果输入的路径不存在，页面提示“找不到 xxx，请检查拼写重试”



2. 单击路径导航栏右侧的下拉小三角，可以查看最近的路径搜索记录，倒序显示，每个用户的每个目录类型下（用户目录、全局共享、组共享、样本数据）最多显示 15 条



进度操作

1. 进入文件处理列表的操作包括：复制、共享、删除、取消共享、压缩、解压缩、上传。同一用户同一操作只有一个在处理，其余需要排队。

文件处理


— ×

文件 (夹) 名	类型	操作类型	大小	存储名称	节点名称	目录	状态	操作
4x.mp3	文件	上传	1.24 MB	master		/zyh	完成	删除
4MB.M...	文件	上传	4.42 MB	master		/zyh	完成	删除
48.5MB...	文件	上传	48.53 MB	master		/zyh	完成	删除
6b01a3...	文件	复制	1.24 KB	master	node1	/zyh/mydat	完成	删除
3abf90...	文件	复制	1.27 KB	master	node1	/zyh/mydat	完成	删除
6b01a3...	文件	删除	1.24 KB	master	node1	/zyh/mydat	完成	删除
3abf90...	文件	删除	1.27 KB	master	node1	/zyh/mydat	完成	删除
wildlife...	压缩包	共享	2.50 MB	master	node1	/clh	完成	删除
测试图...	压缩包	共享	404.75 ...	master	node1	/clh	完成	删除

2. 文件处理进度列表可以进行查看、删除、最小化、关闭等操作。最小化后，文件处理进度列表显示为悬浮窗，可以正常切换模块，例如开发环境、训练任务等。可以删除处理中（显示为百分比），排队中，失败，完成的进度。当关闭文件处理进度列表时，关闭后，清除所有完成的任务，如果存在文件处理任务则显示为悬浮窗。

用户目录权限归属

只有普通用户可以进行用户目录权限归属操作，只能操作自己用户目录下的文件和文件夹。
选择一个或多个用户目录下的文件和文件夹，单击路径导航栏上方快捷菜单“更多”选择“权限归属”操作，弹出二次确认页面，单击确定，可以将选中文件的权限归属为当前用户。



完成上述操作后，文件列表的拥有者显示为当前用户。

用户目录导入

新增外置存储后，对于平台之前已存在的用户，如果该存储上用户家目录不存在，单击备存储名称后，弹框提示：用户家目录不存在，是否需要导入？

单击确定，自动导入该用户在所有备存储的用户目录。

单击取消，不自动导入，用户自行手动操作，可以通过用户目录导入在新增外置存储上创建用户家目录。

确定

×

!

用户家目录不存在，是否需要导入？

取消

确定

导入成功后，自动刷新，进入该用户家目录下。

对象存储配置

对接 Ceph 对象存储配置时，才会有此功能。单击“对象存储配置”按钮，填入配置项信息。每个用户只能配置一个，可以多次配置，以最新配置的为准。不对配置项做校验，配置正确，展示文件列表，配置错误，提示配置信息问题。

上传

新建

复制到

重命名

删除

对象存储配置

更多

上一级

ceph

▢ 用户目录

▾ ▢ 公共目录

▾ ▢ 全局共享

defaultShare

▾ ▢ 组共享

default_group

▾ ▢ 样本数据

master

ceph

名称

50条/页

▼

上一页

下一页

对象存储配置字段内容如下：

字段名称	字段说明	字段填写注意事项
存储名称	对象存储名称	该值不允许界面修改，不必填
accessKey	标识用户 AK	必填项
secretKey	用户用于加密签名字符串或密钥 SK	必填项
endPoint	访问域名，可以是 IP:Port 或者自定义域名	必填项

数据集管理

“数据管理 > 数据集管理”，在业务范围是训练 + 推理、训练下可用

适用存储

数据集管理只适用于共享文件存储 (NFS、Gpfs 等)。对象存储 (Ceph、HDFS 等) 不支持使用数据集管理功能。

创建数据集

单击列表右上方“创建数据集”按钮，可以创建一个数据集，必填项为名称、导入数据路径、数据类型。数据集名称由系统自动生成为 dataset-后加一个 4 位随机字符，也可以自定义修改。导入数据路径选择文件管理中的样本数据，数据类型包含图片、文本、音频、视频、其他，描述信息可不填，如果填写需不超过 256 个字符。创建数据集时，会自动创建一个 V001 的版本，该版本来源于选择的导入数据集路径，导入数据路径可以选择用户目录，全局共享，组共享，样本数据的目录。每个用户最多可以创建 100 个数据集。

字段名称	字段说明	字段填写注意事项
名称	数据集名称	必填项，自动生成数据集名称，允许修改，不允许重名
导入数据路径	数据集的文件夹目录，可选家目录、组共享、全局共享、样本数据	必填项
数据类型	数据类型支持图片、音频、文本、视频、其他	必填项
描述	数据集描述	不必填

创建数据集 < 数据集管理

名称*

dataset-zyiu

导入数据路径*

/MNIST_data

数据类型*

☒ 图片

☐ 音频

☐ 文本

☐ 视频

☐ 其他

描述

0/256

选择数据 ×

上一级

当前路径

用户目录

master

||

公共目录

全局共享

defaultShare

组共享

default_group

样本数据

☐	名称	类型	大小	创建时间
☐	 cifar10	文件夹	-	2019-12-04 18:44:26
☐	 MNIST_pytorch	文件夹	-	2019-12-04 18:33:18
☐	 cifar10_caffe	文件夹	-	2019-12-04 19:00:43
☐	 MNIST_data	文件夹	-	2019-12-04 18:24:02
☐	 MNIST_caffe	文件夹	-	2019-12-04 18:27:02

导入数据路径选择的目录在“文件管理”展示其图标为共享标识图标，区别于普通文件夹图标。

☐	名称	类型
☐	 cifar10	文件夹
☐	 MNIST_pytorch	文件夹
☐	 cifar10_caffe	文件夹
☐	 MNIST_data	文件夹
☐	 MNIST_caffe	文件夹

数据集列表查看

只展示自己创建的数据集和共享给自己版本的数据集列表，数据集列表内容包含：名称、数据类型、导入数据路径、存储名称、状态、创建时间、描述、创建用户、操作（创建版本、删除）。支持按照数据集名称模糊搜索。

名称	数据类型	导入数据路径	存储名称	状态	创建时间	描述	创建用户	操作
> dataset-2ms	图片	/MNIST_pytorch	master	🟢 正常	2023-10-31 14:17:59		jgy	创建版本 删除
dataset-8dks	文本	/defaultShare/auto_test_user	master	🟢 正常	2023-10-31 13:31:51		jgy11	创建版本
版本	数据类型	处理方式	发布状态	描述	创建用户	操作		
V002	文本	修改数据	🟢 组		jgy11	版本预览		

注意：状态为失效的数据集由于导入数据路径不存在产生的状态。失效的数据集不能进行缓存使用，也不能进行创建版本和修改数据等操作。

创建版本

支持修改数据的处理方式，您可以单击创建版本，在该数据集下创建一个新的版本，数据集来源可以选择原始数据集或者已发布的数据集版本。创建完成后，可以对每个版本进行文件增删改操作，并发布使用。发布后的数据集版本不能再进行文件增删改操作。如果想再次进行文件操作，必须创建一个新的数据集版本。创建版本时，数据集名称自动带入，不可修改，来源可以选择导入的数据路径或者已发布的版本。版本由系统自动生成，按顺序填充，从 V001 累加到 V999。版本名称可以自定义修改，不可重名。版本名称只能包含数字字母下划线连接线，不能以下划线和连接线开头，最多 32 个字符。创建的版本会自动进入进度列表中，进度列表显示版本、数据集、节点名称、操作类型、存储名称、状态、操作等。

字段名称	字段说明	字段填写注意事项
名称	数据集名称	该值不允许界面修改，不必填
来源	原始导入数据路径或者数据集下已发布的版本	必填项
版本	数据集下版本名称	必填项，自动生成版本名称，允许修改，不允许重名
描述	版本描述	不必填

创建版本

×

名称*

dataset-9b4a

来源*

请选择

/MNIST_data

V001

版本*

描述

0/256

取消

确定

修改数据（增删改文件）

未发布的版本可以进行修改数据，操作类型包括：导入、删除、编辑文件。

1. 导入数据可以选择文件管理中的文件，不能导入创建数据集时选择的原始数据。如果导入重名文件，提示是否覆盖。单击版本名称进入文件列表页面，单击右上方的“导入”按钮，弹出文件管理页面，选择要导入的数据，单击确定。导入的数据会自动进入传输列表中，进度列表显示导入的文件（夹）名、节点名称、类型、操作类型、大小、存储名称、状态、操作。

上一级 当前路径 /dataset-2ms/V001

发布

导入

删除

进度列表

名称	类型	大小	创建时间
☐ MNIST	文件夹	-	2019-12-04 18:35:20
☐ raw	文件夹	-	2019-12-04 18:33:00
☐ processed	文件夹	-	2019-12-04 18:29:40

进度列表

文件（夹）...	节点名称	类型	操作类型	大小	存储名称	状态	操作
cifar10_test _lmdb	node1	文件夹	导入	-	master	成功	删除

2. 删除数据时，选中文件列表中要删除的文件，单击右上方的“删除”按钮即可，删除的数据会自动进入传输列表中。

上一级 当前路径 /dataset-2rms/V001

发布 导入 删除 进度列表

名称	类型	大小	创建时间
☐ cifar10_test_lmdb	文件夹	-	2023-10-31 14:23:52
☐ MNIST	文件夹	-	2019-12-04 18:35:20
☒ raw	文件夹	-	2019-12-04 18:33:00
☐ processed	文件夹	-	2019-12-04 18:29:40

进度列表

文件 (夹) ...	节点名称	类型	操作类型	大小	存储名称	状态	操作
raw	node1	文件夹	删除	-	master	成功	删除
cifar10_test_lmdb	node1	文件夹	导入	-	master	成功	删除

3. 编辑文件时，单击文件名称打开可编辑的文件，输入修改内容，单击确定即可。

版本发布

未发布的版本，可以单击操作栏的发布按钮进行发布。也可以在该版本的文件列表页面单击“发布”按钮操作，可以将版本发布到个人、组和全局，发布到个人只有个人可以使用，发布到组可以组内用户可以使用，发布到全局可以全局人员使用。

版本	数据类型	处理方式	发布状态	描述	创建用户	操作
V001	图片	修改数据	未发布		jgy	发布 编辑 删除

上一级 当前路径 /dataset-2rms/V001

发布 导入 删除 进度列表

名称	类型	大小	创建时间
☐ cifar10_test_lmdb	文件夹	-	2023-10-31 14:23:52
☒ MNIST	文件夹	-	2019-12-04 18:35:20
☐ processed	文件夹	-	2019-12-04 18:29:40

发布

发布方式*

个人

组

全局

取消

确定

单击“发布”按钮，并选择发布方式后，若页面上方提示“该操作需要等待管理员审批，审批结果可在审批管理中查看”，则需要管理员进行审批操作。若管理员审批通过，则该版本进行发布操作；若管理员审批拒绝，则该版本不进行后续发布操作。

该操作需要等待管理员审批，审批结果可在审批管理中查看

版本视图

发布的数据集版本可以进行版本视图查看，追溯来源过程。

版本视图

自 V001

版本	V001	数据集	dataset-2rrs
处理方式	修改数据	发布状态	个人
创建时间	2023-10-31 14:17:59	创建用户	jgy
来源数据集	/MNIST_pytorch	描述	

关闭

版本删除

普通用户可以对发布状态、未发布状态和失效状态的数据集版本进行删除，不能对共享给自己的其他人创建的数据集版本删除。已发布的数据集版本删除为逻辑删除，底层和数据库保留信息，只是将该版本标记为删除状态，便于其他模块（如开发环境、训练任务等）使用该数据集版本时能够追溯到使用的文件。单击操作栏的操作按钮执行删除操作。

名称	数据类型	导入数据路径	存储名称	状态	创建时间	描述	创建用户	操作
dataset-2rrs	图片	/MNIST_pytorch	master	正常	2023-10-31 14:17:59		jgy	创建版本 删除
版本	数据类型	处理方式	发布状态	描述	创建用户	操作		
V001	图片	修改数据	个人		jgy	版本视图 删除		
V002	图片	修改数据	未发布		jgy	发布 编辑 删除		
dataset-8dks	文本	/defaultShare/auto_test_user	master	正常	2023-10-31 13:31:51		jgy11	创建版本

数据集删除

单击数据集操作栏的删除按钮进行数据集删除，该操作会将数据集下的所有版本永久删除，无法恢复。

确认

该数据集下所有版本永久删除。

取消 确定

文件列表展示

单击版本名称，展示该版本下所有的文件列表。

上一级 当前路径 /dataset-Zrns/V001

☐	名称	类型	大小	创建时间
☐	cifar10_test_imgdb	文件夹	-	2023-10-31 14:23:52
☐	MNIST	文件夹	-	2019-12-04 18:35:20
☐	processed	文件夹	-	2019-12-04 18:29:40

文件查看

可以查看普通文件、图片 (支持 png、jpeg、jpg、bmp 格式)、音频文件 (支持 mp3、wav、flac 格式)、视频文件 (支持 mp4、avi、flv、mov)。支持查看 50M 以下的普通文件和图片，默认支持查看 50M 以下的音频，默认支持查看 100M 以下的视频。

发布数据集使用

发布数据集（状态为个人，组和全局）只支持节点缓存，不支持更新。以开发环境为例，进行说明。选择数据时，选择数据集管理，弹出所有数据集列表，展开可以显示所有已发布的版本，只能选择其中的一个版本，单击确定。

数据配置

数据

文件管理

数据集管理

+ 选择数据

名称

搜索

	名称	数据类型	导入数据路径	存储名称	状态	创建时间	描述	创建用户
▼	dataset-jaj6	图片	/defaultShare/user-data	master	● 正常	2024-05-29 08:54:34	-	jgy
	版本	数据类型	处理方式	发布状态	描述	创建用户		
	V001	图片	修改数据	● 个人	-	jgy		

选择列

共 1 条 50条/页

<

1

>

前往

1

页

取消

确定

传输列表操作

- 1. 进入传输列表的操作包括：创建版本、导入和删除。同一用户同一操作只有一个在处理，其余需要排队。
- 2. 传输列表可以进行查看、删除、关闭等操作。

数据处理

单击列表右上方“数据处理”按钮，可以创建一个数据处理任务。需要填写以下信息：

名称	说明
任务名称	任务的名称，必填参数，只接受英文字母、数字和下划线，不能以下划线开头
镜像	运行任务的镜像，必填参数
运行	运行模式，脚本模式或命令模式二选一，必填参数，脚本模式下只能选择 py 脚本
资源组	运行任务所需的资源组，必填参数
集群网络类型	运行任务所需的集群网络类型，必填参数
数据	数据处理任务所选的数据，非必填，选择的数据只能以挂载的方式直接使用

提交完成后，跳转到任务管理，列表中有任务类型为数据处理任务的数据。

☐	任务名称	状态	运行时长	节点	资源配置	框架	启动内容	部署类型	镜像	任务类型	提交...	紧急任务	操作
☐	20230525163902	排队中 0	-	:	worker*1: Cards:0, CP U:1, MEM:0 GB	pytorch	/zyh/zyh1/tes	单机	8:5000/pyt orch/pytor ch21.10-p v3	数据处理任务	2023-05-25 16:53:57	否	可视化 重新提交 删除

数据下载

“数据下载”，在业务范围是训练 + 推理、训练下可用

创建数据下载任务

单击“数据下载 > 创建”，可以创建数据下载任务，需要填写详细信息如下：

字段名称	字段说明	字段填写注意事项
任务名称	创建数据下载任务名称	必填项，可以修改
下载方式	下载方式可以选择 http(s)、ftp/sftp、git clone	必选项

字段名称	字段说明	字段填写注意事项
下载链接	填写需要下载的连接	必填项，其中 http(s) 和 ftp/sftp 两种方式支持多个，每个链接换行填写，git clone 只能填写一个
用户名	访问下载链接的用户名	非必填项，仅支持 ftp/sftp 下载方式
密码	访问下载链接的密码	非必填项，仅支持 ftp/sftp 下载方式
保存路径	下载链接保存的路径	必选项，可以选择文件管理中家目录和公共目录
环境变量	访问下载链接的环境变量	非必填项

任务名称 *

20240511090255

下载方式 *

http(s)

ftp/sftp

git clone

下载链接 *

可以输入多个链接，最多10个，每个链接占一行

! 下载链接确保可以在集群中可以正常访问

当前方式暂不支持下载目录

用户名

密码

保存路径 *

环境变量

+ 添加环境变量

批量添加

其中任务名称自己填写修改可以重名，下载方式只能选择其中一种，下载方式选择 http(s) 和 ftp/sftp，下载链接若填写多个，每个需换行填写，最多支持填写 10 个，下载方式选择 git clone，下载链接只能填写一个。

保存路径支持多存储，可以选择不同的文件存储的用家目录。

每个用户默认只能创建 10 个下载任务。

数据下载任务列表

用户可以查看自己创建的数据下载任务列表，下载任务列表字段包含：任务名称、下载方式、文件名、状态、节点、下载进度、下载速度、剩余时长、保存路径、创建时间、日志、操作（删除）。支持按照任务名称模糊搜索，按照状态（排队、下载准备、下载中、暂停）精确搜索。

用户可以单击表头下载方式、状态、创建时间升序或降序排序，单击查看日志可以查看正在下载中的任务日志。

其中下载方式为 git clone 没有下载速度和剩余时长信息。

数据下载

终结任务

任务名称

状态

请选择

搜索

创建

启动

停止

删除

☐	任务名称	下载方式	文件名	状态	节点	下载进度	下载速度	剩余时长	保存路径	创建时间	日志	操作
☐	20240511091151	ftp/ftp	Storage_Scale_Erase_Code-5.1.9.2-x86_64-Linux-install	✖ 暂停	node1	1.59%	0B/te/s	-	/jgy2	2024-05-11 09:15:07	查看日志	删除 启动

0

选择列

当前选中 0 条

共 1 条

50条/页

<

1

>

前往

1

用户可以在终结任务中查看自己已完成的数据下载任务列表，终结任务中任务状态都是完成或失败。终结任务列表默认字段包含：任务名称、下载方式、文件名、状态、节点、下载进度、保存路径、创建时间。用户可以单击表头下载方式、状态、创建时间升序或降序排序。

终结任务列表中失败的下载任务包含失败原因。

数据下载状态信息如下表:

状态	说明
排队	创建完数据下载，状态为排队，该阶段底层在创建下载服务
下载准备	底层创建下载服务正常后，该阶段变成下载准备，表示正在启动下载服务，下载方式为 git clone 没有该状态
下载中	该阶段表示下载链接在下载中，任务状态这时就包含下载进度、下载速度等信息
暂停	该阶段表示下载任务暂停，下载方式为 git clone 没有该状态
完成	该状态表示下载任务完成，在终结任务列表中
失败	该状态表示下载任务失败，在终结任务列表中

数据下载任务详情

用户可以在数据下载和终结任务列表单击任务名称查看任务详情，任务详情包含具体详细的链接下载信息，详情中每个链接信息包含：下载链接、文件名、文件大小、状态、下载进度、下载速度、剩余时长。

详情信息

任务名称 20240511091151

下载方式 ftp/sftp

保存路径 /jgy2

拥有者 jgy2

创建时间 2024-05-11 09:15:07

下载链接 sftp://:22/root/jgy/Storage_Scale_Erasure_Code-5.1.9.2-x86_64-Linux-install 

文件名 Storage_Scale_Erasure_Code-5.1.9.2-x86_64-Linux-install20240511091528

文件大小 1.02 GB

状态 暂停

下载进度 1.59%

下载速度 0Byte/s

剩余时长 -

详情中下载方式为 git clone 没有文件大小、下载速度、剩余时长信息。

数据下载任务暂停

用户可以选择正在下载的数据下载任务，进行暂停，支持批量暂停。数据下载任务暂停仅支持下载方式为 http(s) 和 ftp/sftp 两种，git clone 下载方式不支持暂停。

用户选择正在下载的数据下载任务，单击右上角的“停止”按钮，当前数据下载任务状态将从下载中变成暂停状态。

数据下载

终结任务

任务名称

状态

请选择

搜索

创建

启动

修正

删除

任务名称	下载方式	文件名	状态	节点	下载进度	下载速度	剩余时长	保存路径	创建时间	日志	操作
20240511091151	ftp/sftp	Storage_Scale_Erasure_Code-5.1.9.2-x86_64-Linux-install	下载中	node1	1.59%	0Byte/s	More than 1 day	/jgy2	2024-05-11 09:15:07	查看日志	删除 停止

选择列

当前选中 1 条

共 1 条

50条/页

1

前往

1

页

数据下载任务启动

用户可以选择状态为暂停的数据下载任务，进行启动继续，支持批量启动继续。数据下载任务启动继续仅支持下载方式为 http(s) 和 ftp/sftp 两种，git clone 下载方式不支持启动继续。

用户选择状态为暂停的数据下载任务，单击右上角的“启动”按钮，当前数据下载任务状态将从暂停变成下载中状态。

数据下载

终结任务

任务名称

状态

请选择

搜索

创建

启动

停止

删除

任务名称	下载方式	文件名	状态	节点	下载进度	下载速度	剩余时长	保存路径	创建时间	日志	操作
20240511091151	ftp/sftp	Storage_Scale_Erasure_Code-5.1.9.2-x86_64-Linux-install	暂停	node1	15.64%	0Byte/s	-	/jgy2	2024-05-11 09:15:07	查看日志	删除 启动

选择列

当前选中 1 条

共 1 条

50条/页

1

前往

1

页

数据下载任务删除

用户可以选择自己创建的数据下载任务进行删除，可以选择自己任何状态（排队、下载准备、下载中、暂停、完成、失败）的数据下载进行删除，支持批量删除。

用户可以对数据下载和终结任务中数据下载任务进行删除，选择要删除的任务单击右上角的“删除”按钮，也可以在数据下载列表选择操作一列下的“删除”按钮进行删除。

数据下载

终结任务

任务名称

状态

请选择

搜索

创建

启动

停止

删除

任务名称	下载方式	文件名	状态	节点	下载进度	下载速度	剩余时长	保存路径	创建时间	日志	操作
20240511091151	ftp/sftp	Storage_Scale_Erasure_Code-5.1.9.2-x86_64-Linux-install	暂停	node1	15.64%	0Byte/s	-	/jgy2	2024-05-11 09:15:07	查看日志	删除 启动

选择列

当前选中 1 条

共 1 条

50条/页

1

前往

1

页


镜像管理

“镜像管理”，在业务范围是训练 + 推理、训练下可用

镜像查询

单击“镜像管理”，默认显示全部框架镜像，用户可查看公共、组内及个人的镜像。

用户可以查看用户可用、用户已用等信息。



镜像列表信息，主要包括：框架名称、镜像名称、分享属性、镜像大小、使用次数、最近使用时间、镜像tag、上传者、创建时间、备注等。功能包含：共享、删除、导出镜像、修改镜像、修改 Logo。

可以按照镜像框架类型查询，选择一个镜像框架（LLM、Caffe、TensorFlow、MxNet、PyTorch、PaddlePaddle、Other），显示框架的镜像列表信息。

可以按照分享属性查询，选择一种分享属性（个人、组、公共），显示分享属性的镜像列表信息。选择个人属性：显示个人的镜像，选择组属性：显示组镜像，选择公共：显示公共镜像。

可以按照最近使用时间或镜像大小排序，默认降序排列。

可以进行模糊查询，模糊输入框输入上传者、镜像名称、镜像tag相关信息，显示模糊搜索的镜像信息。

镜像列表支持分页展示。

镜像分享



个人和组镜像上有共享按钮，用户可以单击该按钮，修改镜像的分享属性。
可以修改个人的镜像属性，即用户可以把个人修改为组或公共属性。

取消分享



组和公共分类下能看到自己分享的镜像，单击镜像的取消分享按钮，可以撤销自己分享的镜像，重新变成个人镜像。

镜像删除

可以删除个人镜像，不能删除组内和公共镜像。

单击镜像删除按钮，弹出确认信息，单击确认，删除该镜像。

传输列表，显示镜像进度信息。进度的状态有排队、执行中、成功和失败。进度列表可以查看删除日志。支持单条或者批量删除状态为成功和失败的记录。

删除

☐	镜像名称	导出名称	状态	异常原因	操作类型	进度	排队位置	创建时间	完成时间	操作
☐	 tensorflow-a...	-	成功	-	删除镜像	100%	-	2022-1...	2022-1...	删除 查看日志
☐	 tensorflow-a...	-	成功	-	内部镜...	100%	-	2022-1...	2022-1...	删除 查看日志
☐	 tensorflow-a...	tensorflow-a...	成功	-	导出镜像	100%	-	2022-1...	2022-1...	删除 查看日志

导出镜像



tensorflow-a...
2023-12-04
tensorflow/tensorfl...

组 6.4GB 0次

21.10-tf1-py3

最近使用时间: 2023-12-04 11:13:36

上传者: xlx

备注:





tensorflow-a...
2023-11-22
tensorflow/tensorfl...

公共 6.4GB 26次

21.10-tf1-py3

最近使用时间: 2023-12-04 10:14:49

上传者: admin

备注:





caffe-admin
2023-11-22
caffe/caffe-admin

公共 2.0GB 20次

19.06-py2

最近使用时间: 2023-11-30 09:43:21

上传者: admin

备注:



单击导出镜像图标，显示导出镜像界面，默认给出 tar 包名称，用户可自定义修改。

“传输列表”，显示导出镜像进度信息，进度的状态有排队、执行中、成功和失败。“查看日志”查看导出镜像日志记录。如果出现异常，进度列表会显示异常原因。支持单条或者批量删除状态为成功和失败的进度。

删除

☐	镜像名称	导出名称	状态	异常原因	操作类型	进度	排队位置	创建时间	完成时间	操作
☐	 tensorflow-a...	tensorflow-a...	执行中	-	导出镜像	50%	-	2022-1...	-	删除 查看日志

导出成功后，可在“文件管理 > 用户目录”，查看导出的镜像 tar 包。

生成懒加载镜像



平台开启懒加载镜像功能后，镜像列表中非懒加载镜像支持生成功能，单击生成懒加载镜像图标，显示生成懒加载镜像界面，选择生成懒加载镜像的计算节点，点击确认生成懒加载镜像。

“传输列表”，显示懒加载镜像生成进度信息，进度的状态有排队、执行中、成功和失败。“查看日志”查看懒加载镜像生成日志记录。如果出现异常，进度列表会显示异常原因。支持单条或者批量删除状态为成功和失败的进度。

传输列表

×

删除

☐	镜像名称	导出名称	状态	异常原因	操作类型	进度	排队位置	创建时间	操作
☐	100.2.44.28:5000/pytorch/pytorch-admin-xlz	-	执行中	-	懒加载镜像生成	5%	-	2024-05-14 19:26:35	删除 查看日志
☐	100.2.44.28:5000/mxnet/mxnet-admin-xlz	-	成功	-	懒加载镜像生成	100%	-	2024-05-06 17:18:10	删除 查看日志
☐	100.2.44.28:5000/llm/pytorch-admin-xlz	-	成功	-	懒加载镜像生成	100%	-	2024-05-06 16:53:13	删除 查看日志

懒加载镜像生成成功后，可在镜像列表中查看新生成的懒加载镜像。

创建镜像

Dockerfile 创建镜像，单击“**镜像管理 > 创建**”，弹出创建界面，单击文件夹图标, 弹出选择 Dockerfile 界面，选择 Dockerfile 文件，或者在搜索栏搜索 Dockerfile 文件，选择搜索的 Dockerfile 文件，单击“**确定**”。

选择完 Dockerfile 文件，返回创建界面，显示 Dockerfile 文件的相对路径，输入镜像名称，镜像标签，备注信息，单击“**确定**”。

“注意事项”：镜像名称和标签不支持大写，镜像名称和标签需要满足 Docker 官方规范。

创建

Dockerfile *

/ldap_user_1/docker-file/Dockerfile

建议尽量将Dockerfile放在空目录中或者当前目录下只包含用于Dockerfile制作镜像的文件/文件夹

镜像名称 *

ubuntu

镜像类型 *

Other

标签 *

v3

备注

0/200

单击“**传输列表**”，显示创建镜像进度信息。进度的状态有排队、执行中、成功和失败。“查看日志”查看创建镜像的日志记录。支持单条或者批量删除状态为成功和失败的进度。

日志界面显示日志记录信息。如果 Dockerfile 编写有问题，日志页面会输出异常信息，进度条会显示异常原因，同时后台回滚删除相关操作记录，进度状态置为失败。

删除

☐	镜像名称	导出名称	状态	异常原因	操作类型	进度	排队位置	创建时间	完成时间	操作
☐	100.2.4...	-	成功	-	Docker...	100%	-	2022-1...	2022-1...	删除 查看日志

内部导入镜像

单击“**镜像管理 > 导入**”，显示导入界面。

默认选择内部导入，单击文件夹图标，弹出选择镜像文件界面，默认进入 nfs 挂载目录，可以选择镜像 tar、tar.gz 包，内部导入只能导入 docker save 保存的镜像包。选择镜像 tar 包，或者搜索 tar 包后，单击“**确定**”。

选择 tar 包后，输入镜像名称、镜像标签或备注信息，单击“**确定**”。

“注意事项”：镜像名称和标签不支持大写，镜像名称和标签需要满足 Docker 官方规范。

导入

导入方式*

内部导入?

外部导入?

选择镜像文件*

/ldap_user_1/5000_other_ubuntu-jupyter-admin_v2.tar

镜像名称*

ubuntu-jupyter

镜像类型*

Other

标签*

v6

备注

0/200

单击“**传输列表**”，显示内部导入镜像进度信息。进度的状态有排队、执行中、成功和失败。“查看日志”查看内部导入镜像日志记录。如果出现异常，进度列表会显示异常原因。支持单条或者批量删除状态为成功和失败的进度。

删除

☐	镜像名称	导出名称	状态	异常原因	操作类型	进度	排队位置	创建时间	完成时间	操作
☐	100.2.4...	-	执行中	-	内部镜...	40%	-	2022-1...	-	删除 查看日志

外部镜像导入

单击“**外部导入**”，“**下载命令**”可以手动输入 docker pull 镜像命令，也可以从配置的外部 harbor 仓库、Docker Hub 或者 NGC 官方网站复制 pull 镜像命令。如果勾选配置的外部 harbor 仓库，则需要输入镜像名称。

导入

导入方式 *

☐ 内部导入 ?

☒ 外部导入 ?

下载命令 *

docker pull [REDACTED]0/other/ubuntu-python-openssh-jupyterlab:la

镜像类型 *

Other

备注

0/200

DockerHub

https://hub.docker.com

NGC

https://ngc.nvidia.com

☐

Harbor

[REDACTED]

☐

“**传输列表**”显示外部导入镜像进度信息，进度的状态有排队、执行中、成功和失败。“查看日志”查看外部导入镜像日志记录，如果导入失败，进度条会显示异常原因。支持单条或者批量删除状态为成功和失败的进度。

“**注意事项**”：外部导入，需要连接外网，拉取的镜像源最好是国内镜像源，如果是国外源，可能会有限制，导致 pull 过程缓慢，需要花费很长时间，严重时，会出现 pull 失败现象。

删除

☐	镜像名称	导出名称	状态	异常原因	操作类型	进度	排队位置	创建时间	完成时间	操作
☐	100.2.4...	-	执行中	-	外部镜...	60%	-	2022-1...	-	删除 查看日志

修改镜像

单击“**修改镜像**”图标，可以修改镜像备注。



修改镜像 Logo

单击“修改 Logo”图标，可以自定义单个镜像的 Logo，用户只能修改自己镜像的 Logo。

修改Logo

other

选择图片

other类型镜像Logo, 建议最大像素1488px * 1786px, 最大1M, 支持png/jpg/gif格式。

修改完成后，可在“镜像管理”界面查看。

镜像发布

“镜像发布”，在业务范围是训练 + 推理下可用

单击“镜像管理 > 镜像发布”图标，填写应用名称（格式要求：只接受小写字母、数字和中划线，且以小写字母开头，不能以中划线结尾），可以将该镜像发布至应用商店中，发布完成后可在“应用商店”界面查看。



应用商店

“应用商店”，在业务范围是训练 + 推理、推理下可用

应用列表

单击“应用商店”，查看所有应用，包括系统内置以及用户导入的应用，每个分类旁边都有数量统计；系统内置的应用一共有 4 类，包括：元脑应用、NGC 应用、源应用、INAIS 应用；用户导入的应用都在“自定义应用”的分类中。每个应用页签展示的信息包括：应用图标、应用名称、应用分类、应用标签（支持自定义）、应用权限（个人、用户组、集群）、部署方式（模型方式、共享存储模型、镜像方式、helm 方式）、更新时间以及描述，操作按钮（只有自定义应用展示）包括：应用详情、设置应用权限、转移所有权、删除按钮。应用列表过滤条件支持应用标签、部署方式、名称进行过滤查询。



名称	说明
应用标签	下拉列表，显示所有已有标签
部署方式	下拉列表，有模型方式、共享存储模型、镜像方式、helm 方式四种取值
名称	应用名称

应用导入

模型应用的导入

单击“应用商店 > 导入应用”，进入导入应用的页面，填写信息如下：填写应用名称；部署方式选择模型方式，可以添加模型，填写模型名称，选择模型文件，选择模型框架类型，模型文件可以添加多个，单次上传模型的数量不超过 10 个；选择应用图标（非必选，不选择的话，会有默认的图标）；默认的应用分类是“自定义应用”；应用标签可以选择集群已有的标签也可以自定义标签；添加应用描述；单击“确定”即可。

导入应用

应用名称 *

zzm

部署方式 *

模型方式

共享存储模型

镜像方式

helm方式

添加模型

名称

jkk

cifar10.tar

📁

pytorch

🗑

+

应用图标

点击选择图片

仅支持jpg、png格式，且大小不超过20KB

📁 11.png

应用分类 *

自定义应用

应用标签 *

ocr

描述

1

1 / 256

取消

确定

名称	说明
应用名称	应用的名称，格式要求：只接受小写字母、数字和中划线，且以小写字母开头，不能以中划线结尾
部署方式	模型方式
添加模型	模型名称，格式要求：只接受英文字母、数字、点和下划线，开头和末尾为字母或数字；模型文件，格式要求：仅支持.tar 格式的文件，且大小不超过 20GB；模型框架类型，下拉列表，有 pytorch、tensorflow、triton、onnx、tvm 五种取值
应用图标	选择的图片文件要求：仅支持 jpg、png 格式，且大小不超过 20KB
应用分类	默认自定义应用，不可修改
应用标签	下拉列表，可选择已有标签，也可自定义标签，格式要求：最多 12 个字符，只接受小写字母、数字和中划线，且以小写字母开头，不能以中划线结尾
描述	应用的描述，格式要求：最多 256 个字符

注：上传的模型包需满足此要求，即此模型所有的相关文件放置在一个文件夹中再对文件夹进行相应的操作（打包或者打包压缩）。

共享存储模型应用导入

单击“应用商店 > 导入应用”，进入导入应用的页面，填写信息如下：填写应用名称；部署方式选择共享存储模型，首先需要获取对接训练平台的 token，输入 token 单击校验，若 token 无误，校验成功自动回显模型名称、大小、创建时间信息，手动选择模型框架类型和场景（场景可以多选，此处需保证所有场景均已加入 model 存储类且资源充足）；选择应用图标（非必选，不选择的话，会有默认的图标）；默认的应用分类是“自定义应用”；应用标签可以选择集群已有的标签也可以自定义标签；添加应用描述；单击“确定”即可。

导入应用

请先输入token进行校验

token *

32f16a8d7371490297903fe65a1c0014

校验

应用名称 *

ssm1

部署方式 *

模型方式

共享存储模型

镜像方式

helm方式

上传训练模型

模型名称 *

zzz

模型大小 *

232194

创建时间 *

2023-11-08 16:49:50

模型类型 *

pytorch

场景 *

zz X

应用图标

点击选择图片

仅支持jpg、png格式，且大小不超过20KB

11.png

应用分类 *

自定义应用

应用标签 *

ocr

描述

1

1 / 256

取消

确定

名称	说明
token	对接训练平台的模型 token
应用名称	应用的名称，格式要求：只接受小写字母、数字和中划线，且以小写字母开头，不能以中划线结尾
部署方式	共享存储模型
上传训练模型	模型名称、模型大小、创建时间；模型框架类型，下拉列表，有 pytorch、tensorflow、triton、onnx、tvm 五种取值；场景，下拉列表，显示为当前用户可使用的场景列表，可多选
应用图标	选择的图片文件要求：仅支持 jpg、png 格式，且大小不超过 20KB
应用分类	默认自定义应用，不可修改

名称	说明
应用标签	下拉列表，可选择已有标签，也可自定义标签，格式要求：最多 12 个字符，只接受小写字母、数字和中划线，且以小写字母开头，不能以中划线结尾
描述	应用的描述，格式要求：最多 256 个字符

镜像应用导入

单击“应用商店 > 导入应用”，进入导入应用的页面，填写信息如下：填写应用名称；部署方式选择镜像方式，可以添加镜像，填写镜像名称，选择镜像文件，镜像文件可以添加多个，单次上传镜像的数量不超过 10 个；选择应用图标（非必选，不选择的话，会有默认的图标）；默认的应用分类是“自定义应用”；应用标签可以选择集群已有的标签也可以自定义标签；添加应用描述；单击“确定”即可。

导入应用

应用名称 *

zzi

部署方式 *

模型方式

共享存储模型

镜像方式

helm方式

添加镜像

名称

qq:1

addone.tar

📁

🔗

构建

🗑

+

应用图标

点击选择图片

仅支持jpg、png格式，且大小不超过20KB

🖼

11.png

应用分类 *

自定义应用

应用标签 *

ocr

描述

1

1 / 256

取消

确定

名称	说明
应用名称	应用的名称，格式要求：只接受小写字母、数字和中划线，且以小写字母开头，不能以中划线结尾
部署方式	镜像方式

版权所有 © 浪潮电子信息产业股份有限公司

212

名称	说明
添加镜像	镜像名称，格式要求：名称:Tag，名称以小写字母、数字开头或结尾，Tag 以大小写字母、数字开头或结尾，均支持”_.”且”_.”不可相邻；镜像文件，格式要求：仅支持.tar 格式的文件，且大小不超过 20GB
应用图标	选择的图片文件要求：仅支持 jpg、png 格式，且大小不超过 20KB
应用分类	默认自定义应用，不可修改
应用标签	下拉列表，可选择已有标签，也可自定义标签，格式要求：最多 12 个字符，只接受小写字母、数字和中划线，且以小写字母开头，不能以中划线结尾
描述	应用的描述，格式要求：最多 256 个字符

helm 应用导入

单击“**应用商店 > 导入应用**”，进入导入应用的页面，填写信息如下：填写应用名称；部署方式选择 helm 方式，需要添加模板和添加镜像，模板是 helm 的标准模板，模板可以添加多个；可以添加镜像，填写镜像名称，选择镜像文件，镜像文件可以添加多个，单次上传镜像的数量不超过 10 个；选择应用图标（非必选，不选择的话，会有默认的图标）；默认的应用分类是“自定义应用”；应用标签可以选择集群已有的标签也可以自定义标签；添加应用描述；单击“确定”即可。

导入应用

应用名称 *

zzh

部署方式 *

模型方式

共享存储模型

镜像方式

helm方式

添加模板 *

点击选择文件

仅支持tgz格式文件，上传文件支持选择多个

ocr-cpu-1.1.0.tgz

添加镜像

名称

aa:1

addone.tar

📁

🔒

构建

🗑

+

应用图标

点击选择图片

仅支持jpg、png格式，且大小不超过20KB

11.png

应用分类 *

自定义应用

应用标签 *

ocr

描述

0 / 256

取消

确定


名称	说明
应用名称	应用的名称，格式要求：只接受小写字母、数字和中划线，且以小写字母开头，不能以中划线结尾
部署方式	helm 方式
添加模板	helm 文件，格式要求：仅支持 tgz 格式文件，上传文件支持选择多个
添加镜像	镜像名称，格式要求：名称:Tag，名称以小写字母、数字开头或结尾，Tag 以大小写字母、数字开头或结尾，均支持”_.”且”_.”不可相邻；镜像文件，格式要求：仅支持.tar 格式的文件，且大小不超过 20GB
应用图标	选择的图片文件要求：仅支持 jpg、png 格式，且大小不超过 20KB
应用分类	默认自定义应用，不可修改

名称	说明
应用标签	下拉列表，可选择已有标签，也可自定义标签，格式要求：最多 12 个字符，只接受小写字母、数字和中划线，且以小写字母开头，不能以中划线结尾
描述	应用的描述，格式要求：最多 256 个字符

应用详情

模型应用详情

单击“应用商店 > 模型应用”，进入应用详情页面。展示的信息包括：应用的图标、应用名称、应用状态、应用分类、应用标签、部署方式、应用大小（应用下所有模型大小的总计）、应用权限（个人、用户组、集群，个人仅对自己可见，用户组是用户组下所有成员都可见，集群是集群中所有用户都可见）、所属用户、创建时间、在使用用户、描述、模型数量。操作包括：编辑（修改应用图标、应用分类以及描述）、设置应用权限、转移所有权、应用删除按钮、导入模型、传输列表。“详细信息”页签展示的内容是模型的信息，选择不同的模型，可以将指定模型导出，导出后可下载或删除模型文件；选择不同的模型，根据选择的模型展示对应模型的应用配置。



单击“模型数量”，展示模型悬浮列表，此列表包含该应用下所有模型的相关信息，包含模型名称、地址、类型、大小、更新时间，校验（校验功能校验的是模型是否匹配选择的模型框架）、操作（删除）。

模型名称	模型地址	模型类型	模型大小	更新时间	校验	操作
jkk	hdfs://1_jkk_1	pytorch	232.19KB	2023-11-15 16:57:55	校验通过	删除

名称	说明
模型名称	模型名称
模型地址	模型地址
模型类型	模型框架类型
模型大小	模型大小
更新时间	模型更新时间
校验	校验功能校验的是模型是否匹配选择的模型框架，单击校验后，校验结果：校验中，校验通过，校验不通过，校验失败
操作	单个模型删除

应用配置支持修改，修改内容包括：CPU（核心）、内存（GB）、QPS、请求方式和端口号（请求方式和端口号可设置多组，最多为 10 组）。

编辑应用配置

CPU（核心） *

2

内存（GB） *

4

QPS *

1

请求方式

http

▼

端口

8080

🗑

+


取消

确定

名称	说明
CPU（核心）	格式要求：只能输入数字，小数最多 3 位
内存（GB）	格式要求：只能输入数字，小数最多 3 位
QPS	格式要求：必须为整数
请求方式	默认 http，下拉列表，http、https、grpc、tcp
端口	默认 8080，格式要求：端口不符合规范，端口范围 1-65535

共享存储模型应用详情

单击“应用商店 > 共享存储模型应用”，进入应用详情页面。展示的信息包括：应用的图标、应用名称、应用状态、应用分类、应用标签、部署方式、应用大小（应用下所有模型大小的总计）、应用权限（个人，个人仅对自己可见）、所属用户、创建时间、在使用用户、描述、模型数量；操作包括：编辑（修改应用图标、应用分类以及描述）、应用删除按钮、导入模型、传输列表。“详细信息”页签展示的内容是模型的信息，选择不同的模型，根据选择的模型展示对应模型的应用配置。



单击“模型数量”，展示模型悬浮列表，此列表包含该应用下所有模型的相关信息，包含模型名称、地址、类型、大小、更新时间以及操作。

模型名称	场景pvc地址	模型类型	模型大小	更新时间	操作
zzz	zzjpruqpavuu	pytorch	226.75KB	2023-11-09 00:49:50	删除

名称	说明
模型名称	模型名称
模型地址	模型地址
模型类型	模型框架类型
模型大小	模型大小
更新时间	模型更新时间
操作	单个模型删除

应用配置支持修改，修改内容包括：CPU（核心）、内存（GB）、QPS、请求方式和端口号（请求方式和端口号可设置多组，最多为 10 组）。

编辑应用配置

CPU（核心） *

2

内存（GB） *

4

QPS *

1

请求方式

http

▼

端口

8080

🗑

+


取消

确定

名称	说明
CPU（核心）	格式要求：只能输入数字，小数最多 3 位
内存（GB）	格式要求：只能输入数字，小数最多 3 位
QPS	格式要求：必须为整数
请求方式	默认 http，下拉列表，http、https、grpc、tcp
端口	默认 8080，格式要求：端口不符合规范，端口范围 1-65535

镜像应用详情

单击“应用商店 > 镜像应用”，进入应用详情页面。展示的信息包括：应用的图标、应用名称、应用状态、应用分类、应用标签、部署方式、应用大小（应用下所有镜像大小的总计）、应用权限（个人、用户组、集群，个人仅对自己可见，用户组是用户组下所有成员都可见，集群是集群中所有用户都可见）、所属用户、创建时间、在使用用户、描述、应用分发的状态、镜像数量；操作包括：编辑（修改应用图标、应用分类以及描述）、设置应用权限、转移所有权、应用删除按钮、导入镜像、传输列表。“详细信息”页签展示的内容是镜像的信息，可以选择不同的镜像，根据选择的镜像展示的信息包括应用配置、工作路径、环境变量、以及命令。



单击应用分发-“未分发”，创建分发任务，单击“确定”即可。分发之后展示的信息包括：镜像名称、分发状态、更新时间、分发方式、分发节点数。

查看分发状态

镜像名称	分发状态	更新时间	分发方式	分发节点数
qq:1-176	已分发	2023-11-15 11:28:28	定向	1

关闭

单击“镜像数量”，展示镜像悬浮列表，此列表包含该应用下所有镜像的相关信息，包含镜像名称、仓库地址、镜像大小、更新时间以及操作。



名称	说明
镜像名称	镜像名称
仓库地址	镜像仓库地址
镜像大小	镜像大小
更新时间	镜像更新时间

名称	说明
操作	单个镜像删除

应用配置支持修改，修改内容包括：CPU（核心）、内存（GB）、QPS、请求方式和端口号（请求方式和端口号可设置多组，最多为 10 组）。

编辑应用配置

CPU（核心） *

2

内存（GB） *

4

QPS *

1

请求方式

http

▼

端口

8080

🗑

+

取消

确定

名称	说明
CPU（核心）	格式要求：只能输入数字，小数最多 3 位
内存（GB）	格式要求：只能输入数字，小数最多 3 位
QPS	格式要求：必须为整数
请求方式	默认 http，下拉列表，http、https、grpc、tcp
端口	默认 8080，格式要求：端口不符合规范，端口范围 1-65535


漏洞扫描页签展示的信息是该应用下的镜像漏洞扫描的相关信息（系统需要管理员开通漏洞扫描功能并更新正确的漏洞扫描库），一键扫描功能可以扫描此应用下的所有镜像，可以查看扫描后的全部结果也可以根据镜像名称筛选结果。使用一键扫描功能扫描应用下所有镜像，避免在应用下存在多个相同镜像的情况。



注：使用一键扫描功能扫描应用下所有镜像，避免在应用下存在多个相同镜像的情况

helm 应用详情

单击“应用商店 > helm 应用”，进入应用详情页面。展示的信息包括：应用的图标、应用名称、应用状态、应用分类、应用标签、部署方式、应用大小（应用下所有镜像大小的总计）、应用权限（个人、用户组、集群，个人仅对自己可见，用户组是用户组下所有成员都可见，集群是集群中所有用户都可见）、所属用户、创建时间、在使用用户、描述、应用分发的状态、镜像数量；操作包括：编辑（修改应用图标、应用分类以及描述）、设置应用权限、转移所有权、部署按钮（只有 helm 部署方式的展示）、应用删除按钮、模板下载（只有 helm 部署方式的展示）、导入模板、导入镜像、传输列表。“详细信息”页签展示的内容是镜像的信息，可以选择不同的镜像，根据选择的镜像展示的信息包括应用配置、工作路径、环境变量、以及命令。



单击应用分发-“未分发”，创建分发任务，单击“确定”即可。分发之后展示的信息包括：镜像名称、分

发状态、更新时间、分发方式、分发节点数。

查看分发状态

镜像名称	分发状态	更新时间	分发方式	分发节点数
aa:1-169	已分发	2023-11-15 11:00:01	定向	1

关闭

单击“镜像数量”，展示镜像悬浮列表，此列表包含该应用下所有镜像的相关信息，包含镜像名称、仓库地址、镜像大小、更新时间以及操作。

应用分发：已分发 镜像数量：1 模板数量：1

镜像名称	仓库地址	镜像大小	更新时间	操作
aa:1-169	/mine/zzh/aa:1-169	10.67MB	2023-11-07 18:23:13	删除

名称	说明
镜像名称	镜像名称
仓库地址	镜像仓库地址
镜像大小	镜像大小
更新时间	镜像更新时间
操作	单个镜像删除

单击“模板数量”，展示镜像悬浮列表，此列表包含该应用下所有 helm 模板的相关信息，包含模板名称、版本、更新时间以及操作。

应用分发：已分发 镜像数量：1 模板数量：1

模板名称	版本	更新时间	操作
ocr-cpu-1.1.0	1.1.0	2023-11-07 18:23:10	删除

名称	说明
模板名称	helm 模板的名称
版本	helm 模板的版本
更新时间	更新时间
操作	删除

应用配置支持修改，修改内容包括：CPU（核心）、内存（GB）、QPS、请求方式和端口号（请求方式和端口号可设置多组，最多为 10 组）。

编辑应用配置

CPU（核心） *

2

内存（GB） *

4

QPS *

1

请求方式

http

端口

8080

+

取消

确定

名称	说明
CPU（核心）	格式要求：只能输入数字，小数最多 3 位
内存（GB）	格式要求：只能输入数字，小数最多 3 位
QPS	格式要求：必须为整数
请求方式	默认 http，下拉列表，http、https、grpc、tcp
端口	默认 8080，格式要求：端口不符合规范，端口范围 1-65535

“helm”模板页签展示的信息是多个不同版本的模板的信息，选择某一版本的模板之后, 可以模板下载，展示的信息包括：模板中的目录结构以及文件信息，单击文件可以查看文件内容、可以修改文件内容、可以新建文件或者文件夹、可以上传新的文件、可以对文件进行重命名、可以删除文件以及文件夹。

应用详情 < 应用概览

zzh 状态：未使用 分类：自定义应用 标签：ocr 部署方式：helm方式 应用大小：10.67MB 应用权限：个人 所属用户：zyx1 创建时间：2023-11-07 18:23:10 在使用用户：- 描述：-

应用分发：已分发 镜像数量：1 模板数量：1

helm模板

模板 ocr-cpu-1.1.0 模板下载

上一级

上传


文件名	文件类型	大小	修改时间
☐ helmignore	文件	348byte	2023-11-07 18:30:16
☐ Chart.yaml	文件	122byte	2023-11-07 18:30:16
☒ templates	文件夹	4096byte	2023-11-07 18:30:16
☐ values.yaml	文件	1894byte	2023-11-07 18:30:55

Chart.yaml

搜索/替换 撤回 复制 粘贴 剪切

```
apiVersion: v2
name: ocr-cpu-1.1.0
description: A Helm chart for Kubernetes
maintainers:
- name: zyxx
email: zyxx@163.com
version: 1.1.0
```

漏洞扫描页签展示的信息是该应用下的镜像漏洞扫描的相关信息（系统需要管理员开通漏洞扫描功能并更新正确的漏洞扫描库），一键扫描功能可以扫描此应用下的所有镜像，可以查看扫描后的全部结果也可以根据镜像名称筛选结果。使用一键扫描功能扫描应用下所有镜像，避免在应用下存在多个相同镜像的情况。



注：使用一键扫描功能扫描应用下所有镜像，避免在应用下存在多个相同镜像的情况

传输列表

单击“应用商店 > 传输列表”或者“应用商店 > 应用 > 传输列表”，查看传输列表，显示镜像或模型文件上传进度等信息。

名称	说明
名称	镜像名称或者模型名称
应用名称	镜像或模型所属的应用的名称
进度	镜像或模型文件的上传进度，百分比
上传类型	上传镜像或者上传模型
状态	成功或失败
失败原因	状态为失败的话显示失败原因
操作	操作

传输列表

删除

☐	名称	应用名称	进度	上传类型	状态	失败原因	操作
☐	qq:1	aaai	100%	上传镜像	成功		
☐	jkk1	aaam	100%	上传模型	成功		

共 2 条

10条/页

1

应用编辑

单击“应用商店 > 应用 > 编辑”，编辑应用的应用图标、应用标签和描述。

设置应用权限

单击“应用商店 > 应用 > 设置应用权限”，设置应用权限，目前应用权限支持三种：个人、用户组、集群，个人仅对自己可见，用户组是用户组下所有成员都可见，集群是集群中所有用户都可见，单击“提交”即可。应用权限只能升不能降，即可以从个人升级到用户组，但是不能从用户组降到个人。

设置应用权限范围

当前范围

个人

设定范围*

用户组

取消

确定

转移所有权

单击“应用商店 > 应用 > 转移所有权”，将应用转移给同组下具有推理权限的其他用户。

转移所属权

用户名*

zxy2

▼

取消

确定

应用删除

单击“应用商店 > 应用 > 删除”，将应用删除，若应用的在使用用户不为空，则不允许删除。

监控统计

监控告警

告警列表

告警列表模块提供在已配置告警项触发告警条件后，对产生的告警信息进行展示（记录、统计）和作的功能。普通用户登录平台，选择“告警管理 > 告警列表”，进入“告警列表”页面。

1. 可以查看告警信息列表，列表内容包括：节点名称、告警名称、告警类型（告警、恢复）、告警等级（一般告警、严重告警）、告警内容、告警资源、处理状态（待认领、处理中、已解决、已忽略）、告警时间、接收对象类型（角色、用户）、接收对象、告警指标趋势。
2. 支持按照以下搜索条件搜索数据：

告警列表

时间范围

请选择开始时间

请选择结束时间

告警等级

请选择

更多

搜索

导出文件

告警名称	告警类型	告警等级	告警内容	告警资源	处理状态	告警时间	接收对象类型	告警图标趋势	接收对象	操作
加速卡温度	故障	严重告警	Alert name:加速卡温度 Alert level:严重告警 Alert content:the server node1 Accelerator Card index0.uuid:MLU-01043009-2254-0000-0000-000000000000 加速卡温度 continue 1 seconds >= 40.0 °C	index0.uuid:MLU-01043009-2254-0000-0000-000000000000	待认领	2024-05-10 08:47:50	用户		admin	处理 解决 忽略
主机不可用	故障	严重告警	Alert name:主机不可用 Alert level:严重告警 Alert content:the server node1 urtnode2 abnormal status unavailable	urtnode2	待认领	2024-05-10 08:47:45	用户		admin	处理 解决 忽略
加速卡温度	故障	严重告警	Alert name:加速卡温度 Alert level:严重告警 Alert content:the server node1 Accelerator Card index1.uuid:MLU-01043009-2254-0000-0000-000000000001 加速卡温度 continue 1 seconds >= 40.0 °C	index1.uuid:MLU-01043009-2254-0000-0000-000000000001	待认领	2024-05-10 08:47:05	用户		admin	处理 解决 忽略
加速卡温度	故障	一般告警	Alert name:加速卡温度 Alert level:一般告警 Alert content:the server node4 Accelerator Card index0.uuid:GPU-7e8e1e96-c43a-30c7-d2c2-29137d317a6d 加速卡温度 continue 1 seconds >= 30.0 °C	index0.uuid:GPU-7e8e1e96-c43a-30c7-d2c2-29137d317a6d	待认领	2024-05-10 08:47:00	用户		admin	处理 解决 忽略
节点未准备好	故障	严重告警	Alert name:节点未准备好 Alert level:严重告警 Alert content:the server node1 cluster_node_name:node2 not ready	cluster_node_name:node 2	待认领	2024-05-10 08:46:55	用户		admin	处理 解决 忽略

选择列

当前选中 0 条

共 5 条

50条/页

1

前往

1

页

名称	说明
告警名称	下拉列表显示告警名称，根据告警名称精确搜索
告警类型	下拉精确搜索（告警、恢复）
告警等级	下拉精确搜索（一般告警、严重告警）
告警资源	模糊搜索
时间范围（精确到秒）	默认搜索时间为最近 10 分钟，页面刷新频率为 10s； 可自定义搜索时间范围，大于等于开始时间，小于截止时间，页面不自动刷新

3. 可以通过右上角“导出文件”按钮，将页面上搜索到的告警信息导出到 excel 文件中。

系统管理

资源管理

资源组

“资源管理 > 资源组”，在业务范围是训练 + 推理、训练、推理下可用

“资源组”，显示资源组列表，主要包括：名称、服务器节点数、CPU 核数、CPU-Limit、加速卡已用/总数、当前任务数、复用情况、标签、共享属性、状态、超时设置。

名称	服务器节点数	CPU核数	CPU-Limit	加速卡已用/...	当前任务数	复用情况	标签	共享属性	状态	超时设置
defaultGroup	0	0	-	0/0	0	-	通用	共享	-	关闭
defaultGroupInf	1	112	N/A	0/1	0	-	推理	N/A	-	N/A

选择列

当前选中 0 条

共 3 条

50条/页

<1>

前往

1

页

注意，推理资源组 defaultGroupInf 不支持 CPU-Limit、共享属性、超时设置字段，展示 N/A。

用户单击服务器节点数，显示节点列表，包括：节点名称、IP、CPU 核数、加速卡类型、加速卡数、内存、磁盘、配置状态、操作。

☐	节点名称	IP	CPU核数	加速卡类型	加速卡数	内存(GB)	磁盘(GB)	配置状态	操作
☐			128	70-...	2	377	8942	正常	重试

选择列

当前选中 0 条

共 1 条

50条/页

<1>

前往

1

页

节点管理

“资源管理 > 节点管理”，在业务范围是训练 + 推理、训练、推理下可用

“节点管理”，显示所属资源组节点列表，包括：节点名称、状态、计算状态、IP、型号、BMC 地址、CPU 核数、加速卡数、内存、网络类型、挂载路径、挂载开关、网络信息、交换机名称、docker 存储、所属资源组。

节点用途

请选择

搜索

☐	名称	节点用途	节点类型	状态	计算状态	IP	型号	BMC地址	CPU核数	加速卡数	内存(GI
☐	node1	训练	管理节点, 计算节点	● 在线	● 正常	10C	MLU370-X8	-	128	2	377
☐	node2	推理	计算节点	● 在线	N/A	100...	Tesla-V100-PCIE-1...	-	72	3	376

选择列

当前选中 0 条

共 2 条

50条/页

<1>

前往

1

页

注意，节点用途为推理的节点，不支持计算状态、挂载路径、挂载开关、网络信息字段，展示 N/A。

节点详情

“资源管理 > 节点管理 > 节点详情”，在业务范围是训练 + 推理、训练、推理下可用

单击“节点管理 > 节点名称”，显示节点详情，包括：数据、镜像、挂载信息、故障详情。

数据

“资源管理 > 节点管理 > 节点详情 > 数据”，在节点用途为训练下可用

数据列表显示缓存到节点的数据信息，主要包括：节点名称、IP、数据路径、数据大小、使用次数、使用状态、缓存时间、最近使用时间。使用状态有两种：未使用、已使用，表示该数据当前是否使用。缓存时间表示该数据下载的时间。最近使用时间表示最近一次使用的时间。

“删除数据”：可以删除节点的数据，只能删除未使用状态的数据，删除使用状态的数据，会提示删除失败。

数据 镜像 挂载信息 故障详情

删除

☐	节点名称	IP	数据路径	数据大小	使用次数	使用状态	缓存时间	最近使用时间
☐			/mnt/nodestor/.cache-data/defaultShare/user-data	940.2MB	1	未使用	2023-12-14 08:24:18	2023-12-14 08:25:43
☐			/mnt/nodestor/.cache-data/xlz11/user-data	940.2MB	1	未使用	2023-12-14 08:24:18	2023-12-14 08:25:43

镜像

“资源管理 > 节点管理 > 节点详情 > 镜像”，在节点用途为训练、推理下可用

显示节点本地镜像信息，主要包括：节点名称、IP、镜像名称、标签、大小、是否在用、上传者、创建时间、操作。

“删除镜像”：支持单个或批量删除镜像，只能删除未使用的镜像。

数据 镜像 挂载信息 故障详情

删除

☐	节点名称	IP	镜像名称	标签	大小	是否在用	上传者	创建时间	操作
☐	node1	100.2.44.28	000/inais/iresource-service	latest	869.2MB	已使用	admin	2023-12-07 20:16:24	删除
☐	node1	100.2.44.29	000/inais/idam-service	latest	766.2MB	已使用	admin	2023-12-07 18:00:16	删除
☐	node1	100.2.44.30	000/inais/istorage-service	latest	997.9MB	已使用	admin	2023-12-07 16:54:46	删除
☐	node1	100.2.44.29	000/inais/ivision	latest	181.1MB	已使用	admin	2023-12-07 16:15:35	删除

注意，节点用途为推理的节点，“是否在用”显示为 N/A。

挂载信息

“资源管理 > 节点管理 > 节点详情 > 挂载信息”，在节点用途为训练、推理下可用

显示节点的挂载信息，主要包括：节点名称、IP、挂载路径、文件系统类型、总容量、已使用、剩余。

数据 镜像 挂载信息 故障详情

节点名称	IP	挂载路径	文件系统类型	总容量	已使用	剩余
node1	100.2.44.28	/	ext4	1.72 TB	460.21 GB	1.18 TB
node1	100.2.44.29	/boot	ext4	1.90 GB	229.68 MB	1.56 GB
node1	100.2.44.30	/boot/efi	vfat	1.05 GB	6.07 MB	1.04 GB
node1	100.2.44.29	/gpfs	gpfs	411.51 TB	157.02 TB	254.49 TB
node1	100.2.44.28	/snap/core20/1822	squashfs	63.38 MB	63.38 MB	0 Byte

故障详情

“资源管理 > 节点管理 > 节点详情 > 故障详情”，在节点用途为训练下可用

显示节点的故障信息，主要包括：故障时间、故障类型、故障级别、详情、禁用容错截止时间。

数据 镜像 挂载信息 故障详情

故障时间	故障类型	故障级别	详情	禁用容错截止时间
2023-12-07 14:40:00	network	warning	'compute: mlx4_0:1; storage:'	-

选择列

共 1 条 50条/页 < 1 > 前往 1 页

设置

公告管理

用户登录系统，如果当前系统存在公告，则弹窗显示公告信息。

公告

XX平台升级

计划于2023年11月1日晚上10点，对XX平台进行系统升级，在此期间平台停止提供服务，暂停使用，大约2023年11月2日早8点恢复正常，请知悉！

1 / 1 快速跳过 上一条 下一条

单击“下一条”可以看下一个公告信息，单击“上一条”可以看上一个公告信息，单击“快速跳过”则关闭当前窗口，下次登录后仍旧弹窗显示未查看过的公告信息。单击当前弹窗右上角的“x”关闭按钮，同“快速跳过”按钮。

单击系统右上角的小喇叭按钮，可显示当前系统的公告列表。

1

中文 xunlian

全部公告 (1)

XX平台升级 24小时内

上一页 下一页

单击公告主题，可查看公告详情。

公告详情

主题

XX平台升级

内容

计划于2023年11月1日晚上10点，对XX平台进行系统升级，在此期间平台停止提供服务，暂停使用，大约2023年11月2日早8点恢复正常，请知悉！

有效时间

2023-11-13 12:00:00 ~ 2023-11-16 12:00:00

创建时间

2023-11-14 10:49:04

发布时间

2023-11-14 11:00:17

状态

发布

确定

消息中心

普通用户登录平台，单击“系统管理 > ”设置” > 消息中心”或者单击右上角的消息中心图标，打开消息中心页面

消息中心

未读

类型

请选择

更多

搜索

	类型	内容	状态	到达时间
☐	配额预警通知	用户【log】，【ALL-CPU】配额使用超过【5%】，请合理使用	未读	2024-05-07 17:00:02
☐	配额预警通知	用户【log】，【ALL-CPU】配额使用超过【5%】，请合理使用	未读	2024-05-07 16:55:00
☐	配额预警通知	用户【log】，【ALL-CPU】配额使用超过【5%】，请合理使用	未读	2024-05-07 16:50:01
☐	配额预警通知	用户【log】，【ALL-CPU】配额使用超过【5%】，请合理使用	未读	2024-05-07 16:45:07
☐	配额预警通知	用户【log】，【ALL-CPU】配额使用超过【5%】，请合理使用	未读	2024-05-07 16:40:01
☐	配额预警通知	用户【log】，【ALL-CPU】配额使用超过【5%】，请合理使用	未读	2024-05-07 16:35:00
☐	配额预警通知	用户【log】，【ALL-CPU】配额使用超过【5%】，请合理使用	未读	2024-05-07 16:25:08
☐	配额预警通知	用户【log】，【ALL-CPU】配额使用超过【5%】，请合理使用	未读	2024-05-07 16:20:01
☐	配额预警通知	用户【log】，【ALL-CPU】配额使用超过【5%】，请合理使用	未读	2024-05-07 16:15:04
☐	运行开发环境	开发环境【20240507160519】，运行节点【node1】，开始运行	未读	2024-05-07 16:10:20

最新未读消息

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 17:00:02

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 16:55:00

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 16:50:01

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 16:45:07

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 16:40:01

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 16:35:00

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 16:30:17

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 16:25:08

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 16:20:01

用户【log】，【ALL-CPU】配额使用超过【5%】 2024-05-07 16:15:04

查看全部

当前标记为“已读”

选择列

当前选中 0 条

共 11 条

50条/页

1

前往

1

页

1. 默认显示当前普通用户可接收的所有未读的消息列表，包括：类型、内容（告警信息、通知信息）、状态（未读）、到达时间、已读时间，消息的显示、查询统一由“查询”按钮控制。

2. 对于告警，消息中只显示严重的告警信息。

3. 可以统一标记为已读或批量删除。

4. 可通过下拉列选择查看已读、未读、所有消息，可通过下拉列选择对消息类型进行筛选，可填写输入框对消息内容进行模糊查询。

5. 可通过“一键全部已读”将当前用户的所有消息标记为已读。

日志管理

平台提供了日志管理功能，普通用户登录平台后，单击“**设置 > 日志管理**”，即可进入日志管理界面。

操作日志

功能说明：普通用户登录系统，单击“**设置 > 日志管理 > 操作日志**”。该页面提供系统操作日志查看功能和导出功能，如下图。系统日志包括用户登录、登出、更新、删除、创建等操作，记录操作人、操作时间、用户组、终端 IP、操作对象、功能模块、数据 ID、集群名称等信息，方便普通用户查看用户操作记录，追溯操作历史。

操作日志推理业务日志

功能模块请选择

操作时间2024-06-13 - 2024-06-19

终端IP

操作对象请选择

收起

搜索

导出

☐	操作时间	操作人	用户组	终端IP	操作对象	操作内容	操作结果	功能模块	日志级别	数据ID	集群名称
☐	2024-06-19 09:12:57	b	test	10.0.1.100	用户	登录平台	成功	身份与访问管理模块	中	b	cluster
☐	2024-06-19 09:05:56	b	test	10.0.1.100	用户	退出平台	成功	身份与访问管理模块	中	48960ec4-6935-...	cluster
☐	2024-06-19 09:05:49	b	test	10.0.1.100	文件管理	复制文件/default...	成功	存储模块	中		cluster
☐	2024-06-19 09:04:43	b	test	10.0.1.100	用户	登录平台	成功	身份与访问管理模块	中	b	cluster

选择列

当前选中 0 条

共 4 条

50条/页

1

前往

1

页

1. 日志查询：普通用户可以根据终端 IP 模糊查询，按照操作时间、操作对象、功能模块过滤查询。输入终端 IP，选择操作时间范围、操作对象、功能模块，单击查询按钮。列表中展示符合条件的数据。仅支持最近半年的日志数据查询。
2. 日志导出：选择好查询条件，单击导出按钮，可以导出查询到的日志文件，文件格式为 txt。
3. 普通用户只可以看自己的操作日志。

注意：无论是查询还是导出，限制时间范围为半年。

推理业务日志

在业务范围是训练 + 推理下、推理可用

进入“**设置 > 日志管理 > 推理业务日志**”，可查看模型部署、应用部署、原生部署、helm 部署运行状态正常的服务的日志，非正常状态的服务不进行展示和下拉框选择。推理业务日志的查询条件包括：场景、业务名称、实例名称、容器，时间；用户可以自定义时间，也可以使用快捷时间，快捷时间包括：5 分钟、15 分钟、30 分钟、1 小时、3 小时、6 小时、12 小时、1 天、7 天、14 天。单击“导出”，可对查

询到的日志进行下载操作。日志列表中的内容包括：

名称	说明
时间	日志时间
Pod	产生日志的 Pod
容器	产生日志的 Pod 的容器
日志	日志内容
加载更多	加载更多日志
返回顶部	返回日志顶部

操作日志推理业务日志

场景

业务名称

实例名称

容器

请选择

12小时

请求时间

开始时间

结束时间

搜索

导出

时间	Pod	容器	日志
2024-05-27 11:15:29	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T03:15:29.861598Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 10:42:56	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T02:42:56.220822Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 10:42:56	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T02:42:56.152666Z warn xdsproxy upstream [195] terminated with unexpected error rpc error: code = Unavailable desc = closing transport due to: connection error: desc = "error reading from server: read tcp 172.21.160...
2024-05-27 10:38:20	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T02:38:20.043959Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 10:22:26	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T02:22:26.465899Z info ads SDS: PUSH for node ds-predictor-default-00001-deployment-bccb654d5-6fqmm mmm1 resources:1 size:4.0kB resource:default
2024-05-27 10:22:26	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T02:22:26.465682Z info cache generated new workload certificate latency>220.81791ms tt=23h59m59.534350171s
2024-05-27 10:22:26	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T02:22:26.244473Z info ads XDS: Incremental Pushing:0 ConnectedEndpoints:2 Version:
2024-05-27 10:06:44	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T02:06:44.811767Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 09:34:52	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T01:34:52.231110Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 09:30:40	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T01:30:40.970033Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 09:03:23	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T01:03:23.496192Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 08:34:37	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T00:34:37.524623Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 08:05:57	ds-predictor-default-00001-d...	istio-proxy	2024-05-27T00:05:57.357932Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 07:37:02	ds-predictor-default-00001-d...	istio-proxy	2024-05-26T23:37:02.078765Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 07:04:07	ds-predictor-default-00001-d...	istio-proxy	2024-05-26T23:04:07.377851Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 06:31:02	ds-predictor-default-00001-d...	istio-proxy	2024-05-26T22:31:02.617803Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012
2024-05-27 05:58:21	ds-predictor-default-00001-d...	istio-proxy	2024-05-26T21:58:21.900861Z info xdsproxy connected to upstream XDS server: istiod.istio-system.svc:15012

加载更多

返回顶部

审批管理

平台提供了审批管理功能，普通用户登录平台后，单击“**设置 > 审批管理**”，即可进入审批管理界面，审批管理包含“审批列表”一个模块。

审批列表

普通用户可以在“**设置 > 审批管理 > 审批列表**”界面查看自己已提交的审批申请，列表内容包含：ID、业务名称、业务操作、申请人角色、审批人、审批状态、审批意见、执行结果、申请时间、审批时间、操作。

审批列表支持按照审批状态排序，默认按照申请时间排序。

审批列表

审批状态

请选择

业务名称

请选择

申请时间

请选择开始时间

请选择结束时间

收起

搜索

删除

☐	ID	业务名称	业务操作	申请人角色	审批人	审批状态	审批意见	执行结果	申请时间	审批时间	操作
☐	b759479	数据集管理	发布	普通用户	admin	审批通过	通过	成功	2024-06-19 08:37:43	2024-06-19 08:38:23	详情 删除
☐	e45b46b4	数据集管理	发布	普通用户	-	待审批	-	-	2024-06-19 08:37:37	-	详情 撤销

选择列

当前选中 0 条

共 2 条

50条/页

1

前往

1

页

支持按照业务名称、审批状态、申请时间进行查询数据。

查询条件 说明

- 业务名称 下拉框中勾选业务名称的精确匹配
- 审批状态 下拉框中勾选审批状态，支持勾选多个的精确匹配
- 申请时间 选择开始时间、结束时间范围内的精确匹配

单击“查询”按钮，审批列表中显示与查询条件匹配的审批申请信息。

详情

普通用户可以对审批列表内所有审批申请进行“详情”操作，可查看具体申请业务操作的详情信息。

详情

申请人

clhu

申请人角色

普通用户

业务名称

数据集管理

业务操作

发布

审批人

clh

详情

发布方式

个人

名称

dataset-jgcn

版本

V001

审批状态

审批通过

审批意见

同意发布到个人

取消

撤销

普通用户可以对审批列表内自己提交的待审批状态的审批申请进行“撤销”操作。执行“撤销”后，该条审批申请变为撤销申请状态。

删除

普通用户可以对审批列表内非待审批状态的审批申请进行“删除”操作，支持批量删除，审批申请被删除后将不在审批列表中展示。

服务调用数据

在业务范围是训练 + 推理、推理下可用

使用服务调用数据功能的服务总数统计

进入“**系统管理 > 设置 > 服务调用数据**”，将展示使用服务调用数据功能的服务总数，包括原生部署，通用模型和应用部署的服务。



使用服务调用数据功能时，通用模型和应用部署在部署时需选择“开启日志”，原生部署需添加 rrcollector 相关的 annotations 和 label。原生部署示例如下：


```

apiVersion: apps/v1
kind: DaemonSet
metadata:
  name: testds
  namespace: mmm
  labels:
    app: testds
spec:
  replicas: 1
  selector:
    matchLabels:
      app: testds
  template:
    metadata:
      labels:
        app: testds
    rrcollector.injector: enable
    annotations:
      sidecar.istio.io/inject: "false"
      rrcollector.inais.org/sourceURI: "http://127.0.0.1:8080"
      rrcollector.inais.org/namespace: mmm
      rrcollector.inais.org/service: testdssvc

```

存储空间占用统计

进入“**系统管理 > 设置 > 服务调用数据**”，可按场景查看服务调用数据中数据所占的存储空间大小。存储空间的单位为 MB。

 存储空间占用

MB



回流数据

进入“**系统管理 > 设置 > 服务调用数据**”，查看回流数据列表。

查询请求/响应数据

1. 查询：用户可按服务序号，场景，服务名称，处理时长，状态 (状态值可以选择预置值, 也可以进行填写，填写的值除预置值外只支持精确匹配), 请求时间来筛选服务的请求信息。表格具体展示的信息包括：

名称	说明
服务序号	服务列表中区分服务的唯一序号
场景	服务所在场景
服务名称	服务名称
请求时间	请求服务的时间
请求内容（字节）	请求体字节数
响应时间	服务的响应时间
响应内容（字节）	响应体字节数
状态	响应状态
处理时长	此次请求的处理时长
操作	删除按钮

服务列表

服务序号

场景

请选择

服务名称

状态

请选择

处理时长(ms)

-

请求时间

搜索

删除

导出

☐	服务序号	场景	服务名称	请求时间	请求内容(字节)	响应时间	响应内容(字节)	状态	处理时长	操作
☐	851	summs	logger	2024-05-09 14:23:35	0	2024-05-09 14:23:35	232	404	3 ms	删除
☐	851	summs	logger	2024-05-09 14:23:35	0	2024-05-09 14:23:35	232	404	3 ms	删除
☐	851	summs	logger	2024-05-09 14:23:34	0	2024-05-09 14:23:34	232	404	2 ms	删除
☐	851	summs	logger	2024-05-09 14:23:34	0	2024-05-09 14:23:34	232	404	5 ms	删除

选择列

当前选中 0 条

共 4 条50条/页

1

前往

1

页

2. 查看具体请求/响应数据：单击请求内容/响应内容的字节数，将查看到请求/响应的文本数据和文件数据，其中文本数据直接展示，文件数据需要下载查看。

文本数据:

```
{
  "dsds": "ffffff"
}
```


文件数据:

/store/testmmm/567ea8c9-8aab-4f15-b3fe-e8c5c8c100c0_request_test.png


[下载](#)

删除数据

单击列表中每条数据后面的删除，可删除数据。




单击列表中的数据的数据的复选框，选择要删除的数据，单击列表上方的删除，可批量删除数据。



导出数据

- 1. 文件生成：查询数据，单击导出按钮，开始生成导出文件。限制条件：文件不能超过 1G，超过 1G 生成失败，同一用户同时只能生成一个文件。若生成成功，导出按钮后给出文件名，可以进行下一步的下载操作，若导出失败，则导出按钮后给出失败原因。
- 2. 文件下载：单击文件名称后面的下载进行导出文件的下载。
- 3. 文件保留机制：生成的文件仅保存一天，也可以单击文件名后的删除进行手动删除。



服务列表

进入“系统管理 > 设置 > 服务调用数据”，将展示使用服务调用数据功能的服务列表。

查询服务调用数据服务列表

用户可按场景，服务名称，创建时间来筛选服务信息。表格具体展示的信息包括：

名称	说明
服务序号	服务列表中区分服务的唯一序号
场景	服务所在场景

名称	说明
服务名称	服务名称
创建时间	服务创建时间
创建人	服务创建人
数据回流地址	回流地址即为数据转发地址，也即此服务产生的请求响应数据会向回流地址转发一份
操作	查看回流数据和编辑按钮

回流数据

服务列表

场景

请选择

服务名称

创建时间

搜索

☐	服务序号	场景	业务	创建时间	创建人	数据回流地址	操作
☐	851	sxmns	logger	2024-05-09 10:22:11	ssxm		查看回流数据 编辑

选择列

当前选中 0 条

共 1 条

50条/页

<

1

>

前往

1

页

回流数据关联查看

单击每个服务操作栏中的“查看回流数据”按钮，跳转到回流数据页面，展示该服务的回流数据。

修改数据回流地址

单击每个服务操作栏中的“编辑”按钮，填写相应的回流地址。回流地址添加完成后，设置的回流地址将会收到相应服务的请求和相应数据。

修改数据回流地址

http://fdfd/add_data

取消


确定

API 授权

在业务范围是训练 + 推理、推理下可用普通用户可以创建，更新，查询，删除 API 授权信息。


创建签名

普通用户可以选择场景，服务名称，输入有效期、qps、源地址、签名名称信息创建 API 授权。



更新签名

普通用户可以选择某条 API 授权信息，单击“更新”，输入有效期、qps、源地址、签名名称信息更新 API 授权。




查询签名

普通用户可以按照场景，服务名称，签名名称查询 API 授权信息。



删除签名

普通用户可以选择某条 API 授权信息，单击“删除”，删除 API 授权。



复制签名

普通用户可以选择某条 API 授权信息，单击“复制”，复制 API 签名。



AK/SK 签名认证

功能说明：开启开发权限的用户可以进行刷新 SK、查看 SK、设置 SK 有效期操作。

- 1. 刷新 SK 信息：刷新 AK/SK 签名认证 SK 信息。二次认证开关开启时刷新需进行二次认证，通过后刷新 SK 信息。
- 2. 查看 SK 信息：查看 AK/SK 签名认证 SK 明文信息。二次认证开关开启时查看需进行二次认证，通过后明文展示 SK 信息。
- 3. SK 有效期：首次开启开发权限后，默认 7 天有效，可设置为永久有效或选择有效截止时间。

AK

482a813fece560e42607

SK

SK有效期

永久有效

🕒 2024-06-07 16:48:34

工具指南

Jupyter Lab 简介及常用操作

JupyterLab 是一个交互式的开发环境，是 Jupyter Notebook 的下一代产品，可以使用它编写 Notebook、操作终端、编辑 Markdown 文本、打开交互模式、查看 csv 文件及图片等功能。可以说，JupyterLab 是开发者们下一阶段更主流的开发环境。JupyterLab 支持更加灵活和更加强大的项目操作方式，但具有和 Jupyter Notebook 一样的组件。

打开 Jupyter Lab


当创建的开发环境处于运行状态时，单击具体的开发环境名称，进入 JupyterLab 页面后，自动打开 Launcher 页面。您可以使用开源支持的所有功能，详细操作指导可参见 JupyterLab 官网文档。

默认文件目录

文件目录默认显示当前用户目录下的文件

预置 Jupyter-Example 使用

平台预置的各框架相应算例的 ipynb 文件初始都保存在/defaultShare/user-data/jupyter-example 目录下，可以通过文件管理中“复制到”功能复制到用户目录。



当相应框架的开发环境创建完成，进入 jupyter 页面，打开相应算例。

Kernel 重启

在页面菜单中可以操作 Kernel 重启。

镜像组件安装手册

为了适配平台，本文档主要介绍 openssh、JupyterLab 和 python 组件的安装。若需要安装或更新相关组件版本，请参考本文的示例。目前平台适配安装的 **JupyterLab 为 3.2.5 版本，openssh 为 8.2p1，python 为 3.8.10**，建议安装上述版本避免兼容性问题。此外，JupyterLab 必须使用 python3 安装，不能使用 python2 安装！

若无法连接外网，可以参考以下方式：

- 1. 将相关软件安装包或依赖下载完成，上传到用户目录，基于基础镜像创建开发环境，在开发环境中进行组件的离线安装，最后保存镜像，通过平台完成镜像制作。
- 2. 直接在网络正常的环境中，在线安装组件，以 docker save 的方式保存成 tar 包，通过平台“**镜像管理 > 内部导入**”的功能进行导入。

基于 CentOS 安装组件

拉取 CentOS 镜像并进行配置以安装 CentOS 系统

我们需要在 Dockerhub 上使用如下命令拉取 CentOS 镜像。如果您已经拥有 CentOS 系统的镜像，请忽略本小节的内容。

```
docker pull centos:centos7.4.1708
```

CentOS 官方已经在 2020 年 12 月 8 日宣布取消对 CentOS 的更新（单击此处查阅公告）。在此，我们为了支持 CentOS 系统的运行，需要进行一些额外的配置：

1. 进入 yum 的 repos 目录

```
cd /etc/yum.repos.d/
```

2. 修改所有的 CentOS 文件内容

```
sed -i 's/mirrorlist/#mirrorlist/g' /etc/yum.repos.d/CentOS-*  
sed -i 's|#baseurl=http://mirror.centos.org|baseurl=http://vault.centos.org|g' /etc/  
yum.repos.d/CentOS-*
```

3. 更新 yum 源为阿里镜像（或参照此步骤更换为其他可用镜像源）

```
wget -O /etc/yum.repos.d/CentOS-Base.repo https://mirrors.aliyun.com/repo/Centos-  
vault-8.5.2111.repo  
yum clean all  
yum makecache
```

4. 测试是否可以通过 yum 安装

```
yum install vim -y
```

注意：Dockerhub 拉取的 CentOS 镜像中不包含 python3，如果您的系统中已有 python3，请您跳过安装 python3 的步骤。

安装 ssh 相关组件

1. 下载安装包和相关依赖包到指定目录，需要下载的安装包有：

- openssh-8.2p1-21.el7.x86_64.rpm
- openssh-clients-8.2p1-21.el7.x86_64.rpm
- openssh-server-8.2p1-21.el7.x86_64.rpm

2. 运行如下代码下载相关安装包

```
yum install --downloadonly --downloadaddir=/home/tmpUser/image_components/centos7.4/  
openssh openssh -y  
yum install --downloadonly --downloadaddir=/home/tmpUser/image_components/centos7.4/  
openssl openssl -y
```

3. 安装 openssh 和 openssl 组件

```
cd /home/tmpUser/image_components/centos7.4/openssh  
rpm -ivh *.rpm --force --nodeps  
cd /home/tmpUser/image_components/centos7.4/openssl  
rpm -ivh *.rpm --force --nodeps
```

4. 配置 openssh

```
/usr/bin/ssh-keygen -A  
cat /etc/ssh/ssh_config | grep -v StrictHostKeyChecking > /etc/ssh/ssh_config.new  
echo " StrictHostKeyChecking no" >> /etc/ssh/ssh_config.new  
cat /etc/ssh/sshd_config | grep -v PermitRootLogin > /etc/ssh/sshd_config.new  
echo "PermitRootLogin yes" >> /etc/ssh/sshd_config.new  
mv -f /etc/ssh/ssh_config.new /etc/ssh/ssh_config  
mv -f /etc/ssh/sshd_config.new /etc/ssh/sshd_config > /dev/null 2>&1
```

5. 启动 ssh

```
/usr/sbin/sshd
```

安装 python 与 pip

CentOS 系统可能自带 python3 和 pip3。如果您确定您的 CentOS 系统中已存在 python3 和 pip3，您可以跳过本步骤。

1. 下载依赖

```
yum install --downloadonly --downloadaddir=/home/tmpUser/image_components/centos7.4/  
python_depends make zlib zlib-devel bzip2-devel openssl-devel sqlite-devel  
readline-devel gdbm-devel gcc libffi-devel -y
```

2. 安装所有依赖

```
cd /home/tmpUser/image_components/centos7.4/python_depends  
rpm -ivh *.rpm --force --nodeps
```

3. 下载并安装 python3.8.10

```
mkdir /home/tmpUser/image_components/python  
cd /home/tmpUser/image_components/python  
wget https://www.python.org/ftp/python/3.8.10/Python-3.8.10.tgz  
tar -zxvf Python-3.8.10.tgz  
cd Python-3.8.10  
./configure  
make && make install
```

4. 使用下列命令修改 python 配置

```
mv /usr/bin/python /usr/bin/python27  
mv /usr/bin/pip /usr/bin/pip27  
ln -s /usr/local/bin/python3 /usr/bin/python  
ln -s /usr/local/bin/pip3 /usr/bin/pip  
sed -i "s#/usr/bin/python# /usr/bin/python2.7#" /usr/bin/yum  
sed -i "s#/usr/bin/python# /usr/bin/python2.7#" /usr/libexec/urlgrabber-ext-down
```

5. 安装 pip

```
cd /home/tmpUser/image_components
wget https://bootstrap.pypa.io/get-pip.py
python get-pip.py
```

安装 Jupyter

1. 使用 pip 安装 Jupyter

```
pip install jupyterlab==3.2.5
```

也可以离线安装 Jupyter:

```
pip3 install --no-index --find-links=/home/tmpUser/install_packages/jupyterlab
jupyterlab-3.2.5-py2.py3-none-any.whl
```

2. 测试 Jupyter 是否安装成功

```
jupyter lab --ip=0.0.0.0 --no-browser --allow-root
```

3. 配置 Jupyter

```
wget -P /home/tmpUser/image_components/jupyter_configure https://raw.githubusercontent.com/Winowang/jupyter_gpu/master/jupyter_notebook_config.py &&
wget -P /home/tmpUser/image_components/jupyter_configure https://raw.githubusercontent.com/Winowang/jupyter_gpu/master/custom.js
```

4. 拷贝 Jupyter 至指定路径

```
mkdir /etc/jupyter && cp -rf /home/tmpUser/image_components/jupyter_configure/* /etc/jupyter
```

基于 Ubuntu 安装组件

Ubuntu 系统下安装组件的方法与 CentOS 系统下安装组件的方法类似。

拉取 Ubuntu 镜像以安装 Ubuntu 系统

我们需要在 Dockerhub 上使用如下命令拉取 Ubuntu 镜像。如果您已经完成 Ubuntu 系统的安装，请忽略本小节的内容。

```
docker pull ubuntu
```

注意：Dockerhub 拉取的 Ubuntu 镜像中不包含 python3，如果您的系统中已有 python3，请您跳过安装 python3 的步骤。

安装 ssh 相关组件

1. 升级 apt-get

```
apt-get update
```

2. 安装 openssh

```
apt-get install openssh-client  
apt-get install openssh-server
```

3. openssh 配置

```
/usr/bin/ssh-keygen -A  
cat /etc/ssh/ssh_config | grep -v StrictHostKeyChecking > /etc/ssh/ssh_config.new  
echo " StrictHostKeyChecking no" >> /etc/ssh/ssh_config.new  
cat /etc/ssh/sshd_config | grep -v PermitRootLogin > /etc/ssh/sshd_config.new  
echo "PermitRootLogin yes" >> /etc/ssh/sshd_config.new  
mv -f /etc/ssh/ssh_config.new /etc/ssh/ssh_config  
mv -f /etc/ssh/sshd_config.new /etc/ssh/sshd_config > /dev/null 2>&1
```

4. 启动 ssh

```
/usr/sbin/sshd
```

安装 python 与 pip

Ubuntu 系统可能自带 python3 和 pip3。如果您确定您的 Ubuntu 系统中已存在 python3 和 pip3，您可以跳过本步骤。

1. 下载依赖

```
apt-get install -y build-essential libncurses5-dev libgdbm-dev libnss3-dev libssl-dev  
libreadline-dev libffi-dev zlib1g-dev libsqlite3-dev
```

2. 安装所有依赖

```
cd /home/tmpUser/image_components/ubuntu18.04/python_depends  
dpkg -i *deb
```

3. 下载并安装 python3.8.10

```
cd /home/tmpUser/image_components/python  
wget https://www.python.org/ftp/python/3.8.10/Python-3.8.10.tgz  
tar -zxvf Python-3.8.10.tgz  
cd Python-3.8.10  
./configure  
make && make install
```

4. 使用下列命令修改 python 配置

```
mv /usr/bin/python /usr/bin/python27  
mv /usr/bin/pip /usr/bin/pip27  
ln -s /usr/local/bin/python3 /usr/bin/python  
ln -s /usr/local/bin/pip3 /usr/bin/pip
```

5. 下载并安装 pip

```
wget https://bootstrap.pypa.io/get-pip.py  
python get-pip.py
```

安装 Jupyter

1. 安装 Jupyter

```
pip install jupyterlab==3.2.5
```

也可以离线安装 Jupyter:

```
pip3 install --no-index --find-links=/home/tmpUser/install_packages/jupyterlab  
jupyterlab-3.2.5-py2.py3-none-any.whl
```

2. 测试 Jupyter 安装是否成功

```
jupyter lab --ip=0.0.0.0 --no-browser --allow-root
```

3. 配置 Jupyter

```
wget -P /home/tmpUser/image_components/jupyter_configure https://raw.  
githubusercontent.com/Winowang/jupyter_gpu/master/jupyter_notebook_config.py &&  
wget -P /home/tmpUser/image_components/jupyter_configure https://raw.  
githubusercontent.com/Winowang/jupyter_gpu/master/custom.js
```

4. 拷贝 Jupyter 至指定路径

```
mkdir /etc/jupyter && cp -rf /home/tmpUser/image_components/jupyter_configure/* /etc/  
jupyter
```

镜像制作手册

基础镜像

基础镜像都需要安装 cuda、cudnn 等深度学习必备组件，如果所制作的镜像对操作系统版本（官方镜像操作系统都是最新的）、cudnn 版本没有要求，以及要求操作系统是 Ubuntu 系统，都可以去 NGC 官网，下载指定 cuda 版本的基础镜像。

如果镜像的操作系统版本为 CentOS，或指定 cuda、cudnn 版本，NGC 官方没有该基础镜像，则需要自制符合指定操作系统或 cuda 版本的基础镜像。

注意：制作镜像，需要在联网环境下在线制作。由于与组件相关的依赖包较多，不推荐下载安装包离线安装的方式。本文以在线制作镜像为主，提供离线下载安装组件的命令。由于镜像中的操作系统都是 MINI 版，一般在线安装定制组件时，一些共享库或者组件依赖包不会被自动安装。在实际镜像制作过程中，可参考本文档安装所需的共享库或依赖包。若遇到难以解决的问题请联系我们。通过 Dockerfile 制作镜像，如果没有最终失败，请忽略在线制作镜像时输出的红色内容，这不影响最终制作的镜像。本文档，以某客户定制镜像制作作为示例，定制要求：

操作系统 ==CentOS 7.4

numpy==1.15.4

opencv-python==3.4.3.18

tensorflow-gpu==1.8.0

Keras==2.2.4


python3.6.6

cuda9.0

cuda9.0

NGC 官方基础镜像

Ubuntu 系统的 cuda 基础镜像，请在 NGC 官方网站下载，一般不需要单独制作，单独制作只针对 CentOS 版本。NGC 官方基础镜像下载地址：<https://ngc.nvidia.com/catalog/containers/nvidia:cuda/tags>



单击 Pull Tag 获取 pull 镜像命令，下载需要的基础镜像：

```
docker pull nvcr.io/nvidia/cuda:9.0-cudnn7-devel-centos7
```



```
[root@aimaster docker_images]# docker pull nvcr.io/nvidia/cuda:9.0-cudnn7-devel-centos7
9.0-cudnn7-devel-centos7: Pulling from nvidia/cuda
Digest: sha256:5ffdf37b8b19f5c9fd43ef2eac190b77a94a2617e539a12990fa34192d34b78b
Status: Image is up to date for nvcr.io/nvidia/cuda:9.0-cudnn7-devel-centos7
[root@aimaster docker_images]# docker images |grep 9.0-cudnn7-devel-centos7
nvcr.io/nvidia/cuda          9.0-cudnn7-devel-centos7      fd0de7bcd7b0      6 month
ago                          2.54GB
```

自制带 cuda 的基础镜像


由于客户定制的镜像，指定了操作系统，NGC 官方镜像没有该基础镜像，需要自制基础镜像。


下载 Dockerfile

下载指定版本的 cuda 和操作系统的 Dockerfile 和 cuda.repo，然后再修改 Dockerfile。（需要翻墙，才能访问）。


下载链接：<https://gitlab.com/nvidia/container-images/cuda/-/tree/master/dist>

单击 CentOS7 进入 cuda 版本选择，选择 cuda9.0





下载后，如图所示：



gitlab cuda9.0 下面，有 base、devel、runtime 目录，我们需要将每个下面的 Dockerfile 文件，汇总成一个 Dockerfile 文件，制作一个最全的 cuda 镜像，防止镜像使用 GPU 训练时出现问题。base、devel 和 runtime 官方解释，如下：

CUDA images come in three flavors and are available through the NVIDIA public hub repository.

base: starting from CUDA 9.0, contains the bare minimum (libcudart) to deploy a pre-built CUDA application.

Use this image if you want to manually select which CUDA packages you want to install

runtime: extends the base image by adding all the shared libraries from the CUDA

```
toolkit.
```

Use this image if you have a pre-built application using multiple CUDA libraries.

devel: extends the runtime image by adding the compiler toolchain, the debugging tools, the headers and the static libraries.

Use this image to compile a CUDA application from sources.

修改 Dockerfile

将 cuda9.0 下面的所有 Dockerfile 汇总成一个 Dockerfile，重复内容，只保留一份，汇总后的 Dockerfile 内容，如下：Dockerfile 文件：

```
FROM centos:centos7.4.1708
LABEL maintainer "NVIDIA CORPORATION <cuda@nvidia.com>"

RUN NVIDIA_GPGKEY_SUM=
    d1be581509378368edeec8c1eb2958702feedf3bc3d17011adbf24efacce4ab5 && curl -fsSL
    https://developer.download.nvidia.com/compute/cuda/repos/rhel7/x86_64/7fa2af80.pub
    | sed '/^Version/d' > /etc/pki/rpm-gpg/RPM-GPG-KEY-NVIDIA && echo "
    $NVIDIA_GPGKEY_SUM /etc/pki/rpm-gpg/RPM-GPG-KEY-NVIDIA" | sha256sum -c --strict -

COPY cuda.repo /etc/yum.repos.d/cuda.repo

ENV CUDA_VERSION 9.0.176

ENV CUDA_PKG_VERSION 9-0-$CUDA_VERSION-1
RUN yum install -y cuda-cudart-$CUDA_PKG_VERSION && ln -s cuda-9.0 /usr/local/cuda &&
    rm -rf /var/cache/yum/*

#nvidia-docker 1.0
LABEL com.nvidia.volumes.needed="nvidia_driver"
LABEL com.nvidia.cuda.version="${CUDA_VERSION}"
```

```
RUN echo "/usr/local/nvidia/lib" >> /etc/ld.so.conf.d/nvidia.conf && echo "/usr/local/nvidia/lib64" >> /etc/ld.so.conf.d/nvidia.conf

ENV PATH /usr/local/nvidia/bin:/usr/local/cuda/bin:${PATH}
ENV LD_LIBRARY_PATH /usr/local/nvidia/lib:/usr/local/nvidia/lib64

#nvidia-container-runtime

ENV NVIDIA_VISIBLE_DEVICES all

ENV NVIDIA_DRIVER_CAPABILITIES compute,utility
ENV NVIDIA_REQUIRE_CUDA "cuda>=9.0"

#runtime
RUN yum install -y cuda-libraries-$CUDA_PKG_VERSION cuda-cublas-9-0-9.0.176.4-1 && rm -rf /var/cache/yum/*

# cudnn
ENV CUDNN_VERSION 7.6.0.64
LABEL com.nvidia.cudnn.version="${CUDNN_VERSION}"

#cuDNN license: https://developer.nvidia.com/cudnn/license\_agreement
RUN CUDNN_DOWNLOAD_SUM=90659
    ea77734b7b671afe930c9898d21a13b888998f1dd3940cc57d6b2f29b86 && curl -fsSL http://developer.download.nvidia.com/compute/redist/cudnn/v7.6.0/cudnn-9.0-linux-x64-v7.6.0.64.tgz -O && echo "$CUDNN_DOWNLOAD_SUM cudnn-9.0-linux-x64-v7.6.0.64.tgz" | sha256sum -c - && tar --no-same-owner -xzf cudnn-9.0-linux-x64-v7.6.0.64.tgz -C /usr/local --wildcards 'cuda/lib64/libcudnn.so.*' && rm cudnn-9.0-linux-x64-v7.6.0.64.tgz && ldconfig

#devel
```

```
RUN rm -rf /usr/local/cuda-9.0/include && yum install -y cuda-libraries-dev-  
$CUDA_PKG_VERSION cuda-nvml-dev-$CUDA_PKG_VERSION cuda-minimal-build-  
$CUDA_PKG_VERSION cuda-command-line-tools-$CUDA_PKG_VERSION cuda-core  
-9-0-9.0.176.3-1 cuda-cublas-dev-9-0-9.0.176.4-1 && rm -rf /var/cache/yum/*  
ENV LIBRARY_PATH /usr/local/cuda/lib64/stubs
```

替换 FROM 基础镜像

Dockerfile 中的 FROM 操作系统镜像，换成自己需要的操作系统，操作系统镜像下载地址和查看操作系统镜像标签和版本地址如下：

<https://hub.docker.com/> 在搜索框输入 CentOS，单击第一个官方 CentOS，进入寻找需要的操作系统版本，替换 FROM 部分内容。

替换 cudnn（如果没有指定版本，忽略该部分内容）

由于官方 cudnn 中的 Dockerfile 中，cudnn 都是最新的，如果需要指定版本，需要自己手动查找和修改该部分内容。

查看自己指定的 cudnn 版本链接：<https://developer.nvidia.com/rdp/cudnn-archive>

单击下载，查看版本号：



在线 cudnn

将 cudnn 部分修改为如下内容

```
#cudnn
ENV CUDNN_VERSION 7
LABEL com.nvidia.cudnn.version="${CUDNN_VERSION}"
#cuDNN license: https://developer.nvidia.com/cudnn/license_agreement
RUN curl -fsSL http://developer.download.nvidia.com/compute/redist/cudnn/v7.0.5/cudnn
    -9.0-linux-x64-v7.tgz -O && tar --no-same-owner -xzf cudnn-9.0-linux-x64-v7.tgz -C
    /usr/local --wildcards 'cuda/lib64/libcudnn.so.*' && rm cudnn-9.0-linux-x64-v7.
    tgz && ldconfig
```

离线 cudnn

如果上述在线下载出现问题，或者比较缓慢，可以使用离线 cudnn，先下载 cudnn tar 包，然后和 Dockerfile 文件放到一起。然后将 Dockerfile 中的 cudnn 修改如下内容：

```
#cudnn

ENV CUDNN_VERSION 7

LABEL com.nvidia.cudnn.version="${CUDNN_VERSION}"

#cuDNN license: https://developer.nvidia.com/cudnn/license_agreement
COPY cudnn-9.0-linux-x64-v7.tgz /home/cudnn-9.0-linux-x64-v7.tgz
RUN tar --no-same-owner -xzf /home/cudnn-9.0-linux-x64-v7.tgz -C /usr/local && rm /
    home/cudnn-9.0-linux-x64-v7.tgz && ldconfig
```

其它部分修改

避免制作失败，根据 cuda 版本，修改该部分的 cuda 版本——devel RUN 部分添加：

```
rm -rf /usr/local/cuda-9.0/include
```

在线制作 cuda 基础镜像

#进入Dockerfile目录

```
cd /home/wjy/Dockerfile/cuda9.0-wjy
```

```
docker build -t centos7.4-cuda9.0-cudnn7.0-base-tmpUser:latest .
```

```
[root@aimaster cuda9.0-wjy]# docker build -t test-dockerfile:latest .
Sending build context to Docker daemon 5.12kB
Step 1/21 : FROM centos:centos7.4.1708
--> 9f266d35e02c
Step 2/21 : LABEL maintainer "NVIDIA CORPORATION <cuda@nvidia.com>"
--> Running in c134676424ee
--> d5b439c11145
Removing intermediate container c134676424ee
Step 3/21 : RUN NVIDIA_GPGKEY_SUM=d1be581509378368edeec8c1eb2958702feedf3bc3d17011adb24efacce4ab5 && curl -fsSL https://developer.download.nvidia.com/compute/cuda/repos/rhel7/x86_64/7f
a2af80.pub | sed '/^Version/d' > /etc/pki/rpm-gpg/RPM-GPG-KEY-NVIDIA && echo "$NVIDIA_GPGKEY_SUM /etc/pki/rpm-gpg/RPM-GPG-KEY-NVIDIA" | sha256sum -c --strict -
--> Running in a276ada0a53e
/etc/pki/rpm-gpg/RPM-GPG-KEY-NVIDIA: OK
--> 07beel779867
Removing intermediate container a276ada0a53e
Step 4/21 : COPY cuda.repo /etc/yum.repos.d/cuda.repo
--> 504233f78c2c
Removing intermediate container c9e100a3c0d0
Step 5/21 : ENV CUDA_VERSION 9.0.176
--> Running in fa82ff62b578
--> 08fc080824a2
Removing intermediate container fa82ff62b578
Step 6/21 : ENV CUDA_PKG_VERSION 9-0-$CUDA_VERSION-1
--> Running in 3b4f3c33e9d8
--> fe3c60ac805d
Removing intermediate container 3b4f3c33e9d8
Step 7/21 : RUN yum install -y cuda-cudart-$CUDA_PKG_VERSION && ln -s cuda-9.0 /usr/local/cuda && rm -rf /var/cache/yum/*
--> Running in dcde980e258c
Loaded plugins: fastestmirror, ovl
Determining fastest mirrors
 * base: mirrors.tuna.tsinghua.edu.cn
 * extras: mirrors.bfsu.edu.cn
 * updates: mirror.bit.edu.cn
Resolving Dependencies
--> Running transaction check
--> Package cuda-cudart-9-0.x86_64 0:9.0.176-1 will be installed
--> Processing Dependency: cuda-license-9-0 for package: cuda-cudart-9-0-9.0.176-1.x86_64
--> Running transaction check
--> Package cuda-license-9-0.x86_64 0:9.0.176-1 will be installed
```

```
--> Processing Dependency: cuda-license-9-0 for package: cuda-cudart-9-0-9.0.176-1.x86_64
--> Running transaction check
--> Package cuda-license-9-0.x86_64 0:9.0.176-1 will be installed
--> Finished Dependency Resolution

Dependencies Resolved

=====
Package                Arch      Version      Repository    Size
=====
Installing:
 cuda-cudart-9-0        x86_64    9.0.176-1    cuda          143 k
Installing for dependencies:
 cuda-license-9-0       x86_64    9.0.176-1    cuda          28 k

Transaction Summary
=====
Install 1 Package (+1 Dependent package)

Total download size: 171 k
Installed size: 549 k
Downloading packages:
Warning: /var/cache/yum/x86_64/7/cuda/packages/cuda-cudart-9-0-9.0.176-1.x86_64.rpm: Header V3 RSA/SHA512 Signature, key ID 7fa2af80: NOKEY
Public key for cuda-cudart-9-0-9.0.176-1.x86_64.rpm is not installed
-----
Total                78 kB/s | 171 kB  00:02
Retrieving key from file:///etc/pki/rpm-gpg/RPM-GPG-KEY-NVIDIA
Importing GPG key 0x7FA2AF80:
  Userid   : "cudatools <cudatools@nvidia.com>"
  Fingerprint: ae09 fe4b bd22 3a84 b2cc fce3 f60f 4b3d 7fa2 af80
  From      : /etc/pki/rpm-gpg/RPM-GPG-KEY-NVIDIA
Running transaction check
Running transaction test
Transaction test succeeded
Running transaction
  Installing : cuda-license-9-0-9.0.176-1.x86_64                                1/2
*** LICENSE AGREEMENT ***
By using this software you agree to fully comply with the terms and
conditions of the EULA (End User License Agreement). The EULA is located
at /usr/local/cuda-9.0/doc/EULA.txt. The EULA can also be found at
http://docs.nvidia.com/cuda/eula/index.html. If you do not agree to the
terms and conditions of the EULA, do not use the software.

glibc-headers          x86_64    2.17-307.el7.1    base        689 k
kernel-headers          x86_64    3.10.0-1127.8.2.el7 updates     8.9 M
libgomp                 x86_64    4.8.5-39.el7      base        158 k
libmpc                 x86_64    1.0.1-3.el7       base         51 k
libstdc++-devel         x86_64    4.8.5-39.el7      base        1.5 M
mpfr                   x86_64    3.1.1-4.el7       base        203 k
Updating for dependencies:
 glibc                 x86_64    2.17-307.el7.1    base        3.6 M
 glibc-common          x86_64    2.17-307.el7.1    base        11 M
 libgcc                x86_64    4.8.5-39.el7      base        102 k
 libstdc++             x86_64    4.8.5-39.el7      base        305 k

Transaction Summary
=====
Install 6 Packages (+20 Dependent packages)
Upgrade   ( 4 Dependent packages)

Total download size: 530 M
Downloading packages:
Delta RPMs disabled because /usr/bin/applydeltarpm not installed.
Warning: /var/cache/yum/x86_64/7/base/packages/cpp-4.8.5-39.el7.x86_64.rpm: Header V3 RSA/SHA256 Signature, key ID f4a80eb5: NOKEY
Public key for cpp-4.8.5-39.el7.x86_64.rpm is not installed
http://developer.download.nvidia.com/compute/cuda/repos/rhel7/x86_64/cuda-nvml-dev-9-0-9.0.176-1.x86_64.rpm: [Errno 12] Timeout on http://developer.download.nvidia.com/compute/cuda/repos/rhel7/x86_64/cuda-nvml-dev-9-0-9.0.176-1.x86_64.rpm: (28, 'Operation too slow. Less than 1000 bytes/sec transferred the last 30 seconds')
Paying other mirrors.
Public key for kernel-headers-3.10.0-1127.8.2.el7.x86_64.rpm is not installed
-----
Total                558 kB/s | 530 MB  16:11
Retrieving key from file:///etc/pki/rpm-gpg/RPM-GPG-KEY-CentOS-7
Importing GPG key 0xF4A80EB5:
  Userid   : "CentOS-7 Key (CentOS 7 Official Signing Key) <security@centos.org>"
  Fingerprint: 6341 ab27 53d7 8a78 a7c2 7bb1 24c6 a8a7 f4a8 0eb5
  Package   : centos-release-7-4.1708.el7.centos.x86_64 (9CentOS)
  From      : /etc/pki/rpm-gpg/RPM-GPG-KEY-CentOS-7
Running transaction check
Running transaction test
Transaction test succeeded
Running transaction
  Updating : libgcc-4.8.5-39.el7.x86_64                                1/34
  Updating : glibc-2.17-307.el7.1.x86_64                             2/34
Warning: /etc/nsswitch.conf created as /etc/nsswitch.conf.rpmnew
  Updating : glibc-common-2.17-307.el7.1.x86_64                       3/34
```

报红内容，忽略，不影响安装，如果介意，修改 cuda.repo 中的 gpgcheck=0，同时在 Dockerfile 最后一个 RUN 中添加：

```
rpm --import /etc/pki/rpm-gpg/RPM-GPG-KEY-CentOS-7
```



```
cuda-core-9-0.x86_64 0:9.0.176.3-1
cuda-cublas-dev-9-0.x86_64 0:9.0.176.4-1
cuda-libraries-dev-9-0.x86_64 0:9.0.176-1
cuda-minimal-build-9-0.x86_64 0:9.0.176-1
cuda-nvml-dev-9-0.x86_64 0:9.0.176-1

Dependency Installed:
cpp.x86_64 0:4.8.5-39.el7
cuda-cudart-dev-9-0.x86_64 0:9.0.176-1
cuda-cufft-dev-9-0.x86_64 0:9.0.176-1
cuda-curand-dev-9-0.x86_64 0:9.0.176-1
cuda-cusolver-dev-9-0.x86_64 0:9.0.176-1
cuda-cuspars-dev-9-0.x86_64 0:9.0.176-1
cuda-driver-dev-9-0.x86_64 0:9.0.176-1
cuda-misc-headers-9-0.x86_64 0:9.0.176-1
cuda-npp-dev-9-0.x86_64 0:9.0.176-1
cuda-nvgraph-dev-9-0.x86_64 0:9.0.176-1
cuda-nvrtc-dev-9-0.x86_64 0:9.0.176-1
gcc.x86_64 0:4.8.5-39.el7
gcc-c++.x86_64 0:4.8.5-39.el7
glibc-devel.x86_64 0:2.17-307.el7.1
glibc-headers.x86_64 0:2.17-307.el7.1
kernel-headers.x86_64 0:3.10.0-1127.8.2.el7
libgomp.x86_64 0:4.8.5-39.el7
libmpc.x86_64 0:1.0.1-3.el7
libstdc++-devel.x86_64 0:4.8.5-39.el7
mpfr.x86_64 0:3.1.1-4.el7

Dependency Updated:
glibc.x86_64 0:2.17-307.el7.1      glibc-common.x86_64 0:2.17-307.el7.1
libgcc.x86_64 0:4.8.5-39.el7      libstdc++.x86_64 0:4.8.5-39.el7

Complete!
---> 21e5deb9a2da
Removing intermediate container 236cea4822a8
Step 21/21 : ENV LIBRARY_PATH /usr/local/cuda/lib64/stubs
---> Running in 3a2f95595f62
---> cfcbe827a91b
Removing intermediate container 3a2f95595f62
Successfully built cfcbe827a91b
Successfully tagged test-dockerfile:latest
[root@aimaster cuda9.0-wjy]#

Removing intermediate container 3a2f95595f62
Successfully built cfcbe827a91b
Successfully tagged test-dockerfile:latest
[root@aimaster cuda9.0-wjy]# docker run -it test-dockerfile:latest bash
[root@72f7ec4de780 /]# nvcc -V
nvcc: NVIDIA (R) Cuda compiler driver
Copyright (c) 2005-2017 NVIDIA Corporation
Built on Fri Sep 1 21:08:03 CDT 2017
Cuda compilation tools, release 9.0, V9.0.176
[root@72f7ec4de780 /]#
```

离线下载 RUN 安装的 cuda 组件（如果在线制作顺利，忽略该部分）

离线下载 cuda 组件

Dockerfile 在线制作过程中，如果网络环境不太好，可能导致在线制作时间特别长或者制作失败。可以离线 Dockerfile RUN 中 yum 在线安装的组件，然后，修改 Dockerfile, 制作好后，再在制作的镜像中，离线安装这些组件。

在 linux 下新建一个目录，用来下载离线 cuda 组件：

```
[root@aimaster components]# pwd  
/home/wjy/Dockerfile/components  
[root@aimaster components]#
```

在终端执行如下命令：

```
CUDA_VERSION=9.0.176  
CUDA_PKG_VERSION=9-0-$CUDA_VERSION-1  
yum install --downloadonly --downloadaddr=/home/wjy/Dockerfile/components cuda-cudart-  
$CUDA_PKG_VERSION cuda-libraries-$CUDA_PKG_VERSION cuda-cublas-9-0-9.0.176.4-1  
cuda-libraries-dev-$CUDA_PKG_VERSION cuda-nvml-dev-$CUDA_PKG_VERSION cuda-minimal-  
build-$CUDA_PKG_VERSION cuda-command-line-tools-$CUDA_PKG_VERSION cuda-core  
-9-0-9.0.176.3-1 cuda-cublas-dev-9-0-9.0.176.4-1
```

```
total 1234440
-rw-r--r--. 1 root root 32023497 Sep 23 2017 cuda-command-line-tools-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 22626151 May 24 2018 cuda-core-9-0-9.0.176.3-1.x86_64.rpm
-rw-r--r--. 1 root root 73073867 Jul 14 2018 cuda-cublas-9-0-9.0.176.4-1.x86_64.rpm
-rw-r--r--. 1 root root 82335574 Jul 14 2018 cuda-cublas-dev-9-0-9.0.176.4-1.x86_64.rpm
-rw-r--r--. 1 root root 146671 Sep 23 2017 cuda-cudart-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 1217125 Sep 23 2017 cuda-cudart-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 102698085 Sep 23 2017 cuda-cufft-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 95468945 Sep 23 2017 cuda-cufft-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 43847481 Sep 23 2017 cuda-curand-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 67872020 Sep 23 2017 cuda-curand-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 39824385 Sep 23 2017 cuda-cusolver-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 11333919 Sep 23 2017 cuda-cusolver-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 37460915 Sep 23 2017 cuda-cusparse-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 75737774 Sep 23 2017 cuda-cusparse-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 18821 Sep 23 2017 cuda-driver-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 6190 Sep 23 2017 cuda-libraries-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 6318 Sep 23 2017 cuda-libraries-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 28715 Sep 23 2017 cuda-license-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 6010 Sep 23 2017 cuda-minimal-build-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 1193604 Sep 23 2017 cuda-misc-headers-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 95391511 Sep 23 2017 cuda-npp-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 95851387 Sep 23 2017 cuda-npp-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 9251545 Sep 23 2017 cuda-nvgraph-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 9299496 Sep 23 2017 cuda-nvgraph-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 64133 Sep 23 2017 cuda-nvml-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 8962438 Sep 23 2017 cuda-nvrtc-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 14767 Sep 23 2017 cuda-nvrtc-dev-9-0-9.0.176-1.x86_64.rpm
-rw-r--r--. 1 root root 348817823 Nov 17 2017 cudnn-9.0-linux-x64-v7.tgz
-rw-r--r--. 1 root root 7534972 May 13 11:55 gcc-c++-4.8.5-36.el7.x86_64.rpm
-rw-r--r--. 1 root root 311728 May 13 11:55 libstdc++-4.8.5-36.el7.x86_64.rpm
-rw-r--r--. 1 root root 1580028 May 13 11:55 libstdc++-devel-4.8.5-36.el7.x86_64.rpm
[root@node2 ~]#
```

修改 Dockerfile

```
FROM centos:centos7.4.1708
LABEL maintainer "NVIDIA CORPORATION <cuda@nvidia.com>"
RUN NVIDIA_GPGKEY_SUM=
    d1be581509378368edeec8c1eb2958702feedf3bc3d17011adbf24efacce4ab5 && curl -fsSL
    https://developer.download.nvidia.com/compute/cuda/repos/rhel7/x86_64/7fa2af80.pub
    | sed '/^Version/d' > /etc/pki/rpm-gpg/ RPM-GPG-KEY-NVIDIA && echo "
    $NVIDIA_GPGKEY_SUM /etc/pki/rpm-gpg/RPM-GPG-KEY-NVIDIA" | sha256sum -c --strict -

COPY cuda.repo /etc/yum.repos.d/cuda.repo

ENV CUDA_VERSION 9.0.176

ENV CUDA_PKG_VERSION 9-0-$CUDA_VERSION-1
RUN yum install -y cuda-cudart-$CUDA_PKG_VERSION && ln -s cuda-9.0 /usr/local/cuda &&
    rm -rf /var/cache/yum/*
```

```
#nvidia-docker 1.0

LABEL com.nvidia.volumes.needed="nvidia_driver"
LABEL com.nvidia.cuda.version="${CUDA_VERSION}"

RUN echo "/usr/local/nvidia/lib" >> /etc/ld.so.conf.d/nvidia.conf && echo "/usr/local
    /nvidia/lib64" >> /etc/ld.so.conf.d/nvidia.conf

ENV PATH /usr/local/nvidia/bin:/usr/local/cuda/bin:${PATH}
ENV LD_LIBRARY_PATH /usr/local/nvidia/lib:/usr/local/nvidia/lib64

#nvidia-container-runtime
ENV NVIDIA_VISIBLE_DEVICES all
ENV NVIDIA_DRIVER_CAPABILITIES compute,utility
ENV NVIDIA_REQUIRE_CUDA "cuda>=9.0"

#runtime
RUN yum install -y cuda-libraries-${CUDA_PKG_VERSION} cuda-cublas-9-0-9.0.176.4-1 && rm
    -rf /var/cache/yum/*

#cuda
ENV CUDNN_VERSION 7
LABEL com.nvidia.cudnn.version="${CUDNN_VERSION}"

#online cuda
#cuDNN license: https://developer.nvidia.com/cudnn/license\_agreement
RUN curl -fsSL http://developer.download.nvidia.com/compute/redist/cudnn/v7.0.5/cudnn-9.0-linux-x64-v7.tgz -O && tar --no-same-owner -xzf cudnn-9.0-linux-x64-v7.tgz -C
    /usr/local --wildcards 'cuda/lib64/libcudnn.so.*' && rm cudnn-9.0-linux-x64-v7.
    tgz && ldconfig
```

```
#offline cudnn
#cuDNN license: https://developer.nvidia.com/cudnn/license_agreement
COPY cudnn-9.0-linux-x64-v7.tgz /home/cudnn-9.0-linux-x64-v7.tgz
RUN tar --no-same-owner -xzf /home/cudnn-9.0-linux-x64-v7.tgz -C /usr/local && rm /
    home/cudnn-9.0-linux-x64-v7.tgz && ldconfig

#devel
RUN rm -rf /usr/local/cuda-9.0/include && yum install -y cuda-libraries-dev-
    $CUDA_PKG_VERSION cuda-nvml-dev-$CUDA_PKG_VERSION cuda-minimal-build-
    $CUDA_PKG_VERSION cuda-command-line-tools-$CUDA_PKG_VERSION cuda-core
    -9-0-9.0.176.3-1 cuda-cublas-dev-9-0-9.0.176.4-1 && rm -rf /var/cache/yum/*

ENV LIBRARY_PATH /usr/local/cuda/lib64/stubs
```

进入 build 后的基础镜像中，离线安装下载的 cuda 组件

```
cd /home/wjy/Dockerfile/cuda9.0-wjy
#build 镜像
docker build -t centos7.4-cuda9.0-cudnn7.0-base-tmpUser:latest .
#挂载cuda组件目录，进入镜像，安装cuda组件
docker run -it -v /home/wjy:/home/wjy centos7.4-cuda9.0-cudnn7.0-base-tmpUser:latest
    bash
#在镜像中，进入cuda组件目录
cd /home/wjy/components
#安装组件
rpm -ivh *.rpm --force --nodeps
#安装成功后，保存镜像
docker commit 容器ID centos7.4-cuda9.0-cudnn7.0-base-tmpUser:latest
```

验证基础镜像

在装有 GPU 的环境，运行如下命令验证：

```
docker run -it --runtime=nvidia -e NVIDIA_VISIBLE_DEVICES=1 centos7.4-cuda9.0-cudnn7
.0-base-tmpUser:latest bash
```

安装组件

安装组件，可以参照文档中的 Dockerfile 示例，编写安装定制组件的 Dockerfile，将 FROM 换成上面制作的基础镜像，然后在 RUN 中执行安装定制组件命令，Dockerfile RUN 安装命令比较简单，不再详述。

Dockerfile 下载地址：<https://github.com/wjyzzu/inpsur-dockerfile/tree/main/customization/centos7.4>

安装 python3

python 离线包下载地址：<https://www.python.org/downloads/source/>

The screenshot displays the Python source code download page, organized into two columns. Each entry lists a Python version and release date, followed by links to download 'Gzipped source tarball' and 'XZ compressed source tarball'. Two red arrows originate from the left column and point to the 'Python 3.6.6 - June 27, 2018' entry, specifically highlighting the download links.

Python Version	Release Date	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.7.1	Oct. 20, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.6.7	Oct. 20, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.5.6	Aug. 2, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.4.9	Aug. 2, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.7.0	June 27, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.6.6	June 27, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 2.7.15	May 1, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.6.5	March 28, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.4.8	Feb. 5, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.5.5	Feb. 5, 2018	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.8.0b2	July 4, 2019	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.7.4rc1	June 18, 2019	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.6.9rc1	June 18, 2019	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.8.0b1	June 4, 2019	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.8.0a4	May 6, 2019	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.8.0a3	March 25, 2019	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.7.3rc1	March 12, 2019	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.4.10rc1	March 4, 2019	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.5.7rc1	March 4, 2019	Download Gzipped source tarball	Download XZ compressed source tarball
Python 3.8.0a2	Feb. 25, 2019	Download Gzipped source tarball	Download XZ compressed source tarball

在本地服务器下载 python3.6.6 安装包:

```
cd /home/wjy
wget https://www.python.org/ftp/python/3.6.6/Python-3.6.6.tgz
```

挂载/home/wjy 目录到容器:

```
docker run -i -t -v /home/wjy:/home/wjy centos7.4-cuda9.0-cudnn7.0-base-tmpUser:
latest /bin/bash
```

安装 python3.6

```
docker exec -i -t 容器ID /bin/bash #进入基础镜像容器
yum -y install make zlib zlib-devel bzip2-devel openssl-devel sqlite-devel readline-
devel gdbm-devel gcc libffi-devel
tar -zxvf /home/wjy/Python-3.6.6.tgz -C /home/wjy
cd /home/wjy/Python-3.6.6
./configure
make && make install
mv /usr/bin/python /usr/bin/python27
mv /usr/bin/pip /usr/bin/pip27
ln -s /usr/local/bin/python3 /usr/bin/python
ln -s /usr/local/bin/pip3 /usr/bin/pip
```


修改配置文件

可使用如下快捷命令:

```
sed -i "s#/usr/bin/python#/usr/bin/python2.7#" /usr/bin/yum
sed -i "s#/usr/bin/python#/usr/bin/python2.7#" /usr/libexec/urlgrabber-ext-down
source /etc/profile
python -V
```

安装 tensorflow

tensorflow 版本号查看和下载地址：<https://pypi.org/project/tensorflow-gpu/1.8.0/>



直接粘贴下载命令，在镜像中进行在线安装，或者查看历史版本，找到自己要安装的版本。

安装

在线安装如果总是失败或者网速过慢，可以使用 pip download 下载离线包，然后再进行安装。在线安装：

```
pip install tensorflow-gpu==1.8.0 --user --default-timeout=10000 --ignore-installed
--upgrade
```

离线下载：

```
pip download tensorflow-gpu==1.8.0 -d /home/wjy/tian-tan-user-image/tensorflow-gpu1
.8.0
```

离线加在线安装：

```
pip install --find-links=/home/wjy/tian-tan-user-image/tensorflow-gpu1.8.0
tensorflow_gpu-1.8.0-cp36-cp36m-manylinux1_x86_64.whl
```

完全离线安装：

```
pip install --node-index --find-links=/home/wjy/tian-tan-user-image/tensorflow-gpu1
.8.0tensorflow_gpu-1.8.0-cp36-cp36m-manylinux1_x86_64.whl
```


查看版本

```
pip list |grep tensorflow
```

安装 opencv

opencv 查看版本和下载地址：<https://pypi.org/project/opencv-python/3.4.3.18/>

安装

在线安装：

```
pip install opencv-python==3.4.3.18 --user --default-timeout=10000 --ignore-installed  
--upgrade
```

离线下载：

```
pip download opencv-python==3.4.3.18 -d /home/wjy/tian-tan-user-image/opencv3.4.3
```

离线安装：

```
pip install --find-links=/home/wjy/tian-tan-user-image/opencv3.4.3 opencv_python  
-3.4.3.18-cp27-cp27mu-manylinux1_x86_64.whl
```

查看版本

```
pip list |grep opencv*
```

安装 opencv 共享库

由于使用 pip 安装 opencv 后，并不会自动安装 opencv 共享库，需要手动安装，不然 python import cv2 时会报错。共享库：libSM.so.6, libXrender.so.1, libXext.so.6

```
yum whatprovides libSM.so.6 libXrender.so.1 libXext.so.6
```

```
[root@5d7aa9c589a9 /]# yum whatprovides libSM.so.6 libXrender.so.1 libXext.so.6
Loaded plugins: fastestmirror, ovl
Loading mirror speeds from cached hostfile
 * base: mirrors.bfsu.edu.cn
 * extras: mirrors.neusoft.edu.cn
 * updates: mirrors.neusoft.edu.cn
libSM-1.2.2-2.el7.i686 : X.Org X11 SM runtime library
Repo                : base
Matched from:
Provides            : libSM.so.6

libXrender-0.9.10-1.el7.i686 : X.Org X11 libXrender runtime library
Repo                : base
Matched from:
Provides            : libXrender.so.1

libXext-1.3.3-3.el7.i686 : X.Org X11 libXext runtime library
Repo                : base
Matched from:
Provides            : libXext.so.6
```

在线安装:

```
yum install -y libSM libXrender libXext --setopt=protected_multilib=false
```

离线安装:

```
yum install --downloadonly --downloadaddr=/home/wjy/opencv-share libSM-1.2.2-2.el7.
x86_64 libXrender-0.9.10-1.el7.x86_64 libXext-1.3.3-3.el7.x86_64
#安装
cd /home/wjy/opencv-share
rpm -ivh *.rpm --force --nodeps
```

安装 Keras

Keras 查看版本和下载地址: <https://pypi.org/project/Keras/2.2.4/>

安装

在线安装:

```
pip install Keras==2.2.4 --user --default-timeout=10000 --ignore-installed --upgrade
```

离线下载:

```
pip download Keras==2.2.4 -d /home/wjy/tian-tan-user-image/keras2.2.4
```

离线安装:

```
pip install --no-index --find-links=/home/wjy/tian-tan-user-image/keras2.2.4 Keras  
-2.2.4-py2.py3-none-any.whl
```

查看版本

```
pip list |grep Keras*
```

安装 numpy

numpy 查看版本和下载地址: <https://pypi.org/project/numpy/1.15.4/>

安装

在线安装:

```
pip install numpy==1.15.4 --user --default-timeout=10000
```

离线下载:

```
pip download numpy==1.15.4 -d /home/wjy/tian-tan-user-image/numpy1.15.4
```

离线安装:

```
pip install --no-index --find-links=/home/wjy/tian-tan-user-image/numpy1.15.4 numpy  
-1.15.4-cp36-cp36m-manylinux1_x86_64.whl
```

查看版本

```
pip list |grep numpy*
```

配置适配平台的组件

按照《 镜像组件安装手册 》安装 openssh、openssl、jupyter 组件；如果使用 Dockerfile 文件制作镜像，可以将《 镜像组件安装手册 》里面的 Dockerfile 内容合并到该文档的 Dockerfile 文件中，然后使用 Dockerfile 进行在线制作。

可视化功能使用说明

在开发环境和任务管理模块中平台提供主流框架模型可视化的功能，下面主要介绍可视化功能如何使用。

任务管理可视化

在任务管理模块，单机/分布式类型的任务有可视化功能。

Caffe 框架支持 Netscope 网络结构可视化以及 caffe 训练过程可视化。

Tensorflow、Mxnet、Pytorch 框架是基于 TensorBoard 可视化工具实现可视化功能。

PaddlePaddle 框架是基于 VisualDL 工具实现可视化功能。

在任务训练过程中查看或者任务训练完成后，通过单击“可视化”按钮，进入可视化页面。下面通过选择完成的任务介绍可视化功能。

Caffe 可视化


caffe 网络结构可视化

单击“可视化”按钮，打开 Netscope 标签页，开始创建 Caffe 可视化任务。



Netscope

进入文件管理系统，打开 Caffe 的网络结构文件（ /tmpUser/models/caffe/mnist/train_lenet.prototxt ），复制全文，然后在可视化页面的左侧输入框内粘贴复制的内容，键入 shift+enter，得到网络结构。




caffe 训练过程可视化

单击“训练过程可视化”按钮，开始创建 Caffe 训练过程可视化。



弹出训练过程可视化窗口，查看训练时间，损失率，学习率。



TensorFlow 可视化

可视化任务—创建


单击“可视化”按钮，开始创建 TensorFlow 可视化任务。

选择启动文件夹

单击需要打开的可视化文件夹。

TensorBoard


打开 TensorBoard 标签页，展示 TensorFlow 可视化信息。



其它框架的任务可视化可参考“TensorFlow 可视化”章节

开发环境可视化

在开发环境模块，当创建的开发环境运行时，您可以选择相应的可视化工具，如下图：



在开发环境，平台默认提供这三种可视化工具，使用 Tensorboard 工具时，请选择正确的日志文件；Netscope 可视化工具的使用与任务管理一样，参考上述内容。

Visdom 工具是针对 Pytorch 框架任务的可视化，当使用此可视化工具时，请确认所创建的开发环境是

基于 Pytorch 框架镜像创建的，具体使用方式请参考如下介绍：

1. 示例 demo.py 文件地址：‘/{user-name}/ visualization/visdom/demo.py’；
2. 创建基于 Pytorch 框架镜像的开发环境；
3. 打开 Visdom 可视化工具；
4. 修改 demo.py 文件中 hostname 和端口号与 Visdom 可视化工具所打开网页一致；
5. 在开发环境 shell 终端中执行 python demo.py 命令，运行 demo 示例，即可在 Visdom 打开的页面查看此 demo 的可视化。


PyCharm 对接平台

以下示例所用 PyCharm 版本：PyCharm 版本 2018.3 (Professional Edition)


开发环境 ssh 服务运行正常，对应 ip: 10.151.11.53；端口：54963；密码：939549。


PyCharm 配置

打开 PyCharm，选择 “Tools -> Deployment -> Configuration...”




单击左上角 “加号”，选择 SFTP







输入配置名称：



在右侧的 Connection 页面中，Type 选择为 SFTP，对应 Host 和 Port 输入在第 2 步中得到的 ip、端口。在 Password 处输入在第 2 步中得到的密码。




单击“Test Connection”按钮，测试连接。显示连接成功。




此时连接配置完成。

通过 SSH 连接到开发环境


打开 pycharm，选择 “**View > Tool Windows > Terminal**”




此时 pycharm 中出现命令行窗口。



选择菜单 “Tools->Start SSH session...”



在弹出的窗口中选择刚才的配置：




查看刚才的命令行窗口，已经成功连接至开发环境所在的容器。




配置 Remote Debug


打开 pycharm，选择 “Tools > Deployment > Configuration...”



选择之前配置的 DevelopmentEnv 的 Server。单击 “Mappings”。



单击”文件夹”图标，分别选择本地和远端的路径。




Local path 设置为本地代码所在的路径。


Deployment path 设置为开发环境中，代码所在的路径。

如图中所设置。

在 pycharm 对应的代码文件或工程文件夹单击右键，选择 “**Deployment->Upload to...**”



在弹出的对话框中选择，之前创建的 Server 配置” DevelopmentEnv”。



出现以下提示，代表本地的代码文件已经上传至开发环境对应的目录中。



开发环境配置相关 debug 包

在安装了 pycharm 的操作系统中可以找到 Debug 包。

MacOS 中对应路径：

`/Applications/PyCharm.app/Contents/debug-eggs/pycharm-debug-py3k.egg`

`/Applications/PyCharm.app/Contents/debug-eggs/pycharm-debug.egg`

Windows 中对应路径：


Pycharm 安装目录下 /debug-eggs/pycharm-debug-py3k.egg

Pycharm 安装目录下 /debug-eggs/pycharm-debug.egg

pycharm-debug.egg 和 pycharm-debug-py3k.egg 分别对应本地 python 解释器为 python2 和 python3 的情况。

例如需要调试 Python3 的程序，那么将 pycharm-debug-py3k.egg 拷贝至开发环境中 (通过 scp 命令或 xftp、FileZilla 等工具可以上传)。

```
scp -P 46313 pycharm-debug-py3k.egg root@10.151.11.53:/home/*****/DevelopmentEnv
```




在开发环境中，运行 `easy_install pycharm-debug-py3k.egg` 进行安装，运行命令：


```
pip install pydevd
```

配置 Remote debug


单击 “Run->Edit Configurations ...”




在弹出的对话框中单击左上角” + ”号。选择” Python Remote Debug ”。




将这个 Configuration 命名为 DevelopmentDbg, 在 Local host name 处填写本地的 ip 地址, 在 port 处填写一个本地未被占用的端口。




之后复制红框中的两句代码，加入到程序中。



单击红框所示的下拉菜单，选择刚刚创建的 DevelopmentDbg。之后单击绿色的 debug 图标按钮。



当控制台出现” Waiting for process connection...Connected to pydev debugger” 时，进入到开发环境进行操作。



进入开发环境，运行命令：


```
python3 uncompress.py
```

Jupyter Shell终端 容器实例 基本信息

bh3a58sam7tu3-0 shell1

```
root@bh3a58sam7tu3-0:/home/ /DevelopmentDbg# python3 uncompress.py
```

此时 pycharm 中显示如下，程序在第一个断点处停止，可以开始远程调试。



VSCode 对接平台

若要在 VSCode 中远程编辑调试开发环境中的文件，可利用 VSCode 的两个插件实现：Remote-ssh 或者 Remote VSCode。

下面示例所用 VSCode 版本：1.53.2


Windows 系统：win10（已自带安装 ssh）

开发环境 ssh 服务运行正常。

Remote-ssh 插件


1. 下载安装插件

如下图所示：





2. 单击“Remote Explorer”，添加远程环境


如下图所示：



将开发环境 ssh 连接命令复制到上图所示“3”所处位置，确认配置信息，输入“Enter”之后，如下图所示，一般选择个人用户目录下的配置文件：




建议先打开配置文件，修改此环境名称，保存配置文件并刷新。




3. 连接到远程环境


单击远程环境名称，连接远程环境：



选择远程环境的系统类型：




输入远程环境的密码，等待远程环境自动安装相应依赖：



依赖安装完成后，远程环境连接成功


4. 远程调试代码

下面以运行 python 文件为例，其他语言请自行查阅资料。本地和开发环境都需要安装相应的插件并完成相应配置。



5. 免密配置

为解决每次输入密码的麻烦，可将本地电脑个人用户目录.ssh 文件下公钥放到远程环境中。若本地服务器.ssh 目录没有此文件，可用 ssh-keygen 命令生成。




将 id_rsa.pub 复制到开发环境中，在开发环境中执行 cat id_rsa.pub » /root/.ssh/authorized_keys 即可。

Rmate 插件

1. 下载安装插件

如下图所示：



开发环境执行下面命令下载安装插件：

```
wget -O /usr/local/bin/rmate https://raw.githubusercontent.com/aurora/rmate/master/rmate  chmod  
a+x /usr/local/bin/rmate
```

2. 连接到远程环境

新建一个终端，输入如下命令：

```
ssh -R 52698:localhost:52698 username@x.x.x.x -p xxxx 其中，-p 后面为容器的端口号
```


3. 打开文件

在终端执行 `rmate xxx.py` 就可以在本本地编辑修改远程环境中的代码。

预置算例-开发环境使用说明

注意：

1. 创建任意框架的开发环境，进入 shell 终端后，默认目录为当前用户目录；平台自带的算例存放在/defaultShare/user-data 目录下，可以通过文件管理中复制功能复制到用户目录。



以下以 tmpUser 用户为例，所用的资源组是通用标签默认资源组（可根据实际情况选择）；
在/tmpUser/models 目录下，包含所有框架的训练脚本信息；
可以通过 README 获取如何运行作业脚本和注意事项；

2. 可以通过 inaihome_DL_train.sh 脚本提交相应框架的作业脚本；
如提交 caffe 单机单卡作业：

```
./inaihome_DL_train.sh caffe mnist 1
```

如提交 caffe 单机多卡作业（创建开发环境时，需要选择多加速卡资源）：

```
./inaihome_DL_train.sh caffe mnist 2
```

3. 可以到具体框架脚本目录下，通过运行命令提交作业脚本（下文详细说明各框架单卡运行作业脚本）
由于所有作业脚本中路径以 tmpUser 为默认用户；如果是其他用户，首先，通过运行 ./user_path_change.sh user_name 修改作业脚本中的路径信息。

创建开发环境

创建开发环境步骤如下：

1. 单击右上角创建按钮



2. 选择相应框架的镜像

创建开发环境，选择内部镜像；也可以选择外部相应镜像，但需要保证拉取成功。

3. 开发环境参数说明

- 创建开发环境时，自动根据当前的日期和时间进行开发环境的名称的命名。用户可以修改开发环境名称。
- 用户可以选择开发环境要创建到的资源组。
- 右侧显示当前用户所属用户组和个人可用资源以及当前所选资源组下各节点可用资源情况，若选择具体的节点，开发环境将创建在选择的节点上，否则将由系统内部调度机制选择节点。
- 加速卡类型选项列出所选择资源组中所包含的加速卡类型。选择加速卡的类型之后，开发环境会调度到使用对应加速卡的物理机。
- 用户可以配置开发环境所使用的加速卡个数和 CPU 的核数。
- 单击数据集路径右侧的文件夹图标，可以选择要挂载的数据集路径。在弹出的路径选择窗口中选择要挂载的数据集，可以选择多个需要的数据集目录。在创建开发环境时，会将选择的路径挂载到环境中。根据是否更新数据集的开关，可以选择是否会在本地已有缓存数据集的情况下，将数据集更新的部分缓存至本地。使用方式为节点缓存是指将先将数据集缓存至本地，然后挂载到环境中；直接使用是指此数据集直接挂载到开发环境中使用。

更多选项：

内存：大小默认为 0，表明不限制内存。用户可以自行设置。

端口：用户可自行设置所用的端口号。左边为容器内端口号，右边为容器外端口号，右边可为空。

Shm：share memory size。可以自定义 shm_size 大小（需系统管理员开发权限），默认为 4GB。

副本数：一次创建多个开发环境。

启动命令：支持一定程度上由用户指令启动开发环境，并由使用者保证命令的正确性。

在开发环境创建过程中，数据集在同步下载，会显示下载进度。

等开发环境创建完成后，单击开发环境名称，进入开发环境页面。

4. 开发环境五个标签页：

- 1). Jupyter：用户可通过 Jupyter 工具进行代码的编写、调试等工作。
- 2). Shell 终端：用户进到所创建的开发环境终端中，进行模型的开发与调试。
- 3). 容器实例：展示开发环境具体的容器信息以及其资源监控信息（CPU、加速卡、内存、磁盘和网络）。
- 4). 基本信息：展示开发环境的名称、创建时间、所用镜像等基本信息。
- 5). 数据：如果数据集过大，等开发创建完成之后，也可单击数据集页面查看数据集下载详情。

开发环境模型调试

参考上述创建开发环境的步骤，选择对应框架的镜像，例如 Caffe 的镜像在 Caffe 标签页下；按需设置相应的参数，其中数据集路径需要选择训练脚本对应的数据集，其他参数可按需设置。

Caffe 框架

镜像：Caffe 的镜像在 Caffe 标签页下；

数据集路径：MNIST_caffe；

进入 Shell 终端，切换到 caffe/mnist 目录：

```
cd /tmpUser/models/caffe/mnist
```

启动命令：

```
caffe train --solver=solver_lenet.prototxt -gpu all
```

注意：Caffe 框架不支持开启 GPU 共享的资源组。

Tensorflow 框架

镜像：TensorFlow 的镜像在 TensorFlow 标签页下；

数据集路径：MNIST_data；

进入 Shell 终端，切换到 tensorflow/mnist 目录：

```
cd /tmpUser/models/tensorflow/mnist
```

启动命令：

```
python tf_mnist_single.py
```

Mxnet 框架

镜像：MxNet 的镜像在 MxNet 标签页下；

数据集路径：MNIST_data；

进入 Shell 终端，切换到 mxnet/mnist 目录：

```
cd /tmpUser/models/mxnet
```

启动命令：

```
python mx_mnist_single.py
```

Pytorch 框架

镜像：Pytorch 的镜像在 Pytorch 标签页下；

数据集路径：MNIST_pytorch；

进入 Shell 终端，切换到进入 pytorch/mnist 目录：

```
cd /tmpUser/models/pytorch/mnist
```

启动命令：

```
python pytorch_mnist_single.py
```

PaddlePaddle 框架

镜像：PaddlePaddle 的镜像在 PaddlePaddle 标签页下：

数据集路径：MNIST_data；

进入 Shell 终端，切换到 paddle 目录：

```
cd /tmpUser/models/paddle
```

启动命令：

```
python paddle_mnist_single.py
```

Other 框架

通过相应的镜像创建环境，脚本及数据集需要与镜像一致。

远程连接开发环境

鼠标放到开发环境列表 SSH 列的查看按钮上，可以查看当前开发环境的连接命令。打开一个 Shell 软件，复制命令就可以在 Shell 中登录本开发环境。

如果是本地 xshell 直接登录的前提下需要把复制中的-p 参数去掉，比如 ssh root@IP 30100 如果是本地 xshell 通过已有的系统中登录，直接复制就可以连接，比如 ssh root@IP -p 30100 其中密码用户可以按需设置成随机或者自定义密码。

预置算例-训练任务使用说明

训练任务创建

1. 单击“创建”按钮，开始创建训练任务

创建训练任务

< 任务管理

☆ 归档

☆ 归档

任务名称 *

20231108154251

镜像 *

外部镜像

请选择

请选择

部署类型 *

单机

Worker个数 *

-

1

+

运行 *

脚本模式

命令模式

脚本 *

执行目录 *

资源组 *

请选择

2. 设置训练任务相关参数

训练任务参数意义：

名称：任务名字（只接受英文字母、数字和下划线，不能以下划线开头）。

镜像：在第一个窗口选择对应框架名称，在第二个窗口选择框架版本。

外部镜像：勾选该选项后，用户可以选择外部镜像创建训练任务。

部署类型：根据所用框架及训练任务，可选择不同的部署类型（单机、分布式、MPI）。

资源组：选择资源组。

右侧显示当前用户所属用户组和个人可用资源以及当前所选资源组下各节点资源剩余情况；若选择具体的节点，训练任务将创建在选择的节点上，否则将由系统内部调度机制选择节点。

加速卡类型：选择资源组内相应的加速卡类型。

CPU/加速卡：选择 Worker 节点的 CPU/加速卡资源配置方案，当配额方案是“自定义”时，会弹出加速卡和 CPU 窗口，可以自定义设置资源配置方案。

脚本：单击窗口后的按钮，弹出“选择启动文件”窗口，通过历史访问或者个人数据选择相应训练脚本或者单击命令模式使用命令模式。脚本参数：在“脚本参数”输入框可以输入 python 脚本所需要的参数。

执行目录：当选择脚本模式时，根据脚本需要，请指定相应的执行目录（一般为脚本所在目录）。

数据集：单击窗口后按钮可以弹出“选择数据集窗口”，选定后单击确定。勾选下方“更新数据集”选项可以在进行训练前更新所选定的数据集。

更新数据集说明：勾选后，平台自动会对缓存的数据集进行识别，如果部分数据集文件发生变化，平台会实现增量更新；如果缓存中没有数据集，会全量下载数据集。如果缓存中的数据集正在使用，则不能进行更新操作。

当选择数据集之后，使用方式为节点缓存是指先将数据集缓存至本地，然后在训练任务中挂载使用；直接使用是指此数据集目录直接挂载到训练任务中使用。

更多配置：

功能	描述
调度策略	配置调度策略，目前支持 spread(默认)、bestfit。
端口	提供服务端口访问能力，容器内服务端口会自动映射到宿主机的端口上，且支持多个端口设置，多端口之间用英文状态下的分号隔开，第一个端口具有容错能力，其他端口只提供服务功能。设置完成后，可以在实例列表中查看到对应的端口信息。
内存	配置训练任务 Worker 节点所需要的内存，当设置为 0 时表示无限制（需要小于 Worker 所在主机目前剩余内存量）。
日志路径	训练日志输出路径，单击窗口后的按钮，选择相应路径后单击“确定”。
目录挂载	可供挂载的公共目录。
Shm	容器 shm_size 参数，默认为 4GB。
模型输出	开启开关后，配置输出模型的名称、路径，任务成功运行后，会自动按照配置输出一个模型，可以在模型管理中维护该模型。

3. 创建任务成功

任务状态进入“排队中”；当资源分配完成后，任务状态进入“运行中”，单击任务名称，可查看训练任务的输出日志；训练完成后任务自动进入“终结任务”内，训练成功时任务状态为“完成”，训练失败时任务状态为“失败”。

注意：以下以 tmpUser 用户为例，在/{用户名}/models 目录下，包含所有框架的训练脚本信息

单机任务创建

Caffe 单机任务

1. 单击“创建”按钮，开始创建 Caffe 单机任务。

2. 填写任务信息

镜像：选择 Caffe 镜像

数据集：/MNIST_caffe

启动文件：Caffe 单机训练脚本：/tmpUser/models/caffe/mnist/solver_lenet.prototxt

或者使用命令模式：

```
caffe train --solver=/tmpUser/models/caffe/mnist/solver_lenet.prototxt --gpu=all
```

其他参数按需设置。

Tensorflow 单机任务

1. 单击“创建”按钮，开始创建 Tensorflow 单机任务。

2. 填写任务信息

镜像：选择 Tensorflow 镜像

数据集：/MNIST_data

启动文件：Tensorflow 单机训练脚本，/tmpUser/models/tensorflow/mnist/tf_mnist_single.py

或者使用命令模式：

```
python /tmpUser/models/tensorflow/mnist/tf_mnist_single.py
```

其他参数按需选择。

Mxnet 单机任务

1. 单击“**创建**”按钮，开始创建 Mxnet 单机任务。

2. 填写任务信息

镜像：选择 Mxnet 镜像

数据集：/MNIST_data

启动文件：Mxnet 单机训练脚本，/tmpUser/models/mxnet/mx_mnist_single.py

或者使用命令模式：

```
python /tmpUser/models/mxnet/mx_mnist_single.py
```

其他参数按需选择。

Pytorch 单机任务

1. 单击“**创建**”按钮，开始创建 Pytorch 单机任务。

2. 填写任务信息

镜像：选择 Pytorch 镜像

数据集：/MNIST_pytorch

启动文件：Pytorch 单机训练脚本，/tmpUser/models/pytorch/mnist/pytorch_mnist_single.py

或者使用命令模式：

```
python /tmpUser/models/pytorch/mnist/pytorch_mnist_single.py
```

其他参数按需选择。

PaddlePaddle 单机任务

1. 单击“**创建**”按钮，开始创建 PaddlePaddle 单机任务。

2. 填写任务信息

镜像：选择 PaddlePaddle 镜像

数据集：/MNIST_data

启动文件：Paddlepaddle 单机训练脚本，/tmpUser/models/paddle/paddle_mnist_single.py

或者使用命令模式：

```
python /tmpUser/models/paddle/paddle_mnist_single.py
```

其他参数按需选择。

分布式任务创建

Tensorflow 分布式任务

1. 单击“**创建**”按钮，开始创建 Tensorflow 分布式任务。

2. 填写任务信息

镜像：选择 Tensorflow 镜像

数据集：/MNIST_data

启动文件：Tensorflow 分布式训练脚本，/tmpUser/models/tensorflow/mnist/tf_mnist_dist.py

或者 Benchmark 分布式测试脚本：/tmpUser/models/tensorflow/benchmarks-cnn_tf_v1.15_compatible/scripts/tf_cnn_benchmarks/benchmark_cnn_distributed_test_runner.py

部署类型：PS/Worker；PS 个数：1；Worker 个数：2

其他参数按需设置。

Mxnet 分布式任务

1. 单击“**创建**”按钮，开始创建 Mxnet 分布式任务。

2. 填写任务信息

镜像：选择 Mxnet 镜像

数据集：/MNIST_data

启动文件：Mxnet 分布式训练脚本，/tmpUser/models/mxnet/mx_mnist_dist/mx_mnist_dist.py（注意：若使用 GPU，脚本中 84 行，gpus 需修改为 gpus: '0'）

部署类型：Server/Worker；Server 个数：1；Worker 个数：2

其他参数按需设置。

Pytorch 分布式任务

1. 单击“**创建**”按钮，开始创建 Pytorch 分布式任务。

2. 填写任务信息

镜像：选择 Pytorch 镜像

数据集：/MNIST_pytorch

启动文件：Pytorch 分布式训练脚本，/tmpUser/models/pytorch/mnist/pytorch_mnist_dist.py

部署类型：Master/Worker；Master 个数：1，Worker 个数：2

其他参数按需设置。

MPI 任务创建

Caffe MPI 任务

1. 单击“**创建**”按钮，开始创建 Caffe MPI 任务。

2. 填写任务信息

镜像：选择 Caffe 镜像

数据集：/MNIST_caffe

部署类型：MPI；Worker 个数：2

启动文件：Caffe MPI 训练脚本，/tmpUser/models/caffe/mnist/solver_lenet.prototxt

或者使用命令模式：

```
mpirun -allow-run-as-root -np 2 caffe train --solver=/tmpUser/models/caffe/mnist/
solver_lenet.prototxt --gpu all
```

其他参数按需选择。

Tensorflow MPI 任务

1. 单击“**创建**”按钮，开始创建 Tensorflow MPI 任务。

2. 填写任务信息

镜像：选择 Tensorflow 镜像

数据集：/MNIST_data

部署类型：MPI；Worker 个数：2

此镜像只能使用命令模式：

```
mpirun --oversubscribe --allow-run-as-root -np 2 -mca pml ob1 python /tmpUser/models/
horovod/tensorflow_mnist.py --data_dir=/MNIST_data
```

其他参数按需设置。

Mxnet MPI 任务

1. 单击“**创建**”按钮，开始创建 Mxnet MPI 任务。

2. 填写任务信息

镜像：选择 Mxnet 镜像

数据集：/MNIST_data

此镜像只能使用命令模式：

```
mpirun --oversubscribe --allow-run-as-root -np 2 -mca pml ob1 python /tmpUser/models/horovod/mxnet_mnist.py --data_dir=/MNIST_data
```

部署类型：MPI；Worker 个数：2

其他参数按需设置。

Pytorch MPI 任务

1. 单击“**创建**”按钮，开始创建 Pytorch MPI 任务。

2. 填写任务信息

镜像：选择 Pytorch 镜像

数据集：/MNIST_pytorch

部署类型：MPI；Worker 个数：2

启动文件：Pytorch MPI 训练脚本，/tmpUser/models/horovod/pytorch_mnist.py

或者使用命令模式：

```
mpirun -np 2 -allow-run-as-root python /tmpUser/models/horovod/pytorch_mnist.py
```

数据处理工具-通过开发环境启动镜像使用说明

label studio 是一个具有标准化输出格式的多域数据标注工具。

通过开发环境启动数据处理工具镜像

平台预置了数据标注镜像 label-studio，镜像类型属于 Other，可以在**镜像管理**查看，如下图：



下面具体描述下该镜像通过开发环境启动的过程：用户单击**模型开发 > 开发环境**中的创建按钮创建开发环境，选择 other 框架下的 label-studio 镜像，选择资源组、网络类型，选择不使用加速卡并填写 CPU 核数，如下图：

环境名称 *

20231123172314

镜像 *

外部镜像

other

5000/other/heartexlabs/label-studio:latest

资源配置

资源组 *

zhn111

集群网络类型 *

ether

加速卡系列 *

不使用加速卡

CPU *


-

2

+

核

为了保证该开发环境删除时，您的标注数据仍然被保留，您可以在创建开发环境时选择用户家目录的某一个目录作为数据标注目录，这个目录权限需要为 775，保证数据标注的数据能正常写入，并填写该目录的挂载路径（必须是 /label-studio/data ），采用直接使用的方式，这样该目录将被挂载到开发环境中，如下图：




label-studio 启动时固定使用 8080 端口，因此，需要在开发环境中进行端口映射，端口范围填写开发环境允许的范围（端口范围可以通过“设置 > 常规设置 > 基础设置 > 业务配置 > 端口配置”设置），如下图：


更多选项



在启动命令中输入启动命令：label-studio log-level DEBUG，如下图：



上述信息填写完成后，单击确定创建开发环境，等到开发环境的状态为运行中时，可以通过节点 ip 和创建开发环境时填写的外部映射的端口号使用 http 进行访问，如下图：低版本的谷歌浏览器可能会遇到一些问题，包括但不仅限于登录报错，无法打开图片标注等，推荐使用最新版本的谷歌浏览器。



启动完成后就可以创建账户，登录使用了，详细使用参考 label-studio 官网，链接如下：

<https://labelstud.io>